主权过滤中大语言模型判断的机制与边界条件：四家族、80 次运行的机制性重放

Xutong Wang[1], Wen Hu[1,2], Ya Yu[1]

摘要—信息过滤器必须丢弃几乎所有候选信息，但大语言模型（LLM）的判断能否取代结构性召回机制，仍不明确。我们将 LLM 智能体用作主权认知获取（SEA）判断层的模式生物，而非人类替代被试。这项已完成、协议冻结的机制研究在一个学术语料库上进行了重放，涵盖四个模型家族、80 次独立运行和 73,547 条有效智能体-日记录。O/C/Q/G 的判断臂关键机会召回率分别为 0.443/0.534/0.514/0.519，而诚实特征参照为 0.241；每个家族均报告运行层自助法 95% 置信区间。然而，引用代理价值仅在 C/Q 中上升，在 O/G 中下降。两个真实语料试点界定了适用范围：学术域高召回的强形式被拒绝（最佳端到端召回率为 0.28）；金融域组合内召回率仅在极为有利的配额匹配条件下达到 0.952，并在新闻扩展后稀释至 0.910。因此，语义判断改善了日简报内的选择，却既不能提供架构层面的召回保证，也不能提供人类获益的证据。完整的 P1–P12 检验组合仍在进行中；本文不声称对人类有效，也不声称已完成总体层面的验证。

关键词： 大语言模型智能体；模式生物；信息过滤；关键召回；机制性重放；认知主权

单位： 1 南京航空航天大学电子信息工程学院，中国南京；2 江苏云禾峰智能科技有限公司，中国江苏。通信作者：Wen Hu (huwen@nuaa.edu.cn)。

1. 引言

在数字信息环境中，稀缺资源是注意力，而非候选信息 [1]。因此，无论约束来自人类工作记忆 [2]，还是人工智能体的上下文与推理预算，有限智能体都必须在深度处理前丢弃大多数到达项。LLM 智能体为研究这一问题提供了独特的实验载体：其决策可以重放，反事实可以配对，完整的选择轨迹可以审计 [3]。对于载体中立机制，它们是有用的模式生物；但其顺从性、训练知识以及人类情感的缺失，使其不适合作为直接的人类替代被试。

这一区分对主权信息获取至关重要。推荐系统研究日益关注如何将福祉或价值编码进排序 [4]，以及不一致偏好为何会使参与度优化受挫 [5]。与此同时，LLM 智能体研究记录了强大的工具调用系统与新的操纵攻击面，包括间接提示注入 [3], [6], [7]。然而，任何一类文献都无法独自回答三个可分离的实证问题：关键信息是否到达候选集？到达后判断层是否选择了它？这种选择是否提升了决策相关价值？将三者合并为一个端到端准确率指标，会掩盖实际失效的机制。

主权认知获取（SEA）将获取界定为有界优化问题，其中智能体拥有目标、写入权和审计轨迹。其双通道架构将结构性覆盖与评分发现分开。完整的 SEA 专著展开了完整的定理体系 [21]；配套期刊理论论文以常规论文形式呈现该体系。相比之下，本会议论文的贡献是实证与机制层面的：冻结一项判断层重放，报告跨家族效应量与不确定性，并刻画端到端召回在何处失效。只有在规定测量准则或防止过度主张所必需之处，本文才保留理论内容。

本文贡献有四点。第一，我们报告一项**已完成、范围受限的机制研究**，而非完整的 SEA 验证组合：在学术语料时序重放上，涵盖四个 LLM 家族、80 次独立运行和 73,547 条有效智能体-日记录。第二，我们表明，相较于诚实特征参照，判断提高了关键机会召回率，而引用代理价值的符号却随家族而异。因此，召回与价值不能作为可互换的终点。第三，双域真实语料试点提供了适用边界的证据：学术域高召回的强形式被拒绝，而金融域的有利结果仅出现在受限组合与配额配置内。第四，我们公开完整的统计协议、排除规则和冻结记录，使负结果及推断范围均可审查。

2. 机制检验所需的最低理论

2.1 SAP、认知主权与双通道

主权获取问题（SAP）选择获取策略 π，其所属的策略集 Π_S 受认知主权约束：

$$\max_{\pi\in\Pi_S} \mathbb{E}_\pi\left[\sum_{t=1}^{H}\beta^t \{\mathrm{VOI}_t(A_t)+\zeta\Delta\theta_t-\mathrm{Harm}_t(A_t)\}\right],$$

约束条件为

$$\sum_{i\in A_t}\tau_i + c(\pi_{\mathrm{pull},t}) + c_{\mathrm{ref}} \le T.$$

其中，A_t 为消费集合，T 为注意力预算，VOI 为期望决策价值 [8], [9]，θ 为慢变认知状态变量。拉取式获取、推送过滤与反思共享同一预算。认知主权要求目标可检视、参数写入须经反思层明确授权、不含第三方收益项，且决策可审计。这些条件约束的是 Π_S，本身并不提高准确率。

选择之前，先将文档坍缩为命题，以避免在重复副本上耗费多个名额。随后，双通道分工如下。**通道 I** 在去重后直接放行受监测的信源类和已声明的观察清单实体，并设有预算可行性报警。**通道 II** 对剩余候选排序，以发现新信息并分配稀缺名额。本实验单独考察日简报构建之后的判断。它不验证完整的 SAP、拉取/推送的全局最优性、人类目标引出，或完整的双通道技术栈。

2.2 评分分离度：排序器为何不能承载 95% 的承诺

令 π_0 为关键命题比例，β 为消费比例，d' 为关键与非关键评分分布之间的标准化分离度 [10]。在等方差高斯评分下，选取评分最高的 β 比例候选，可得

$$(1-\pi_0)\bar{\Phi}(z)+\pi_0\bar{\Phi}(z-d')=\beta, \qquad R=\bar{\Phi}(z-d'),$$

其中，$\bar{\Phi}$ 为标准正态分布上尾，R 为评分通道召回率。与高斯模型无关，计数约束给出 $R\le\min(1,\beta/\pi_0)$。在高斯特例下，要达到目标召回率 R，需要

$$d'\ge\Phi^{-1}\left(1-\frac{\beta-\pi_0 R}{1-\pi_0}\right)+\Phi^{-1}(R),$$

前提是 $\beta\ge\pi_0 R$。当 $\beta=0.0125$、$\pi_0=0.01$ 且 $R=0.95$ 时，阈值为 $d'\ge 4.39$。该准则是预算—分离度约束，并非声称任一实际部署的评分器都服从高斯分布。它预示着，仅靠表征改进不足以为极端过滤提供可信的召回保证。

2.3 冗余：条件性架构界

令 $p_{\min}$ 为每个受监测类别对关键命题覆盖概率的经核验下界。若 k_{eff} 为信源类独立子集的大小，则

$$P(\text{miss } e) \le (1 - p_{\min})^{k_{\text{eff}}}.$$

该界以覆盖下界和独立性结构为条件；相关信源会降低 k_{eff}，而过小的 $p_{\min}$ 会使界失去实际约束力。若被观察实体发布了内容且配额仍可行，观察清单可消除过滤阶段的漏报，但无法迫使保持沉默的实体发布内容。因此，SEA 的综合设计有意采取非对称分工：评分负责发现，架构负责任何有依据的召回保证。由此，主动搜索、信源探索和监测清单构建与排序同等重要 [11]–[15]。

3. 方法

3.1 冻结的判断层重放

主要研究采用协议 v2.1 和 arXiv 2019 年 9 月学术重放。监测全集包含 2,576 条命题。冻结的关键性代理将当月被引量前 2% 的论文标记为关键，得到 $K^* = 52$；被引数据是回顾性评价标签，而非作为事前真值提供的信息。该学术生态为单信源，因此命题坍缩比为 1.0。

在每个模拟日，框架构建至多 18 个条目的日简报：先列入机构清单的通道 I 条目，再补入按代理分数排序的通道 II 候选。智能体接收研究者画像和已声明的决策集，并以结构化输出至多选择三个条目。预算由框架而非模型强制执行，结果也由框架计算。外生凸显性注入与关键性分别记录。

区分三种选择逻辑。**判断臂**是 LLM 对每日简报所作的选择。**半 oracle 参数臂**在含噪的引用相关代理（$\rho = 0.4$）下选取排名前三的条目；由于它使用了与未来相关的信号，所以是一个要求很高的比较对象，而非真正可部署的诚实评分器。**诚实特征参照**利用前窗的元数据和滚动前推的 TF-IDF 新颖度拟合逻辑评分，然后不调用 LLM 而选择三个条目。其冻结的 30 天参照召回率为 0.241。它是描述性参照，而非另一个包含 80 次运行的随机化臂。

主要终点是**关键机会召回率**：重放日简报中，关键命中数除以出现的关键机会数。对每次运行，先分别汇总命中数与机会数，再计算召回率；每个家族的估计值是其各次运行估计值的非加权均值。该终点以上游候选构建为条件，不得与语料库层面的端到端召回率混淆。次要终点为引用代理价值，即对所选条目计算 $\sum \log(1+\text{citations})$。$\Delta$value 先在有效智能体-日上计算判断臂减参数臂之差的运行层均值，再对运行求家族均值。它是冻结的代理度量，而非实际实现的 SAP 效用或人类福祉。

3.2 复制、有效性与模型分离

O 和 C 家族各有 30 次独立运行；锚点家族 Q 和 G 各有 10 次，共计 80 次运行。名义上的运行模板是在固定种子下使用 30 个智能体、模拟 30 天；实际执行采用分片，重试与补齐均由冻结协议规定。有效记录要求选择结果非空；每次纳入分析的运行都必须通过**至少** 900 条有效记录的完整性门限——这是下限，而非上限。冻结分析包含 73,547 条有效智能体-日记录：O 27,385；C 27,459；Q 9,321；G 9,382。提示词、模型实例、解码参数、后端分配和访问条件均在发布材料中冻结。研究结论仅适用于这些实例，而不适用于相关厂商的整个产品线。

协议 v1 记录和未完成的第五家族 F 在分析前已被隔离，不纳入任何观测数据。凡需由模型承担不同角色之处，被试、评分器、生产者/红队和评审至少在三个家族之间分离；本重放的关键命中由框架计算，而非模型自我报告。跨家族复制检验结果对模型家族特异机制的稳健性；同一家族内的后端差异则作为已声明的实现条件，而非新的生物学重复。

3.3 统计分析

运行是复制单元，智能体-日是分析单元，推断按运行分层或以运行为单位重抽样。绝不为虚增自由度而将智能体-日视为独立复制。我们使用 10,000 次运行层重抽样，报告 95% 百分位自助法区间。判断臂与参数臂在同一智能体-日上的配对比较，在各家族内采用精确 McNemar 检验，并进行 Benjamini–Hochberg 校正。经连续性校正的 Cochran–Mantel–Haenszel（CMH）汇总以 80 次运行为层，其解释从属于效应量与区间估计。

对于 χ^2_1 CMH 统计量，上尾概率严格按 $p = \operatorname{erfc}(\sqrt{\chi^2/2})$ 计算。极端尾概率仅用于数量级参考，绝不作为校准后的错误概率，也不替代效应量估计。

3.4 独立的双域适用性试点

学术与金融试点分别冻结，不与 80 次运行的推断数据集合并。金融重放涵盖 2019 年 9 月的 EDGAR 披露和扩展到十个域的公开新闻存档，包含 1,876 条命题和 15,368 篇文档。它采用两类目标：具有法定重大性的 8-K 申报文件和市场移动日。关键的有利配置让 25 家持仓公司通过通道 I 直通，每日仅有 4.6 条命题，并以 $m = 5$ 的配额匹配该供给。我们还考察新闻扩展后的同一设置，此时新增命题会竞争配额。这些试点检验的是适用条件，而非普遍召回保证。

4. 结果

4.1 四家族判断层复制

每个家族的召回率均至少达到诚实特征参照 0.241 的 1.8 倍，且四个召回区间整体位于该参照值之上。这些区间量化的是家族召回率的运行间不确定性，而非判断臂与特征参照之差的置信区间。更重要的是，即使尚未计入上游漏报，0.443–0.534 仍远低于 95% 的召回目标。

与半 oracle 参数臂相比，按运行分层的 CMH 汇总合并了 14,550 个判断臂较优与 9,673 个参数臂较优的不一致智能体-日，得到 $\chi^2_1 = 981.52$。由上式可得 $p \approx 1.9 \times 10^{-215}$。我们报告该渐近尾概率仅作参考；实质结果是在多次运行中重现的召回效应大小及其运行层不确定性，而不是极端的 p 值。

4.2 召回提升并不意味着价值一致提升

价值结果按家族分化：C 和 Q 的 Δvalue 为正值（+0.676 和 +0.432），O 和 G 则为负值（−0.175 和 −0.223）。因此，命中维度的结果在四个家族中均得到复制，但平均引用代理价值增量并未同样复制。我们将这一两正两负的分化视为一项发现，而非可通过平均抹去的噪声。冻结结果中没有价值差值的置信区间，因此不对任一符号作统计显著性判断。

另一项包含 40 个问题的智能体校准诊断进一步表明，不能将各家族视为可互换。O/C/Q/G 的 Brier 分数 [18], [19] 分别为 0.170/0.232/0.233/0.285。这些是模型特定的校准测量，不是校准改善，也不是人类测量。结合价值分化，这些结果提示应依据家族分别部署和复制，而不是声称“LLM”具有一种稳定的判断效应。

4.3 双域适用边界

所有报告的特征-d' 估计值均低于 4.39。由于该阈值是高斯特例，且试点使用代理标签，因此这一结果支持架构/评分的分工，而非对该恒等式的独立证明。

学术结果拒绝了高召回的强形式。作者粒度监测几乎未覆盖回顾性关键集合，机构清单虽改善覆盖但仍对容量敏感；两类诚实特征产生的 $d' = 0.73$–0.77，远低于高斯准则所要求的 4.39。替代引用代理——早期被引和跨领域被引——并不改变拒绝的方向。这

表 I
表 1. 冻结的四家族机制性结果。召回区间为运行层自助法 95% 置信区间；Δvalue 为描述性指标。

家族	运行数	有效记录	关键召回率 [95% CI]	Δvalue
O	30	27,385	0.443 [0.433, 0.454]	−0.175
C	30	27,459	0.534 [0.527, 0.541]	+0.676
Q	10	9,321	0.514 [0.502, 0.526]	+0.432
G	10	9,382	0.519 [0.498, 0.539]	−0.223

表 II
表 2. 冻结的真实语料试点口径与边界证据。

指标	学术试点	金融试点
语料库与代理	2,576 条命题；被引量前 2%，$K^* = 52$	1,876 条命题/15,368 篇文档；法定与市场目标
坍缩比 ρ_c	1.0（单信源）	8.19
覆盖 $\widehat{p}_{\min}$	作者清单 ≈0.02；机构清单 0.17–0.37	法定 1.00；市场 0.70–0.73
特征 d'	0.73–0.77	法定 2.65–3.49；市场 0.54–0.60
召回边界	**最佳端到端召回率 0.28：强形式被拒绝**	**0.952 仅出现在有利的组合内设置；新闻扩展后为 0.910**

是关于获取、清单构建与配额适配的边界结果，与表 1 中较高的以日简报机会为条件的召回率并不矛盾。

金融域的 0.952 有意作了严格限定：它是 $m = 5$、25 家持仓公司直通、每日 4.6 条命题且配额与这一有利供给相匹配时的组合内市场代理召回率。它不是所有事前关键金融信息的召回率。新闻层扩展引入了同一配额的竞争，使召回率稀释至 0.910。法定重大申报文件表明，制度性来源如何提供高覆盖下界；市场移动标签并不继承这种法律保证。在所汇集的披露/新闻层中，约 90% 的市场移动日没有可归因的当日文档，进一步限制了构念效度。

另一项公共层诊断进一步强化了边界主题。原始多类别认证产生的关键性提升倍数为 0.63×，表明其发生了注意力驱动的反转，而非富集。质量加权惊讶度认证将提升倍数部分恢复至 1.23×，但仍只是弱富集，不能作为对抗鲁棒性的证据。因此，除非审计其来源与稀缺性，冗余计数所衡量的可能是注意力集中。

5. 讨论

5.1 证据的三阶段解释

结果区分了端到端评分经常混淆的三个阶段。**到达**关注关键命题是否进入日简报；**判断**关注其到达后智能体是否选择它；**价值**关注由此产生的集合是否改善已声明的目标。表 1 支持 LLM 在判断阶段的贡献。表 2 表明，良好的判断无法找回被上游排除的命题，而配额竞争会稀释直通效果。随后，Δvalue 的符号分化表明，在第二个基于引用的终点上，更多关键命中并不必然意味着更高价值。

这种分解使 SEA 的综合框架更加清晰，而非削弱它。诚实特征比较表明，语义判断包含了低成本的滚动前推特征未能捕捉的选择信号。它并未表明 LLM 的端到端 $d' \geq 4.39$，也未消除评分分离度瓶颈。反之，冗余界是否有力，取决于实测的 $p_{\min}$、有效独立性以及供给—配额适配程度。“高召回是结构性的”因而是一项设计要求和可证伪的条件性主张，而非附加在 SEA 标签上的保证。

模式生物策略之所以有效，正因为它能定位这些机制。受控智能体可呈现反事实选择行为，并允许进行大量基于随机种子的复制。它们不能回答应由谁写入目标、人们如何声明这些目标，或人类福祉是否改善。在重放中，反思层是工程化的画像与宪法，而不是已正确引出某个人第二序意志的证据。

5.2 与相邻研究的关系

SEA 与预算约束下的信息获取研究共同关注理性疏忽和主动学习 [11], [14]，但它还把目标的所有权与覆盖的来源纳入实证问题。搜索与觅食规则 [12], [13] 为信源探索提供依据，而次模监测分配 [15] 说明清单构建为何是一个优化问题，而非例行性的 top-N 步骤。我们的贡献不是新的通用搜索定理，而是展示这些组件在组合时何处成功、何处失败的证据。

同样，曝光多样性与算法单一文化研究为公共兜底层提供了动机 [16], [17]，但认证反转表明，若原始覆盖计数成为公共层的认证依据，该层也会再现注意力集中。最后，提示注入研究 [6], [7] 表明检索内容是一种攻击面。本研究并不声称具有对抗鲁棒性：它提供的是一个基线，后续注入与协同伪造检验必须据此评估。

5.3 效度威胁与证据状态

五项局限界定了本文主张的边界。**构念效度：**引用影响和市场移动是回顾性代理，而非对关键性的独立事前判断。金融法定目标以规则为基础，但其范围窄于所有决策相关信息。**生态效度：**两个重放均只涉及一个月，公开新闻存档也不完整；两个域不能建立时间、文化或总体层面的普适性。**归因：**半 oracle 代理参与了上游日简报的构建，而诚实特征参照并非完整的现代 RAG 或端到端 LLM 基线。直接端到端 LLM 消融实验及 RAG/福祉基线仍处于设计阶段。**模型依赖：**冻结实例、量化、后端和不等的运行次数都会制约估计；因容量限制而裁撤的家族也可能限制代表性。**有效性筛选：**空选择按冻结规则被重试或排除，因此实际运行中的失败率应与基于有效日的科学终点一并检查。

向人类转移是另一个尚未解决的推断步骤。在此前对 Bail 对立观点接触范式的重放 [20] 中，效应方向在不同模型家族间并不一致，这说明为何不能通过类比，把载体中立的选择机制转化为人类心理效应。本文不对人类侧功效、福祉、校准改善、反噬防护或去技能

化防护作出任何主张。这些陈述仍为**可证伪预测**，而非已确立的结果。HP-0 为**【已设计；数据收集待完成】**，仅检验可行性，不检验功效。完整的 P1–P12 总体层面检验组合**仍在进行中**，其预注册样本量尚未达到。

因此，下一批实验应在相同数据流上设置直接端到端 LLM 与 RAG 基线，分别干预清单质量和配额，并预注册与决策相关联的事前标签。价值分化需要机制分析，以区分召回导向的选择与价值导向的选择。人类研究若日后获批并启动，必须检验其自身的预测，而不能继承智能体结果。

6. 结论

在 80 次运行和 73,547 条有效智能体-日记录中，四个 LLM 家族在关键机会召回率上均表现出可复制的判断层优势，优于诚实特征参照，但引用代理价值并未一致提升。双域试点同样清晰地揭示了架构边界：学术域高召回的强形式被拒绝，最佳端到端召回率为 0.28；金融域的 0.952 仅出现在极为有利、组合内且配额匹配的设置中，并在新闻扩展后稀释至 0.910。因此，LLM 判断是主权获取的一个有用组件，但不能替代候选覆盖、冗余、配额约束或审计。本文是一项范围受限且已完成的机制研究，不意味着完成 P1–P12 检验组合，也不构成人类验证或总体层面有效性的主张。

数据与代码可用性

代码、冻结协议、分析脚本、逐次运行记录和重建材料见 **https://github.com/hurrywhen/sea-nuaa**。冻结存档版本见 **https://doi.org/10.5281/zenodo.23620920**。发布材料标明了协议 v2.1、有效记录与完整性规则、运行层推断流程，以及被隔离的协议 v1 和家族 F 记录。派生语料库可利用冻结种子和访问记录，从已记录的公开 arXiv/OpenAlex、EDGAR、archive.org CDX 和 Wikimedia 来源重建。其中不包含任何人类参与者数据集。

AI 贡献与人类数据声明

LLM 智能体协助了文献综合、软件、实验执行、统计分析和论文起草；它们不作为作者，也不拥有决策权。人类作者提出研究问题，批准协议与冻结的判定规则，批准保留负结果，并审阅最终稿和所报告的数值。部分模型家族既是研究工具，又是研究对象。角色分离、冻结协议、跨家族复制、隔离规则和人工审查可缓解但不能消除由此产生的循环论证风险。

本文未收集或分析任何人类被试数据。智能体-日观测由机器生成，语料库文档也不是参与者数据。本文不对人类功效、安全性或福祉下结论，也不得出总体层面的结论。所有人类侧主张均为需要独立检验的可证伪预测；HP-0 仍为 **【已设计；数据收集待完成】**，不构成证据。

参考文献

[1] H. A. Simon, “Designing organizations for an information-rich world,” in *Computers, Communications, and the Public Interest*. Johns Hopkins Press, 1971.

[2] N. Cowan, “The magical number 4 in short-term memory,” *Behavioral and Brain Sciences*, vol. 24, no. 1, pp. 87–114, 2001.

[3] Z. Xi, W. Chen, X. Guo, et al., “The rise and potential of large language model based agents: A survey,” *Science China Information Sciences*, vol. 68, no. 2, Art. 121101, 2025.

[4] J. Stray, I. Vendrov, J. Nixon, S. Adler, and D. Hadfield-Menell, “Building human values into recommender systems: An interdisciplinary synthesis,” arXiv:2207.10192, 2022; revised version in *ACM Transactions on Recommender Systems*, 2024.

[5] J. Kleinberg, S. Mullainathan, and M. Raghavan, “The challenge of understanding what users want: Inconsistent preferences and engagement optimization,” *Management Science*, vol. 70, no. 9, pp. 6336–6358, 2024.

[6] K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz, and M. Fritz, “Not what you’ve signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection,” in *Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security (AISec)*, pp. 79–90, 2023.

[7] Y. Liu, Y. Jia, R. Geng, J. Jia, and N. Z. Gong, “Formalizing and benchmarking prompt injection attacks and defenses,” in *Proceedings of the 33rd USENIX Security Symposium*, pp. 1831–1847, 2024.

[8] R. A. Howard, “Information value theory,” *IEEE Transactions on Systems Science and Cybernetics*, vol. 2, no. 1, pp. 22–26, 1966.

[9] D. Blackwell, “Equivalent comparisons of experiments,” *The Annals of Mathematical Statistics*, vol. 24, no. 2, pp. 265–272, 1953.

[10] D. M. Green and J. A. Swets, *Signal Detection Theory and Psychophysics*. Wiley, 1966.

[11] C. A. Sims, “Implications of rational inattention,” *Journal of Monetary Economics*, vol. 50, no. 3, pp. 665–690, 2003.

[12] M. L. Weitzman, “Optimal search for the best alternative,” *Econometrica*, vol. 47, no. 3, pp. 641–654, 1979.

[13] P. Pirolli and S. Card, “Information foraging,” *Psychological Review*, vol. 106, no. 4, pp. 643–675, 1999.

[14] B. Settles, *Active Learning Literature Survey*, Computer Sciences Technical Report 1648, University of Wisconsin–Madison, 2009.

[15] G. L. Nemhauser, L. A. Wolsey, and M. L. Fisher, “An analysis of approximations for maximizing submodular set functions—I,” *Mathematical Programming*, vol. 14, pp. 265–274, 1978.

[16] N. Helberger, K. Karppinen, and L. D’Acunto, “Exposure diversity as a design principle for recommender systems,” *Information, Communication & Society*, vol. 21, no. 2, pp. 191–207, 2018.

[17] J. Kleinberg and M. Raghavan, “Algorithmic monoculture and social welfare,” *Proceedings of the National Academy of Sciences*, vol. 118, no. 22, Art. e2018340118, 2021.

[18] G. W. Brier, “Verification of forecasts expressed in terms of probability,” *Monthly Weather Review*, vol. 78, no. 1, pp. 1–3, 1950.

[19] T. Gneiting and A. E. Raftery, “Strictly proper scoring rules, prediction, and estimation,” *Journal of the American Statistical Association*, vol. 102, no. 477, pp. 359–378, 2007.

[20] C. A. Bail, L. P. Argyle, T. W. Brown, et al., “Exposure to opposing views on social media can increase political polarization,” *Proceedings of the National Academy of Sciences*, vol. 115, no. 37, pp. 9216–9222, 2018.

[21] W. Hu, X. Wang, and Y. Yu, “Sovereign Epistemic Acquisition: A Conditional Framework for Active Information Acquisition and Sovereign Filtering under Bounded Agency, with Preliminary Validation,” manuscript v1.7, 2026. [Online]. Available: https://github.com/hurrywhen/sea-nuaa