主权认知获取：有限智能体主动信息获取与主权过滤的条件性框架与初步验证

Sovereign Epistemic Acquisition: A Conditional Framework for Active Information Acquisition and Sovereign Filtering under Bounded Agency, with Preliminary Validation

Wen Hu[1,2] **Xutong Wang**[1] **Ya Yu**[1]

1 南京航空航天大学 电子信息工程学院（College of Electronic and Information Engineering, Nanjing University of Aeronautics and Astronautics），南京 2 江苏云禾峰智能科技有限公司（Jiangsu Yunhefeng Intelligent Technology Co., Ltd.），江苏

通讯作者：Wen Hu（huwen@nuaa.edu.cn）

2026 年 10 月·人机协同完成（AI 贡献见文末《人机协同与 AI 贡献声明》）

摘要

信息生成边际成本趋零的时代，有限智能体面临算术性约束：认知预算 T 与日候选供给 $N \sim 10^4$ 之间的过滤比必须 ≥ 99.8%。现有过滤基础设施优化平台参与度而非主体自身目标——这是系统性的认知主权让渡；而主动获取与被动过滤长期被割裂研究。本文提出**主权认知获取（SEA）**：将信息获取重构为主体第二序目标函数下、认知预算内的统一优化问题——主权获取问题（SAP）——过滤器、其目标函数与审计权的所有权均归属主体。主要结果：(i) (V1)–(V5) 下期望实现决策价值的逐决策结构分解；(ii) 评分分离度瓶颈定理：极端过滤比下纯评分无法支撑 95% 召回，除非 $d' \geq 4.4$，故召回保证必须由架构承担；(iii) 冗余覆盖定理群：$P(\text{miss}) \leq (1-p_{\min})^{k_{\text{eff}}}$——**条件性紧**的界，其强度恰为覆盖下界 $p_{\min}$ 的制度来源（§7.7）；(iv) 注意力无套利定理：边际价值定理、Pandora 规则与消费阈值是同一变分原理的特例；(v) 目标俘获统一模型与防火墙界、人类门控德性收敛（条件收敛：零漂移底分支为定理 10.1，附完整初等证明；正漂移底分支**是猜想而非定理**（猜想 10.1），由 ODE 方法梗概支持并附明确的已核验/未核验清单）、紧急授权遗憾界与公共议程碎片化下界。本文是框架/综合（framework/synthesis）论文：各定理均为标准工具在显式结构下的正确应用；新的是结构与问题表述，而非工具。已完成的证据为双域真实语料试点（负面结果前置：学术域拒绝高召回的强形式，最佳召回 0.28）与四家族 LLM 智能体判断层机制重放——**试点支持与适用域边界映射，而非群体级验证**。标题中”初步验证”的确切含义是：**迄今未收集任何人类被试数据**；一切人类侧结论仍为可证伪预言，且最小人类可行性试点（HP-0，$n \leq 10$，低强度）已完整设计、待数据收集（§15.5；见证据状态声明）。

关键词：认知主权；主动信息获取；信息过滤；信息价值；对抗鲁棒性；公共知识

Abstract

In an era in which the marginal cost of producing information approaches zero, a bounded agent faces an arithmetic constraint: with a daily cognitive budget T against a candidate supply $N \sim 10^4$, the filtering ratio must exceed 99.8%. Today’s filtering infrastructure optimizes platform engagement rather than the agent’s own ends—a systemic abdication of epistemic sovereignty—while active acquisition and passive filtering have been studied in isolation. This paper proposes **Sovereign Epistemic Acquisition (SEA)**, which recasts information acquisition as a unified optimization problem—the Sovereign Acquisition Problem (SAP)—under the agent’s second-order objective and within its cognitive budget, with ownership of the filter, its objective function, and its audit trail resting with the agent. Main results: (i) a per-decision structural decomposition of expected realized decision value under

assumptions (V1)–(V5); (ii) a score-separability bottleneck theorem proving that pure scoring cannot sustain 95% recall at extreme filtering ratios unless $d' \geq 4.4$, so recall guarantees must be architectural; (iii) redundancy-coverage theorems bounding miss probability by $(1 - p_{\min})^{k_{\text{eff}}}$—**conditionally tight** bounds whose strength is exactly the institutional provenance of the coverage floor $p_{\min}$ (§7.7); (iv) an attention no-arbitrage theorem unifying the marginal-value theorem, Pandora's rule, and consumption thresholds as one variational principle; (v) a unified goal-capture model with firewall bounds, human-gated virtue convergence (conditional convergence: the zero-drift-floor branch is Theorem 10.1 with a complete elementary proof; the positive-drift-floor branch is **a conjecture, not a theorem** (Conjecture 10.1), supported by an ODE-method sketch with an explicit verified/unverified checklist), pre-authorization regret bounds, and a fragmentation lower bound for public agenda layers. This is a framework/synthesis paper: each theorem is a correct application of standard tools under explicit structure; what is new is the structure and the problem formulation, not the tools. Completed evidence comprises two-domain real-corpus pilots—**including the negative result stated up front: the strong form of high recall is rejected in the academic domain (best recall 0.28)**—and a four-family LLM-agent judgment-layer mechanistic replay: **pilot support and applicability-boundary mapping, not population-level validation**. "Preliminary validation" in the title means exactly this: **no human-subject data have been collected to date**; all human-side conclusions remain falsifiable predictions, and a minimal human feasibility pilot (HP-0, $n \leq 10$, low intensity) is fully designed and awaiting data collection (§15.5; see the Statement of Evidence Status below).

Keywords: epistemic sovereignty; active information acquisition; information filtering; value of information; adversarial robustness; common knowledge

---

证据状态声明（诚实披露）

验证采用三层架构——以 AI 智能体队列为主实验载体（合成生态与真实语料时序重放），以在线公开人类数据为转移锚点，人类随机对照试验的方案完整存档、暂缓启动。**本文一切人类侧结论（德性收敛、反噬防护、校准改善、去技能化防护）均为可证伪预言而非已证结果；群体级验证（P1–P12 全表）仍在进行中，预注册样本量未达**。已完成双域试点与四家族 LLM 智能体判断层机制重放（判断层的主要机制试验台；学术域，80 独立 run、73,547 有效 agent-day：判断臂关键召回 0.443–0.534，全家族 ≥1.8× 诚实特征臂，跨家族 CMH $p \approx 1.9 \times 10^{-215}$），且负结果先行：学术域的高召回强形式被真实数据拒绝（最优召回 0.28），由此精确化出适用域边界；金融域在极有利的条件下（25 持仓直通、4.6 命题/日、配额适配、事后真值代理）达到组合内召回 0.952、新闻层扩充后稀释至 0.910——该数字是"事后市场移动日召回"而非"事前关键信息召回"，构念效度有限，不构成普遍保证；公共层认证统计量在真实新闻生态中一度失效（lift 0.63×），工程修正后部分恢复至 1.23×（仍为弱富集），其博弈稳健性为开放问题。AI 智能体只能验证载体中立机制及其 AI 实例化，不能验证人类侧参数（H8/H9 已显示跨家族系统性分歧）。**最小人类可行性试点（HP-0，$n \leq 10$，低强度，三个预注册可行性终点：声明协议可完成性、两周校准工具重测、课程可接受性/无反噬旗标）已连同知情同意书、参与材料与分析管线完整设计（§15.5 与补充材料）；在其数据收集完成之前，一切人类侧陈述——包括最小声明协议的可行性——仍为预言**。

Validation follows a three-tier architecture: LLM-agent cohorts serve as the primary testbed (synthetic ecologies and real-corpus temporal replays), online public human data serve as transfer anchors, and a human RCT protocol is fully archived but deferred. **All human-side conclusions (virtue convergence, backfire pro-**

tection, calibration improvement, deskilling protection) are falsifiable predictions, not established results; the population-level main validation (the full P1–P12 battery) is still in progress, and the pre-registered sample sizes have not been reached. What has been completed is the two-domain pilots and the four-family LLM-agent judgment-layer replay—the main validation of the judgment layer (academic domain; 80 independent runs; 73,547 valid agent-days: judgment-arm critical recall 0.443–0.534, every family ≥1.8× the honest feature arm; cross-family CMH $p \approx 1.9 \times 10^{-215}$); and we report the negative results first: the strong form of high recall is rejected by real data in the academic domain (best recall 0.28), which yields precise boundary conditions; the financial domain attains within-portfolio recall 0.952 under highly favorable conditions (25 direct-pass holdings, 4.6 propositions/day, quota-feasible, post-hoc ground-truth proxy), diluted to 0.910 after news-layer expansion—a recall of post-hoc market-moving days, not of ex-ante critical information, with limited construct validity; public-layer certification initially fails in the real news ecology (lift 0.63×) and is only partially repaired to 1.23× (still weak enrichment), with adversarial robustness remaining an open problem. LLM agents can validate the carrier-neutral mechanisms and their AI instantiation, but not the human-side parameters (H8/H9 already exhibit systematic cross-family divergence).

人机协同与 AI 贡献声明

本文由人机协同完成。分工原则与本文主张的主权条件（S1–S4）同构：**写入权、批准权与终审权在人类作者**，AI 全程深度参与但不拥有决策权。如实陈述如下：

AI（大语言模型智能体）的贡献：文献调研与第 2 节谱系梳理；前提化表述与定理陈述的初稿；证明构造协助与形式检查；全部仿真与实验代码；实验执行与统计分析（含预注册判定规则的机械化核对）；结果报告与正文初稿；投稿前一致性审计脚本。

人类作者的贡献：研究问题提出与框架方向（“在信息洪流中最主动、最高效地获取有益于自身的信息”）；关键设计决策的批准（框架命名、三层验证架构、AI 智能体队列为主实验对象、人类 RCT 暂缓启动）；**预注册判定规则与全部负结果处置的批准**（学术域高召回强形式被拒、跨家族不一致效应冻结、域条件性负结论、公共层认证反转触发的实证限定——均由人类审定后如实入档）；全文终审与署名负责。

责任声明：全部证明虽由 AI 协同构造，**人类作者对全部定理陈述与证明的正确性承担最终责任**；核心定理（5.1、6.1、7.1–7.2、8.1、10.1、11.1、12.1）的证明与全部显式数值已经人类作者逐行独立复核。复现代码、审计脚本与实验记录随论文公开（见《数据与代码可用性》）。

特别披露（双重角色）：第 14–15 节的实验对象包含若干 LLM 模型家族——它们既是本文的**研究工具**（协同写作与编码），又是本文的**研究对象**（智能体队列实验的被试）。这一双重角色是本文方法论（模式生物策略，§15.1）的固有特征，特此声明。**由此产生的偏差通道及其缓解（v1.6 扩充）**：(a) 设计偏差通道——写作辅助模型的偏好可能影响了实验设计的取舍；缓解：每一条判定规则、口径与处置都在相应分析运行**之前**经人类批准预注册并冻结，负面结果全部保留并前置报告（§14.7、表 14-3），关键设计决策均由人类作者批准（见上文分工）。(b) 同家族利益冲突通道——若某写作辅助家族同时是被试家族，该家族的结果将带利益冲突风险；被试家族以 O/C/Q/G 匿名化，结构性缓解是**跨家族复制**：家族特异性伪影无法在四家族、80 个独立 run 中重现，唯一裁撤家族被禁区隔离归档而非进入分析（§14.7）。(c) 无自我裁决——本文没有任何结果由来自被试家族的 LLM 评审裁决：模型分离原则（§15.2）强制 被试 ≠ 评分器 ≠ 生产者/红队 ≠ 评审/合并 跨 ≥3 个家族，评审侧另加 10% 人工抽检。残余风险如实承认：在当前的 LLM 研究条件下，工具与对象的完全独立不可达；这是模式生物策略本身的局限（§17 局限 15），不是本文声称已解决的缺陷。

Author contributions (CRediT, 简): Wen Hu——conceptualization, supervision,

funding acquisition, writing (review & editing); Xutong Wang——methodology, software, validation, writing (original draft, AI-assisted); Ya Yu——investigation, data curation, visualization, writing (review & editing)。AI 工具贡献按上述段落如实披露，不具名作者资格（遵循 ICMJE 准则：AI 不能承担署名责任）。

目录

主权认知获取：有限智能体主动信息获取与主权过滤的条件性框架与初步验证 **1**
摘要 1
Abstract 1
证据状态声明（诚实披露） 2
人机协同与 AI 贡献声明 3

第一部分 基础 **6**
1 引言 6
2 相关工作：七大学科板块的共识与争议 9

第二部分 前提与形式框架 **13**
3 工作假设与设计原则 13
4 信息环境与智能体模型 15
5 主权获取问题（SAP）与信息价值分解定理 17

第三部分 核心定理 **22**
6 被动过滤（push）的效率理论 22
7 冗余覆盖定理：激进过滤召回的结构条件与适用域 29
8 主动获取（pull）理论与注意力无套利定理 33
9 对抗鲁棒性：目标俘获的统一 38
10 升华：人类门控的两时间尺度控制 41
11 紧急覆盖：预先授权与极小化极大遗憾 46
12 公共议程层：普遍个性化的外部性治理 48

第四部分 验证与治理 **50**
13 可证伪命题清单 50
14 仿真与 AI 智能体实验 52
15 实测验证：以 AI 智能体队列为主的三层架构 57
16 治理与伦理 61
17 局限与开放问题 62
18 研究路线与结论 64
数据与代码可用性 65
参考文献 65
附录 A 记号表 72
附录 B 技术引理 74

第一部分 基础

1 引言

1.1 问题：鸿沟的算术

设智能体每日可分配给信息消费的认知预算为 T 分钟。以中文深度阅读速度 250–350 字/分钟计，$T = 45$ 对应每日认知产能约 1.1–1.6 万字（250–350 × 45 = 11,250–15,750 字），即 8–12 条实质性内容。而典型信息环境的日候选供给 N 处于 10^4 量级（订阅源、社交流、通知、检索结果的合计）。**过滤比必须 ≥ 99.8%——这不是设计选择，是算术**（命题 6.1 将其形式化为不可逾越的容量下界）。

因此，问题从来不是”要不要过滤”，而是四个递进的追问：

1. **过滤为谁工作?**（主权问题：目标函数归谁所有、由谁写入）
2. **过滤凭什么安全?**（可证明的激进过滤：丢弃 99% 而关键召回不塌）
3. **过滤之外，还该主动抓取什么?**（获取问题：候选池本身如何被主体主动重构）
4. **过滤与获取把人带向何方?**（退化还是升华）

1.2 本文的问题陈述

本文要为如下目标建立坚实的理论基础：

> **在信息洪流中，最高效地、主动地获取有益于自身的信息**。

逐词拆解，这句话包含四个理论承诺，构成本文的骨架：

- **“信息洪流中”**——供给超额是结构性的且随生成式 AI 加剧（前提 2）：内容边际生产成本趋零，信噪比崩溃，操控不再受制作成本约束；机器生成的低价值内容（“slop”）的规模本身已成为被测量的研究对象（Kommers et al., 2026）。操控形态从”让人相信谎言”（灌输）升级为”让人不再相信任何东西”（淹没），后者瓦解的是判断能力本身（Paul & Matthews, 2016）。
- **“最高效地”**——效率必须是可度量、可证明的：单位认知时间换取的信息价值（VOI/分钟）最大化，且在关键信息上的漏报有可证明的上界（第 6–8 节的定理群）。
- **“主动地”**——智能体的信息食谱不是外生给定的：它选择订阅哪些信源、检索什么、监测什么、何时探索新信源、何时离开一个信息补丁。主动获取（pull）与被动过滤（push）消耗同一稀缺资源、服务同一第二序目标，因而是**同一个优化问题的两族算子**（第 5、8 节）。这是本文的核心理论构造。
- **“有益于自身”**——“有益”由谁定义是全部设计的分水岭。本文的立场：由主体的第二序意志 $g^{(2)}$（反思层认可的目标）定义，而非由一阶冲动 $g^{(1)}$（点击时刻的偏好）或平台收益定义（前提 3、主权条件 S1–S4）。

1.3 从被动过滤到主动获取：统一框架的必要性

纯过滤理论回答”到达的信息如何安全过滤”，但把候选池的构成本身当成外生输入。这是一个真实的理论缺口：

其一，候选池的质量决定过滤的天花板。若主体订阅的信源集合本身就遗漏了某类关键命题，任何过滤器都无法召回它——漏报发生在过滤之前。信源组合的选择（监测名额分配）、信源质量的探索（订阅试错）、按需检索（针对性查询）都是**先于过滤的获取决策**，它们与过滤共享同一预算。

其二，push 与 pull 的边际价值必须联合定价。多花 10 分钟检索一个特定问题，还是多消费 10 分钟推送流？直觉上”哪个更值选哪个”，但这需要一个定理：本文的**注意力无套利定理**

（定理 8.1）证明，在凹性假设下，最优分配处所有用途的边际 VOI/分钟相等，且该公共值恰是预算的影子价格；信息觅食的边际价值定理（Charnov, 1976）、Pandora 盒子的停止规则（Weitzman, 1979）与 KKT 条件都是它的实例。统一之后，“主动”不再是一种态度，而是一个有最优性刻画的控制问题。

其三，对抗与主权约束同时作用于两侧。提示注入可以藏在被检索的网页里（pull 侧攻击面），情绪劫持可以来自推送流（push 侧攻击面）；目标函数写入权（S2）既约束过滤权重，也约束检索排序与监测清单。分裂的理论无法给出统一的防护。

既有文献对 pull 侧已有分散的成熟工具——搜索经济学（Stigler, 1961）、带检查成本的搜索（Weitzman, 1979）、最优觅食（Charnov, 1976）、信息觅食（Pirolli & Card, 1999）、理性疏忽（Sims, 2003）、贝叶斯实验设计（Lindley, 1956; Chaloner & Verdinelli, 1995）、主动学习（Settles, 2009）、多臂与不安定 bandit（Gittins, 1979; Whittle, 1988）——但从未与错误信息防护、认知主权、德性动力学整合。本文完成这一整合（第 2.7 节梳理谱系，第 8 节给出统一理论）。

1.4 现有路径的结构性缺口

三条主要技术—学术路径各自存在缺口：

- **推荐系统研究**优化参与度（engagement），其目标函数与主体福祉存在系统性错位；且只覆盖 push 侧，用户的主动检索也被折算为参与度信号。“把人类价值写入推荐系统”的跨学科综合（Stray et al., 2022）与”参与度优化在用户偏好不一致时的识别困难”（Kleinberg, Mullainathan & Raghavan, 2024）从 CS 侧独立抵达了同一问题，但都未触及过滤器的所有权与写入权结构。
- **错误信息科学**产出了碎片化的干预手段（接种、纠正、横向阅读、准确性提示），效应量多为小到中等且彼此孤立（van der Linden, 2022; Pennycook & Rand, 2022），缺乏系统级整合，更缺乏”事前架构性防护”的形式理论。
- **人机协同研究**讨论了自动化分级与信任校准，但缺少”主权”维度——没有回答过滤器的目标函数归谁所有、由谁写入；也缺少把人类德性状态纳入控制回路的收敛理论。

1.5 核心命题与贡献

本文的核心命题一句话：把信息获取从”平台为目标函数优化用户注意力”重构为”智能体为自己的第二序目标函数，在统一预算下联合优化主动获取与被动过滤”，并为此重构提供可证明的效率性、安全性、自主性与对抗性保证。

具体贡献（C1–C9，定理编号见各章）：

- **C1（假设与设计原则）**：六条前提（经验假设 / 规范假设 / 设计立场三分类）与不变量 I1–I5 的显式推导；主权获取问题 SAP 的统一优化表述（第 3–5 节）；
- **C2（VOI 结构分解）**：评分特征向量的决策论地基——Blackwell 框架下的逐决策结构分解，决策同质性条件 (V4) 下的精确摘要，与高斯闭式（定理 5.1、推论 5.1）；
- **C3（过滤效率理论）**：失真下界、评分分离度瓶颈定理、次模性与 $(1-1/e)$ 贪心保证、阈值型最优策略（第 6 节）——其中瓶颈定理证明”命题坍缩 + 信源冗余 + 直通”的双通道架构不是工程装饰而是高召回的数学必然；
- **C4（冗余覆盖定理严格版）**：完整证明、相关情形的独立子集界与紧性、监测名额分配的次模对偶（第 7 节）；
- **C5（主动获取理论）**：注意力无套利定理、Pandora 监测准入判据、边际价值停留规则、查询批次的次模性（第 8 节）；
- **C6（目标俘获统一模型）**：人类与 AI 防护的完全对称、期望与高概率防火墙界、生产者博弈临界采纳率 σ^* 与复制子灭绝（第 9 节）；
- **C7（升华控制论）**：人类门控两时间尺度控制的几乎必然收敛定理、稳态邻域界、反 Goodhart 条款、C 类判断负荷必要性（第 10 节）；

- **C8（紧急覆盖与公共议程）**：预先授权的形式化与遗憾界、委托严格占优条件、公共知识生成与碎片化下界定理（第 11–12 节）；
- **C9（验证纲领）**：12 条可证伪命题、升级仿真设计（含 pull 侧与消融）、**以 AI 智能体队列为主的三层验证架构**（智能体假设 H1'–H7'、在线人类数据锚点 H8–H9、暂缓启动的人类 RCT；第 13–15 节）。

1.6 论文定位与阅读指南

本文为理论论文：全部定理附完整证明或归约到附录 B 的标准引理与经典定理（明确标注出处）；全部假设显式编号（前提 1–6；冗余假设 R1–R3；防火墙假设 F1–F3；收敛假设 C1–C5；特征分解假设 V1–V5），并逐一给出经验含义与可检验性讨论。理想化假设不被隐藏：**每处理想化都伴随"现实偏离方向 + 工程缓解 + 仿真检验"三件套**（集中汇总于第 17 节）。**对"完整证明"承诺的一处明示例外**：收敛主张的正漂移底（$b_0 > 0$）分支**根本不以定理形式陈述**——它以**猜想 10.1（条件性）**出现，由 ODE 方法梗概支持（Borkar, 1997, 2008），其对 Kushner–Clark 条件的核验为梗概级别；§10.3 给出明确的清单，逐项列出哪些 Kushner–Clark 条件已核验、哪些尚未。零漂移底分支（$b_0 = 0$）为定理 10.1，附完整初等证明。

关于结果标注的诚实约定：本文区分三档断言——**定理/命题（证明）**给出完整数学推导；**命题（论证）**给出的是概念性论证或量级估计而非逐行推导（如命题 3.1 的不变量推导、命题 10.2(iii)、§9.4 军备竞赛段），文中逐一显式标注；**猜想（条件性）**给出精确的数学断言以及尚待核验的条件清单（本文仅有猜想 10.1 一处）。若读者只接受第一档，第二、三档可整体视为设计动机而不影响定理链条。**条件性设计引理**（v1.7 新增；本文仅有引理 12.1 一处）陈述在显式声明的设计条件下成立的界（引理 12.1：标定的单类攻破上界与跨类独立性，或其有效类数松弛 k^a_{eff}）；它们是该条件下的设计指引——而非无条件安全保证——按第二档阅读。

第三部分（第 6–12 节）是理论核心，各章相对独立：只关心"激进过滤为何安全"的读者可径读第 6–7 节；只关心"主动获取如何最优"的读者可径读第 8 节；关心对抗安全的读者读第 9 节。第 13 节把全部定理压缩为一张可证伪命题表，是实验者的最短入口。第 14–15 节为实证部分（仿真与 AI 智能体实验），可独立于理论部分阅读；其详细实验记录与代码见补充材料（《数据与代码可用性》）。**关于符号负担的说明**：附录 A 以核心速查表开篇——跟随主定理链所需的最小符号集；本文其余一切编号族（P/H/O/L/E/S/C/R/F/V/I/W/KC）都是在各自定义处局部使用的检索装置，初读无需记忆任何一个。**载体形式**：本文按专著撰写并投稿；若收件载体要求常规期刊篇幅，将执行的拆分预案载于 §18.1。

图 1 SEA 框架总览（前提 → 机制 → 定理 → 验证的依赖结构）：

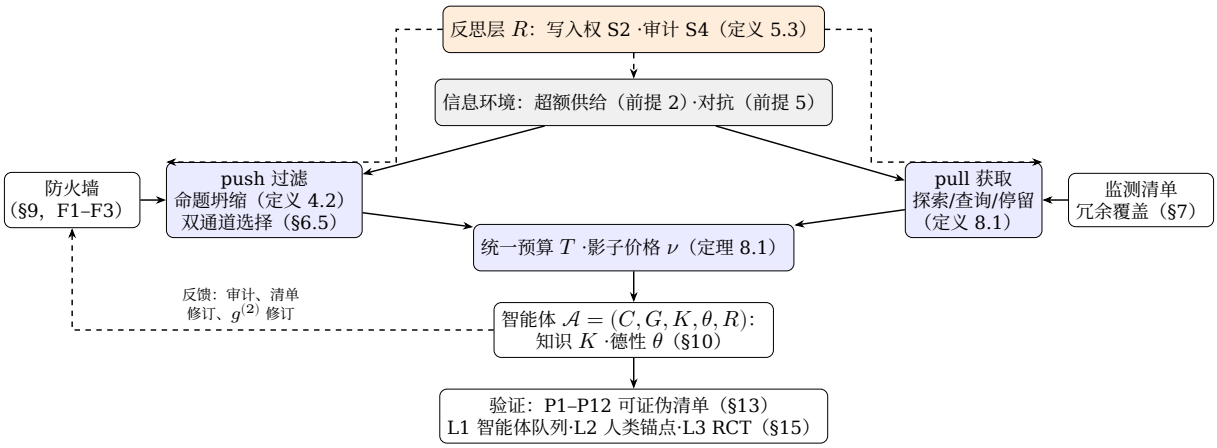


图 1: SEA 总体框架：信息环境的内容经 push 过滤与 pull 获取两族算子进入统一预算分配（影子价格 ν），反思层 R 以 S1–S4 约束全部写入与审计；验证层把全部定理映射为可证伪命题。

2 相关工作：七大学科板块的共识与争议

本节按问题的七个层次梳理理论地基，每层标注**共识**（可作为工程前提）与**争议**（必须作为设计变量处理）。

2.1 稀缺性与价值的形式化

- **注意力经济学**（Simon, 1971）：信息的富有造成注意力的贫困。共识：瓶颈在注意力侧。
- **有限理性与满意化**（Simon, 1955）：主体在计算约束下寻求”足够好”而非最优。本框架的贪心近似保证（定理 6.3）是满意化的规范性版本。
- **理性疏忽**（Sims, 2003; Maćkowiak, Matějka & Wiederholt, 2023）：主体在信道容量约束下最优分配注意力，离散选择情形导出 softmax 形式的选择概率（Matějka & McKay, 2015），考虑集内生化的进一步分析见 Caplin, Dean & Leahy (2019)。互补的有界注意力路线把理性建模为**稀疏性**：主体只关注状态的一个低维线性投影、最优地忽略其余（Gabaix, 2014）。优点：形式化成熟；缺陷：假设目标函数已知且稳定——而目标恰恰被环境重塑，且该文献不处理对抗性内容。本文第 8.6 节将其作为 SAP 的特例对接；对照稀疏理性，SEA 的五维特征映射 ϕ 可读作一个声明且可审计的稀疏模式（S1），与”经优化但隐式”的注意力投影相对。该纲领在宏观经济学中以信息成本内生的注意力形成及其一般均衡后果继续推进（Angeletos & Sastry, 2025）。
- **信息价值理论**（Howard, 1966; Blackwell, 1953; Lindley, 1956）：信息价值等于决策改进的期望；实验的 informativeness 序（$\succeq_B$，附录 B.5(ii)）由 Blackwell 定理刻画。支撑本文定理 5.1 的分解；缺陷是无法直接为”泛泛的知情”定价——本文以德性动力学（第 10 节）补足长期项。
- **信息觅食理论**（Pirolli & Card, 1999）：主体追逐信息气味，停留与离开服从边际价值定理。解释算法流的成瘾性；描述性而非规范性——本文第 8.3 节将其提升为规范性调度规则。
- **数字成瘾与自我控制的实证经济学**（Allcott et al., 2020; Allcott, Gentzkow & Song, 2022）：社交媒体戒断实验给出”一阶偏好与自报福祉系统性分离”的因果证据——用户事后评价自己的消费为过度。这是本文前提 3（$g^{(1)}$ 与 $g^{(2)}$ 分离）最强的实证锚点之一，也直接支持”目标函数归谁所有”的问题提法。

2.2 认知处理的硬约束

工作记忆极限（Miller, 1956; Cowan, 2001，约 4 个并行单元）；注意的选择性与容量（Broadbent, 1958）；认知负荷理论（Sweller, 1988）；双系统理论（Kahneman, 2011）；错觉真实效应——重复曝光本身提升感知真实性（Fazio et al., 2015）；遗忘曲线（Ebbinghaus, 1885）。这些结果共同约束交付层的形态：分层摘要、去重、少而深；并支撑前提 1（有限性）的量化。

2.3 茧房与极化机制

共识：回音室（用户自组织的同质化网络）证据稳健——选择性接触与同质化是人性默认值（Festinger, 1957; McPherson, Smith-Lovin & Cook, 2001; Stroud, 2011）；**过滤泡**（算法单独造成的封闭，Pariser, 2011）证据有限且受质疑——偶然接触仍然普遍，算法单独对极化的作用温和（Gentzkow & Shapiro, 2011; Guess et al., 2023）。**争议震中**：Bail et al. (2018) 发现随机暴露于对立观点反而加剧极化——未经策展的”破茧”会反噬。Nguyen (2020) 的概念区分对本框架至关重要：认知气泡（暴露缺失）$\neq$ 回音室（对外信任被系统性瓦解）；后者才是真问题，故对策重心应从”多听异见”转向”信任锚点的选择与审计”。本文将其落实为容差半径约束下的课程化曝光（定义 10.2）而非随机注入。过滤泡/回音室文献最新的系统综述巩固了这一图景，并强调算法策展效应随人群与平台而异（Ahmmad et al., 2025）。

2.4 操控与免疫（错误信息科学）

共识：(a) 纠正平均有效但不完全，存在持续影响效应（Lewandowsky et al., 2012; Chan et al., 2017; Ecker et al., 2022），对身份敏感的科学议题纠正可能无效（Chan & Albarracín, 2023）——**架构含义：事前过滤为主，事后纠正为辅**；(b) 横向阅读是实证支持最强的个人技能（Wineburg & McGrew, 2019）——本文将其形式化为 pull 侧的查询策略（第 8.5 节）；(c) 情绪化、道德化内容传播更快更远，且由人驱动（Vosoughi, Roy & Aral, 2018）；(d) 身份保护性认知使高认知能力者在身份议题上更极化（Kahan, 2017）——“聪明”不是免疫，防护必须外置；(e) 真相默认理论：人默认相信，怀疑需要认知努力（Levine, 2014）——这是目标俘获攻击面存在的心理学根据。

争议：接种/预辟谣效应量小到中等且随时间衰减，存在发表偏倚争论（McGuire, 1964; Roozenbeek & van der Linden, 2019; van der Linden, 2022）；准确性提示的持久性存疑（Pennycook & Rand, 2019, 2022）；错误信息的实际危害量级存在测量之争（Guess, Nagler & Tucker, 2019; Grinberg et al., 2019; Allen et al., 2020; Lazer et al., 2018）。本文的架构立场不依赖任何单一干预的效应量：**防火墙界（定理 9.1–9.2）把”检测器实测召回率 × 单条有界影响 × 暴露上限”作为设计参数**，效应量争议转化为参数标定问题。2025 年的两项研究使其更尖锐：信号检测论框架的元分析以 d' 为单位量化了接种的判别力增益（Simchon et al., 2025），真实社交信息流内的预注册现场试验报告接种在信息流层面的效力有限（Wang et al., 2025）——二者与本文立场一致：干预效应量小，负担必须由架构性防护承担。

2.5 人机协同的认知工程

扩展心智（Clark & Chalmers, 1998）为人机协同提供哲学正当性；认知卸载研究提示去技能化风险（Sparrow, Liu & Wegner, 2011）——本文命题 10.2 证明该风险在本框架内的准确位置：卸载判断形成过程将使校准测量通道退化；自动化偏见（Parasuraman & Riley, 1997）与算法厌恶/欣赏（Dietvorst, Simmons & Massey, 2015; Logg, Minson & Moore, 2019）约束信任校准设计；Goodhart 定律（Goodhart, 1984）与价值捕获（Nguyen, 2019）警告指标治理的必要性——本文以梯度隔离条款（命题 10.1）作构造性防护；道德褶皱区（Elish, 2019）警告人类决定不可沦为仪式——本文以 B 类真实性三条件（第 11.1 节）落实。随着自主 LLM 智能体的兴起（Xi et al., 2025），协同二元体正在变为协同团队；此类智能体对注入与操纵的安全问题本身已成为有综述的领域（Tang et al., 2025）——我们的定义 9.1 正是把该载体级目录抽象为单一攻击类。

2.6 政治经济与治理

注意力商人史（Wu, 2016）、监控资本主义批判（Zuboff, 2019）、注意力权主张（Williams, 2018）正确指出问题的激励结构本质，但批判强于建设；公共领域的结构性转型（Habermas, 1962/1989）与共和主义关切（Sunstein, 2017）提示普遍个性化的公共性代价。算法层面对这一代价的刻画已有重要实证与理论工作：信息流算法对暴露多样性的因果效应实测（Bakshy, Messing & Adamic, 2015）、曝光多样性的规范性设计框架（Helberger, Karppinen & D’Acunto, 2018）、“破泡”干预的规范分析（Bozdag & van den Hoven, 2015）、以及**算法单一文化**（algorithmic monoculture，Kleinberg & Raghavan, 2021）——当多数决策者依赖同一算法时，个体理性汇聚成系统性同质化。本文第 12 节的碎片化下界定理与算法单一文化文献是同一问题的两面：前者给出”共享现实最小面积”的构造性保证，后者诊断无共享结构时的失败模式。传播学中的认知福祉纲领（Hyzen et al., 2025; Van den Bulck et al., 2025）给出治理侧的对应物：以推荐系统对公共领域认知福祉的贡献评估之，并以公共服务媒体为治理锚——这正是本文公共议程层（第 12 节）的制度类比。证词认识论（Coady, 1992; Zagzebski, 2012）给出哲学地基：知识绝大部分来自他人证词，信任中介不可消除，只能选择与审计——这是前提 4 的来源。

2.7 主动信息获取的理论谱系

pull 侧的经典工具分散于六个传统，本文第 8 节将其接入同一框架：

- **搜索经济学**（Stigler, 1961）：搜索有成本，最优搜索深度由边际收益 = 边际成本决定。
- **带检查成本的搜索 / Pandora 盒子**（Weitzman, 1979）：每个”盒子”（候选信源）打开有成本、收益随机；最优策略按保留指数 z_i（解 $E[(X_i - z_i)^+] = c_i$）降序打开，并在已开最大值超过剩余指数时停止。这是信源探索与监测准入的精确模型（命题 8.1）。Pandora 模型的现代扩展——是否开盒本身可选（Doval, 2018）、更一般的停止规则（Olszewski & Weber, 2015）——与本文第 8 节处理的问题共享同一结构。
- **最优动态信息获取**：Zhong (2022) 给出一般序贯信息获取问题的最优性刻画（动态版本的信息价值指标化），与本文第 8 节的主题几乎完全重合；本文与其区别在于预算的多用途联合定价（push/pull/反思共享影子价格）与主权约束，而非获取技术本身。
- **最优觅食理论**（Charnov, 1976）：补丁停留时间由边际价值定理决定——当瞬时摄入率跌至环境平均水平（= 影子价格）时离开。信息补丁的停留与轮换由此获得规范形式（命题 8.2）；多信源的持续调度是不安定 bandit 问题（Gittins, 1979; Whittle, 1988; Weber & Weiss, 1990）。
- **贝叶斯实验设计与主动学习**（DeGroot, 1962; Lindley, 1956; Chaloner & Verdinelli, 1995; Settles, 2009）：DeGroot (1962) 的序贯实验表述——每次选择实验以最大化后验效用的期望增益——是本文 pull 侧查询规划器的直接源头；查询的价值 = 期望信息增益（EIG）；在观测条件独立下 EIG 关于查询集合单调且次模（Krause, Singh & Guestrin, 2008），贪心选择获得 $(1 - 1/e)$ 保证（定理 8.2）。在 SEA 中，DeGroot 判据在注意力预算之下、针对已声明的 $g^{(2)}$ 运行，Pandora 指数（Weitzman, 1979）是其”冻结盒”特例（§8.6）。
- **最优停止**（Ferguson, 2006）：何时停止检索转为消费，是预算约束下的停止问题；本文以注意力无套利定理（定理 8.1）给出其静态刻画。

共识：以上工具各自成熟且相互兼容（都以”边际价值 = 影子价格”为核）。**缺口**：没有一个传统同时处理 (a) 对抗性内容，(b) 第二序目标，(c) 与 push 过滤的联合预算分配，(d) 长期德性动力学。SAP（定义 5.1）填补的正是这个四重缺口。

2.8 跨学科收敛点

七大学科在五点收敛，构成本框架的前提基础与设计原则：

1. **事前过滤为主**（纠正效应有限且迟滞）；
2. **信任需经选择与审计**（证词中介不可消除）；
3. **异质暴露需策展而非随机**（反噬证据）；
4. **人类必须保留真实的判断负荷**（去技能化与道德褶皱区证据）；
5. **获取与过滤是同一预算分配问题的两面，边际价值必须均衡**（搜索、觅食、理性疏忽传统的共同内核——本文定理 8.1 使其成为框架的组织原则）。

与最接近工作的区别（新贡献的明确划界）。(a) **Zhong (2022)** 给出一般序贯信息获取的最优性刻画，是本文 pull 侧的理论上游；本文的不同点：push 过滤通道、对抗分支（误设更新下的负价值）与主权约束不在其框架内，本文的 SAP 把这些纳入同一预算。**形式的特例关系（v1.6 新增）**：对 SAP 施加限制 (i) 仅 pull 通道（$T_{\text{push}} = T_{\text{ref}} = 0$）、(ii) 无对抗分支（$c_i \equiv 1$，$W$ 退化为 VOI，(V5) 变为空洞）、(iii) 主权约束不激活（$\Pi_S = \Pi$）、(iv) $g^{(2)}$ 在视界内固定（无反思层动力学），则 SAP 目标函数退化为”每期获取预算下序贯选择信息结构的期望效用增益”——这正是 Zhong (2022) 的问题类，其动态信息价值指数化刻画给出该受限问题的最优解。包含关系因此是精确的：Zhong (2022) = SAP$|_{(i)-(iv)}$ 的特例；SEA 特有内容恰在补集中——push 通道的逐期选择问题（第 6–7 节）、误设更新下的负价值分支（第

9 节)、对目标函数本身的写入权约束（S1–S4)。本文**不**主张任何反向归约（Zhong 框架无法表达 (i)–(iv) 的补集，因其价值对象按构造非负)。(b) **Weitzman (1979) / Charnov (1976)** 给出探索准入与补丁离开的经典规则；本文不重新证明它们，而是证明它们是注意力无套利条件的共同特例，并补上 push 侧的消费阈值（命题 6.4）与信源调度（§8.6）作为同一影子价格的其余实例。(c) **KKT / 次模贪心 / Hoeffding / Robbins–Siegmund** 是标准工具；本文的相关定理（8.1、6.3、9.1–9.2、10.1）是这些工具在所设结构下的正确应用，**新的是结构与问题的 formulation**（主权条件、双通道分工、人类门控)，不是工具本身。(d) **对抗机器学习**（Dalvi et al., 2004; Lowd & Meek, 2005; Biggio & Roli, 2018）处理分类器级对抗；本文的目标俘获模型（定义 9.1）把攻击目标从分类决策提升到目标函数本身，写入隔离（S2）是该文献没有的结构（详见 §9.1)。(e) **有界置信意见动力学**（Hegselmann & Krause, 2002; Deffuant et al., 2000）给容差半径课程（定义 10.2）提供了现成的动力学参照系：本文把描述性半径升级为随能力增长的内生课程。(f) **价值学习**（Hadfield-Menell et al., 2016, 2017）处理目标未知下的对齐；本文的 $g^{(2)}$ 声明 + 人类门控是对同一问题的制度性折中（§5.3 引导注)。(g) **LLM 谄媚**（Sharma et al., 2023）是目标俘获在 AI 侧最被实测的载体，与定义 9.1 直接同构。(h) **LLM 智能体安全与提示注入的 2025 综述**（Geng et al., 2025; Tang et al., 2025）为 LLM 集成应用编目了载体级攻击与防御（含经检索内容的间接注入)；本文定义 9.1 的不同点在于攻击目标是目标函数的写入路径而非单次调用的完整性，并把写入权隔离（S2）作为一等结构性防御而非输入净化技术——综述记录攻击面，本文给出关闭它的所有权结构。

2.9 对 2025–2026 相邻文献的实质性定位

§2.8 的划界说明本文与何处不同；本节逐文献陈述**相邻的 2025–2026 研究纲领实际假设了什么、本文从它们继承什么、以及它们能而本文不能回答什么**——对照是实质性的而非标签式的。

(a) LLM/RAG 信息代理与间接提示注入（Xi et al., 2025; Tang et al., 2025; Geng et al., 2025; Liu et al., 2024; Greshake et al., 2023)。这些工作把智能体的失效模式处理为调用完整性：注入指令劫持某一次工具调用或某一段检索上下文，防御是输入净化、沙箱、权限域与检测分类器。本文继承它们的攻击目录（定义 9.1 将其抽象为单一载体中立类）与”检索即攻击面”的证据。差别是结构性的而非分类学的：调用完整性防御不触及目标函数的写入路径——一个权重、权重的权重或交付目标被其运营者或参与反馈静默重调的智能体，可以在没有任何单次调用畸形的情况下被俘获。S2（写权隔离）正是注入文献所没有的防御，因为它不建模目标的所有权；反过来，本文从它们继承一个诚实的局限：S2 是所有权结构而非净化器——它拦不住说服反思层本身的载荷（命题 10.1 的慢尺度通道)，而它们的检测率恰是我们防火墙界的 ρ_m 输入。

(b) 推荐福利、曝光多样性与推荐系统中的价值（Allcott et al., 2020, 2022; Kleinberg & Raghavan, 2021; Kleinberg, Mullainathan & Raghavan, 2024; Helberger et al., 2018; Stray et al., 2022; Bozdag & van den Hoven, 2015)。该文献优化或规制平台侧目标：以显示偏好度量的福利、作为设计原则的曝光多样性、或经跨学科流程植入的价值。它假设目标的所有者是平台（或其规制者)，问的是如何把该目标做得更好或更公平。SEA 继承它们的福利度量（§14.3 的 S5 基线以 Allcott et al. 的显示偏好福利为对照）与”参与优化不等于福利优化”的证明。不可化约的差别是**所有权**：Kleinberg, Mullainathan & Raghavan (2024) 证明偏好不一致使”用户想要什么”对平台优化者不适定；SEA 的回应不是更好地推断用户效用，而是把写权移交给用户的反思层（S2)，把不适定性转化为已声明、可修订的 $g^{(2)}$（§5.3 的季度修订机制)。作为系统强加原则的曝光多样性（Helberger et al.）与作为主体声明约束的容差半径课程（定义 10.2）在多数配置下操作一致，而在主体声明的半径窄于多样性规范处恰好分道——本文在此站在主体一边，并接受家长主义质疑作为残余成本（§16.3、§17 局限 5)。本文不能而它们能回答的：普遍个性化下的聚合福利与市场效应——那是它们的对象、我们的外部性（第 12 节只界定了它的一个碎片)。

(c) 信息检索召回保证与主动学习/bandit 工程（Settles, 2009; Krause et al., 2008; IR 评估文献)。工程实践靠改进评分器改善召回（更好的特征、排序器、检索模型)；主动学习

与 bandit 形式化在预算下优化下一步获取哪些标签或臂。SEA 从该线继承次模贪心与 EIG 机器（定理 6.3、8.2），并按该文献使用分类器质量的方式使用实测 d'。实质性增量在不可能性方向：定理 6.1 给任何评分器在 99.8% 过滤比下能买到的召回定价（$d' \approx 4.4$ 以下买不到，而实测范围是 0.54–3.49），把”改进评分器”从开放式纲领变为有已知天花板的纲领，并使第二通道（结构：直通、清单、冗余）成为数学必然而非工程偏好。本文不能而它们能回答的：评分器内部改进、查询规划器启发式、以及任何依赖学习表征的保证——我们的定理按设计是表征无关的，这也正是它不能为具体检索栈背书的原因。

(d) 公共广播与平台治理的机制设计（Van den Bulck et al., 2025; Hyzen et al., 2025; Helberger et al., 2018；公共服务媒体文献）。这些工作把认知外部性的 remedy 定位于制度：认知福利作为公共服务媒体的规制目标、推荐器义务、透明度义务。SEA 继承它们的诊断（普遍个性化把共享现实成本外部化）与”认知福利必须操作化而非口号化”的坚持。差别在机制设计的位点：它们为供给者设计义务，SEA 设计个人主权层加最小公共地板（第 12 节），且只对该地板证明碎片化下界。两者是互补而非竞争：公共层的 γ 与认证类恰是规制者可以作为个人主权之下地板强制的参数，而我们的认证反转负结果（lift 0.63×、部分恢复 1.23×）是面向它们设计空间的警告——原始计数认证可被注意力通胀博弈（O7）。本文不能而它们能回答的：任何强制令的政治经济可行性，以及地板成本由谁承担的分配问题。

净定位。四个文献中，2025–2026 的前沿靠更好的模型、更好的度量或更好的制度推进；**本文不声称在模型、度量或制度设计上超越其中任何一个**。其唯一主张是：它们都视为给定的一个变量——**获取目标的所有权**——本身是一个具有形式结构（S1–S4）的设计变量，且固定它会改变哪些保证可达（定理 6.1 的双通道必然性、注入文献缺失的写隔离防御、以声明半径替代强加多样性）。新颖性主张因此恰如 §2.8(c) 所述：新的结构与问题表述，标准的工具。

第二部分 前提与形式框架

3 工作假设与设计原则

3.1 六条前提：经验假设、规范假设与设计立场

本框架的地基是六条前提。**为避免”前提”一词的误导，显式说明**：它们不是数学前提（不能作为免检前提参与推导），而是三类不同认识论地位的主张——**经验假设**（可测量、可证伪：前提 1、2、4）、**规范假设**（哲学立场与价值规定：前提 3）、**设计立场**（工程与治理承诺：前提 5、6）。每条标注类别与**可检验性**，并显式承担相应的经验风险或论证责任。后文定理只依赖其中的经验假设部分；规范假设与设计立场决定的是问题的表述形式与制度设计，不进入任何证明的逻辑前提链（进入处均另以显式编号的条件假设 R/F/C/P 等声明）。

前提 1（有限性，Boundedness）。【经验假设】任何智能体的信息处理能力有限：存在每周期认知预算 $T < \infty$（时间与注意）与工作记忆约束 W（人类 $W \approx 4$ 个并行单元，Cowan, 2001；AI 智能体为上下文窗口与推理预算）。量化基础：第 2.2 节。

前提 2（超额供给，Excess Supply）。【经验假设（含量级外推）】信息环境的候选供给速率 λ（条/日）与单条消费成本 $\bar{t}$ 满足 $\lambda\bar{t} \gg T$，且在生成式 AI 制度下 λ 的增长不受制作成本约束。当前量级：$\lambda\bar{t}/T \approx 10^3$（按 §1.1 的典型参数 $T = 45$、$\bar{t} \approx 4$、$N \sim 10^4$ 复算为 8.9×10^2）。可检验性：供给量与成本可直接测量；“生成成本趋零”是产业事实。**推论**：过滤比 $1 - T/(\lambda\bar{t}) \geq 99.8\%$ 是算术必然（命题 6.1）。

前提 3（目标分层，Goal Stratification）。【规范假设（哲学地基：Frankfurt, 1971）】智能体的目标结构 $G = (g^{(1)}, g^{(2)})$ 分层：$g^{(1)}$ 为一阶偏好（点击时刻的冲动、高唤起内容的即时吸引），$g^{(2)}$ 为第二序意志（反思层 R 认可的、关于”希望自己被什么塑造”的目标）。两者可系统性分离；**规范上 $g^{(2)}$ 对信息环境塑造拥有权威**。经验支撑：自控的规划者—执行者结构（Thaler & Shefrin, 1981）、跨期不一致（Ainslie, 1992）、偏好内生塑造（Elster, 1983）。

前提 4（证词依赖，Testimonial Dependence）。【经验假设（认识论地基：Coady, 1992; Zagzebski, 2012）】智能体关于世界的信念绝大部分经由他人证词获得；信任中介不可消除，只能被**选择**（信源组合）与**审计**（溯源与校准）。推论：溯源结构（定义 4.2）不是可选的元数据，而是信念形成的承重墙。

前提 5（对抗性，Adversariality）。【设计立场（最坏情况假设）】信息环境中存在其行为者，其收益依赖于改写智能体处理回路中的目标或信念，且其策略会对防护作出适应（军备竞赛）。形式化见定义 9.1（目标俘获攻击）。人类实例：情绪劫持、宣传的"谎言消防水管"（Paul & Matthews, 2016）；AI 实例：提示注入，尤其是经由检索内容实施的间接提示注入（Greshake et al., 2023; Liu et al., 2024）。**不设此前提的过滤理论在开放环境中不成立**。

前提 6（可测性与可修正，Measurability & Correctability）。【设计立场】过滤器性能（召回、精度、操控暴露）与智能体认知状态 θ 可被含噪测量；修正通道（参数回滚、信源撤换、目标修订）常开。这是 Goodhart 定律的治理学逆命题：不可测量的过滤器不可治理。

3.2 不变量及其推导

命题 3.1（不变量 I1–I5；论证性推导）。在前提 1–6 下，任何主权的认知获取系统必须满足下列不变量。（本命题属"命题（论证）"档：I1 有严格推导，I2–I5 是从前提到设计要求的概念性推导，其功能是把前提的操作含义显式化，而非数学定理。）

- **I1（容量约束）**：$C \ll |X|$，过滤与优先级排序不可避免；唯一的问题是获取—过滤机制的所有权与目标函数。
- **I2（主权）**：目标函数 $g^{(2)}$ 与过滤器参数 w 的写入权属于主体的反思层 R（或其合法委托人）。
- **I3（溯源）**：每条被接受的命题携带可验证溯源。人类实例：一手信源（论文、财报、判决书、原始数据）；机器实例：密码学签名来源与内容凭证（C2PA, 2021）。
- **I4（对抗鲁棒）**：存在界 ε，使处理任意对抗性内容序列后的有效目标发散 $D(\tilde{U}, G) \leq \varepsilon$（第 9 节给出 D 的精确度量与界的构造）。
- **I5（校准）**：过滤器性能可测量、可审计、修正通道开放。

证明。

I1：由前提 1，消费预算 T 有限；由前提 2，$\lambda\bar{t} > T$。故任何策略至多消费 $m \leq T/\bar{t} < \lambda$ 条/日，被弃比例 $\geq 1 - T/(\lambda\bar{t}) > 0$ 且趋近 1。过滤（广义：对候选池的选择性准入）在一切策略下发生，故问题只剩"由谁、按什么目标"。■

I2：由前提 3，$g^{(1)}$ 与 $g^{(2)}$ 可分离，且规范权威在 $g^{(2)}$。过滤器的目标函数决定了哪些内容进入智能体的信念形成回路，从而**塑造未来的 $g^{(1)}$ 与 $g^{(2)}$ 本身**（偏好内生性，Elster, 1983）。若写入权不属于 R，则该机制构成第三方对主体目标结构的强制执行——按自主性的程序性定义（Frankfurt 层级条件 + 程序性独立条件），这不是主体的自主获取而是他主塑造。故主权要求写入权 $\in R$。■

注（适应性偏好与程序性判据的限度——v1.6 新增）：I2 的论证依赖 Frankfurt 层级条件的程序性读法：反思层 R 的背书赋予 $g^{(2)}$ 权威。经典反驳（Elster, 1983——酸葡萄）是：$g^{(2)}$ 本身可能被贫瘠的信息环境塑造，于是"反思性背书"可能追认的是适应性偏好而非自主偏好。本文不声称消解该反驳——任何工具都不能（§16.6 已作让步）。框架增加的是结构性的东西：(i) 背书赖以形成的输入集**默认**保持非退化（容差半径课程与公共层均默认开启，退出须留痕，S4）；(ii) 塑造通道被做成**可审计**（写入隔离 S2 + 防篡改日志 S4），故适应而来的 $g^{(2)}$ 至少可追溯其形成史；(iii) 每个治理周期都保留修订可能（§16.4）。因此本文主张的主权精确地是"程序性自主**加上可审计的、默认非退化的形成条件**"——不是"$g^{(2)}$ 本真地属于主体"的实质性保证，后者是任何工程框架范围之外的哲学难题。

I3：由前提 4，信念经由证词中介；中介的可靠性不可先验假定（前提 5：存在伪造中介的对抗者）。可验证溯源是把"信任"从不可审计的心理状态转化为可审计的结构属性的唯一途径：

无溯源则审计无对象，I5 失效；溯源可伪造而无密码学/制度锚定，则前提 5 下的对抗者可注入伪证。故 I3 是 I5 与前提 4–5 的合取推论。■

I4：前提 5 断言对抗者存在且适应。若目标发散无上界，则系统的有效目标函数可被内容改写，I2 名存实亡（写入权被绕过内容通道窃取）。故 I4 是 I2 在对抗环境下的保全条件；ε 的构造见定理 9.1–9.2。■

I5：前提 6 直接给出。注意逻辑层级：前提 6 本身是设计立场而非经验事实，故 I5 是**设计要求**（“系统应当如此建造”），不是经验不变量；其经验部分（“测量是否可行”）由第 10.1 节的测量模型与第 14–15 节的实测承担。补充论证：若性能不可测，则 (a) 修正通道无从触发，(b) Goodhart 漂移不可发现，(c) I2 的审计权（S4）空转。■

3.3 人类—AI 对称表

不变量与后续全部机制在两类智能体上的实例化保持对称，这是”方法论适用于一切有限智能体”主张的操作含义：

结构	人类实例	AI 智能体实例
容量约束（前提 1）	工作记忆、时间预算	上下文窗口、推理预算
目标分层（前提 3）	冲动 vs 反思认可的目标	即时指令响应 vs 委托人的授权配置
对抗俘获（前提 5）	情绪劫持（System 1 被唤起劫持权重）	提示注入（指令被内容改写）
溯源（I3）	一手信源核查	签名来源、内容凭证
反思层 R	本人	委托人的合法授权配置
德性状态 θ	校准度、开放度、谦逊	校准度、稳健性（无谦逊维度，以过自信惩罚项替代）
pull 算子	主动检索、订阅试错	工具调用、子查询、检索增强
push 算子	信息流筛选	输入队列准入控制

4 信息环境与智能体模型

本节固定全部数学对象。测度论设定从简但严格：所有随机元素定义在共同的带滤链概率空间 $(\Omega, \mathcal{F}, \{\mathcal{F}_t\}_{t\geq 0}, P)$ 上；“a.s.”均指 P-几乎必然。

4.1 信息条目与到达过程

定义 4.1（信息条目）。信息流 $X = \{x_1, x_2, \dots\}$ 为到达时间 $\{t_i^{arr}\}$ 上的标记点过程（对 push 流取复合 Poisson 到达，速率 λ；建模扩展见第 14 节仿真）。每条

$$x_i = (\text{content}_i,\ \text{prov}_i,\ \tau_i),$$

其中 prov_i 为溯源信息（信源身份、签名/凭证、转述链），$\tau_i > 0$ 为消费时间成本。条目携带潜在属性（对过滤者不可观测或仅含噪可观测）：

- $v_i^* \in \mathbb{R}_{\geq 0}$：**真实价值**——对该条目所属命题与主体决策集关联强度的地面真值（精确定义经定理 5.1 的 VOI 分解给出）；
- $m_i \in [0,1]$：**操控强度**——内容中被植入的目标俘获载荷的强度（定义 9.1）；
- $s_i \in \mathcal{S}$：**立场向量**——议题相关立场流形 $\mathcal{S}$ 上的位置。

可观测特征映射 $\phi(x_i;\, K, D) \in [0,1]^5$，$\phi = (\text{相关度}, \text{新颖度}, \text{耐久度}, \text{行动性}, \text{可信度})_i$。**类型签名说明**：$\phi$ 是**条目 × 主体状态**的函数而非仅条目的函数——相关度依赖主体声明的决策集 D，新颖度依赖知识状态 K（在 K 已含的信息上无增益）。这一点是实质性的：任何把 ϕ 当作 $X \to [0,1]^5$ 的纯条目函数的表述都与定理 5.1 的分解不一致。定理 5.1 给出 v_i^* 的逐决

策结构分解，并证明：在追加的决策同质性假设 (V4) 下 $\phi(\cdot; K, D)$ 是 v_i^* 的精确摘要（存在 F 使 $v_i^* = F(\phi)$）；在 (V4) 之外 ϕ 只是工程启发式摘要（§5.2 给出显式反例）。

定义 4.2（命题图与溯源树）。底层事件/命题集合 $E = \{e_j\}$。生成结构：命题 e_j 派生文档集合 $D_j \subseteq X$；归并映射 $\kappa : X \to E$ 将文档映到其所属命题。每个命题挂一棵**溯源树** T_j：根节点为一手信源，验证状态 $r(T_j) \in \{\text{verified}, \text{unverified}\}$；枝节点为转述与评论。**评论不是独立信息，而是命题的注解层**——其价值计入命题价值的一个有界修正项，不重复占用消费预算的完整份额。

定义 4.3（命题坍缩比）。$\rho_c := |X|/|E|$。命题中心架构使转载自动坍缩：n 家媒体转载 = 1 条命题 + n 条溯源树边。先验预测 $\rho_c \in [5, 20]$（仿真与实测检验，第 13 节 P3）。**推论 6.1 证明**：坍缩把文档级过滤比难题转化为命题级选择问题，是极端过滤比可行性的必要条件之一。

定义 4.4（信源类）。信源全集按（所有权 × 地域 × 类型）三元组划分为**信源类** $\mathcal{C}_1, \ldots, \mathcal{C}_K$。划分的目的是逼近覆盖事件的条件独立性（假设 R2）：同一所有权或同一通讯社上游的媒体归入同类，类间相关性由此被构造性地压低。类 i 对命题 e 的**覆盖事件** $Z_i(e) := \mathbb{1}\{\exists x \in D_e : x \text{ 的信源} \in \mathcal{C}_i\}$。

4.2 智能体

定义 4.5（智能体五元组）。

$$\mathcal{A} = (C,\ G,\ K,\ \theta,\ R)$$

- $C = (T, W)$：认知容量——周期预算 T（分钟）与工作记忆约束 W；
- $G = (g^{(1)}, g^{(2)})$：目标结构（前提 3）；
- K：**知识状态**——对与主体决策集相关的状态空间 Θ_{rel} 的信念测度 $\mu_K \in \mathcal{P}(\Theta_{\text{rel}})$，连同已消费命题集的记忆（用于新颖度计算：条目 i 的新颖度 $= I(y_i; \omega \mid K)$，见第 8.5 节）；
- $\theta = (\theta_{\text{cal}}, \theta_{\text{open}}, \theta_{\text{hum}}) \in [0, 1]^3$：认知德性状态（第 10 节给出测量模型与动力学）；
- R：反思层——对人类是本人，对 AI 智能体是其委托人的合法授权配置。

定义 4.6（决策集）。D 为主体声明的**活跃决策集**（有限）：每项 $d \in D$ 附带决策期限 h_d（视界）与效用函数 $u_d(a, \omega)$。关键性以此定义：命题 e 对主体是**关键的**（$e \in E^*$），若存在 $d \in D$ 使 e 的信息对 d 的最优行动有非零改变概率，且改变幅度超过声明阈值。**关键性是主体相对的**——本文将其显式化：它使召回目标在算术上可行（命题 6.3 的预算可行性条件）。

4.3 获取—过滤策略

定义 4.7（策略五元组）。策略 $\pi = (\pi_{\text{mon}}, \pi_{\text{pull}}, \pi_{\text{push}}, \pi_{\text{del}}, \pi_{\text{esc}})$：

- π_{mon}：**监测清单**——被直通准入的信源类子集与监控实体清单（假设 R3）；慢变量（周/月更新），受慢尺度门控（§10.3 假设 C5）；
- π_{pull}：**主动获取策略**——查询生成、检索深度、信源探索、补丁停留与轮换（第 8 节）；
- π_{push}：**过滤策略**——对候选池（push 到达 ∪ pull 返回）的选择 $A \subseteq X$（第 6 节）；
- π_{del}：**交付策略**——分层摘要、排序、冷却队列调度；遵守”摘要 = 地图”原则（第 11.1 节 C 类约束）；
- π_{esc}：**紧急覆盖策略**——预先授权指令下的保守行动（第 11 节）。

预算恒等式：$T = T_{\text{pull}} + T_{\text{push}} + T_{\text{ref}}$，其中 T_{ref} 为反思负荷（每周校准会等，C 类，不可自动化）。定理 8.1 给出该划分的最优性条件。

4.4 生产者生态

定义 4.8（生产者博弈环境） 。内容生产者群体按类型 $q \in \{\text{honest}, \text{sensational}, \text{manipulative}\}$ 分布，份额向量 $\mathbf{x} = (x_h, x_s, x_m)$，$\sum_i x_i = 1$。生产者选择内容策略以最大化收益 $\Pi(q)$（第 9.4 节给出收益结构）；份额按复制子动态演化。过滤器的采纳率 $\sigma \in [0,1]$（人群中主权过滤器用户占比）是生产者收益的外生参数，σ 的内生化（用户根据生态质量采纳）留作开放问题（第 17 节）。

---

5 主权获取问题（SAP）与信息价值分解定理

5.1 主权获取问题

定义 5.1（Sovereign Acquisition Problem, SAP）。给定视界 H（期数）、贴现因子 $\beta \in (0,1]$，SAP 为：

$$\max_{\pi \in \Pi_S} \mathbb{E}_\pi \left[\sum_{t=1}^{H} \beta^t \Big(\underbrace{\mathrm{VOI}_t(A_t)}_{\text{当期信息价值}} + \underbrace{\zeta\, \Delta\theta_t}_{\text{德性增益}} - \underbrace{\mathrm{Harm}_t(A_t)}_{\text{操控损害}} \Big) \right]$$

约束：

- **(预算)** 每期 $\sum_{i \in A_t} \tau_i + c(\pi_{\text{pull},t}) + c_{\text{ref}} \le T$，其中 $c(\pi_{\text{pull},t})$ 为主动获取的时间成本（查询、探索、阅读检索结果），c_{ref} 为不可压缩的反思负荷；
- **(操控暴露)** $\mathbb{E}[\#\{i \in A_t : m_i > \tau_m\}] \le \varepsilon_c / (\delta(1-\rho_m))$（由定理 9.1 的界 $D \le \delta(1-\rho_m)\,\mathbb{E}[n_m] \le \varepsilon_c$ 反解）；
- **(容差带)** 曝光集立场散布 $d(E_t) \le \rho(\theta_t)$（定义 10.2，非反噬约束）；
- **(主权约束)** $\pi \in \Pi_S$：策略空间被 S1–S4（定义 5.3）限制——目标函数可读、参数写入须经 R 授权、无第三方收益项、决策可审计；
- **(紧急结构)** π_{esc} 限于预先授权指令类（定义 11.2）。

注（量纲一致性）。目标泛函中 VOI_t 与 Harm_t 均以同一决策效用单位计量（Harm 的定义见 §5.2：误设更新下的期望效用损失），二者可加；$\zeta\,\Delta\theta_t$ 是慢尺度项，ζ 是主体声明的”德性—效用兑换率”（B 类决策），其存在本身就是前提 3 的操作化——主体显式声明长期德性相对当期信息价值的权重。第 8 节”VOI/分钟”的影子价格 ν 在 push/pull/反思之间统一量纲，正是因为三类用途的价值函数都被表示为同一效用单位对时间的函数。

SAP 是随机控制问题：pull 侧的探索—利用权衡、push 侧的在线选择、慢尺度的 θ 动力学与监测清单更新耦合在一起。**本文不对完整 SAP 求全局最优**（一般情形下的 restless bandit 特例即已 PSPACE 难，Papadimitriou & Tsitsiklis, 1999；复杂性讨论见 §8.6），而是采取”分解 + 逐层最优性保证”的策略：第 6 节解 push 选择层（次模贪心 + 阈值策略），第 7 节解监测清单的覆盖保证，第 8 节解 pull 层并给出三层之间预算分配的无套利条件（定理 8.1），第 9–12 节给各层装上安全、升华、紧急与公共性约束。**诚实声明**：逐层最优性不能自动组合成全局近似最优——各层通过共享预算与知识状态耦合，层内近似比相乘或误差线性传播的一般性定理本文没有证明；本文给出的是各层误差项的显式刻画（失真下界、覆盖漏报界、防火墙界、收敛邻域界）与它们进入 SAP 目标的通道，弱耦合条件 (W1)–(W4) 下 §8.8 的注已给出可加的组合界，一般耦合情形的严格传播界列为开放问题 O8。仿真（第 14 节）以端到端 KPI 检验分解策略的实际表现。

命题 5.1（最优策略的存在性）。设视界 H 有限，每期奖励有界（$|\mathrm{VOI}_t|, |\mathrm{Harm}_t| \le \bar{V} < \infty$），每期候选池有限（从而每期行动集——候选池子集族与有限 pull 算子组合的笛卡尔积——有限），且约束集（预算、暴露、容差带、主权约束 S1–S4、紧急结构）逐期封闭。则 SAP 存在最优（确定性马尔可夫）策略，不必唯一。

证明（有限视界动态规划）。在每期行动集有限、奖励有界、视界有限的标准假设下，有限视界 MDP 的逆向归纳直接成立：定义期末值函数 $V_{H+1}(\cdot)\equiv 0$，自 $t=H$ 至 $t=1$ 递推

$$V_t(s_t)=\max_{a_t\in\mathcal{A}_t(s_t)}\Big\{r_t(s_t,a_t)+\beta\,\mathbb{E}\big[V_{t+1}(s_{t+1})\mid s_t,a_t\big]\Big\},$$

其中 $s_t=(K_t,\theta_t,\text{剩余预算},\pi_{\text{mon},t})$ 为充分状态，$\mathcal{A}_t(s_t)$ 为当期可行行动集（非空：空消费行动总可行）。每期 $\mathcal{A}_t$ 有限 ⇒ 最大值取得 ⇒ 各期存在最优行动规则；归纳拼接即得全局最优策略。主权约束 S1–S4 的作用是收缩各期 $\mathcal{A}_t$（剔除未授权参数写入、含第三方收益项的策略），收缩不改变逐期有限性，存在性结论不受影响。**关于证明技术层级的澄清（v1.6 新增）**：在本文的有限性假设（有限视界、每期有限行动集）之下，**实际上不需要任何可测选择机制**——有限集上的最大值直接取得，上述逆向归纳自足。引用 Bertsekas & Shreve (1978) 的可测选择理论不是因为有限论证需要它，而是标出同一存在性结果向 Borel 状态空间（信念 μ_K 为概率测度）推广的标准路线（若有限性假设被放松）：其第 7 章（“Borel Spaces and their Probability Measures”，尤指普遍可测选择结果）的选择机制与第 8–9 章（“The Finite Horizon Borel Model”/ “The Infinite Horizon Borel Models”；章号随印本略有差异，章名是稳定标识）的 Borel 模型存在性结果。该引用是推广路标，不是承重步骤。■

注（证明路线说明）。本文不采用”策略空间弱紧性 + 连续泛函取最大值”的路线：条件转移核空间的弱紧性需要 relaxed control（Young 测度）框架，且 S2 的授权约束把参数限定在 R 批准的集合上——该集合一般非闭，与紧性论证不兼容。DP 路线在本文自身假设（有限视界、逐期有限行动、有界奖励）下更初等也更严格。

5.2 信息价值的特征分解

评分函数是全部工程的核心。本节为五维特征向量提供决策论地基：在显式假设下给出条目**期望实现决策价值**的逐决策结构分解，并精确刻画”五维特征是其摘要”成立所需的追加条件（(V4)，含失效反例）。本节同时诚实处理一个概念难点：Blackwell 框架下任何实验的信息价值非负（引理 5.1），而对抗性内容显然可以造成负价值——两者的相容需要一个显式的”误设更新”建模步骤（定义 5.2），这正是本节的主要技术内容。

设定。状态空间 Θ_{rel}（与决策集 D 相关的世界状态），主体当前信念 μ_K。条目 x_i 的生成是一个**两分支混合**：以概率 c_i（信源可信度）为真分支，条目提供关于 Θ_{rel} 的真实信号 y_i（信息结构 σ_i）；以概率 $1-c_i$ 为假分支，条目携带对抗者选择的信号 $\tilde{y}_i$（旨在把信念推向对对抗者有利的方向）。主体消费条目时**无法观测分支标签**——这正是对抗问题的实质。

引理 5.1（EVPI 恒等式与非负性）。对任一决策问题与任一实验 σ，主体按正确似然作贝叶斯更新时：

$$\mathrm{VOI}(\sigma):=\mathbb{E}_{y\sim\sigma}\Big[\max_a\mathbb{E}[u(a,\omega)\mid y]\Big]-\max_a\mathbb{E}[u(a,\omega)]\;\geq\;0.$$

证明见附录 B.5（Jensen 不等式的一行推论；Blackwell (1953) 进一步给出实验间的信息化序刻画）。

推论性观察（对抗分支为何不是 Blackwell 实验）。引理 5.1 的非负性以”主体按**正确似然**更新”为前提。对抗内容的伤害机制恰恰在于：主体**按误设的似然更新**——把对抗信号 $\tilde{y}$ 当作真实信号 y 处理。因此对抗分支的”价值”不是任何 Blackwell 实验的 VOI，必须单独定义。

定义 5.2（误设更新下的期望实现决策价值）。对决策 d、信号 z（真实分布 Q_z），设主体按（可能误设的）似然 ℓ 把信念更新为后验 $\mu_K^{\ell}(\cdot\mid z)$，并据此选择行动 $\widehat{a}(z)=\arg\max_a\mathbb{E}_{\mu_K^{\ell}(\cdot|z)}[u_d(a,\omega)]$。定义**期望实现决策价值**

$$W_d(z;\,\ell):=\mathbb{E}_{z\sim Q_z}\,\mathbb{E}_{\omega\sim P(\cdot|z)}\big[u_d(\widehat{a}(z),\omega)\big]-\max_a\mathbb{E}_{\mu_K}[u_d(a,\omega)],$$

其中外层期望按**真实**联合分布取值。按正确似然更新时 $W_d(z;\ell_{\text{true}})=\mathrm{VOI}_d(z)\geq 0$（引理 5.1）；按误设似然更新时 W_d 可严格为负（后验被系统性推离真值，行动比在 a_0 处停留更差）。

假设（特征分解假设 (V1)–(V5)）：

- **(V1) 决策关联**：条目只通过 D 中的决策影响主体效用：$v_i^* = \sum_{d\in D} P(d \text{ 在视界内活跃且} i \text{ 与之关联}) \cdot W_i^{(d)}$，其中 $W_i^{(d)}$ 为条目对决策 d 的期望实现决策价值。泛泛的知情不经由 D 定价，其价值进入慢尺度德性项 $\zeta\Delta\theta$（第 10 节）——这诚实地承认：决策论框架定价不了”修养”，修养由升华控制论单独处理。
- **(V2) 分支混合与有界伤害**：真分支中主体按正确似然更新，实现价值为 Blackwell 信息价值 $W_i^{(d)}(y_i;\ell_{\text{true}}) = \text{VOI}_i^{(d)}(y_i) \geq 0$；假分支中主体按”信号为真”的误设似然更新，实现价值 $W_i^{(d)}(\tilde{y}_i;\ell_{\text{mis}}) \leq 0$ 且有下界：定义**伤害项** $\text{Harm}_i^{(d)} := -W_i^{(d)}(\tilde{y}_i;\ell_{\text{mis}}) \in [0, \text{Harm}_{\max}]$（单条目伤害有界与第 9 节 F1 的单条有界影响假设互为表里）。
- **(V3) 时效折扣**：决策 d 的信息价值随信息到达距决策期限的时间差 h 按 e^{-h/λ_d} 折扣（λ_d 为决策的**耐久尺度**：一次性事件新闻 λ_d 小，基础性知识 λ_d 大）。
- **(V4) 决策同质性**（精确摘要所需的追加假设）：所有决策 $d \in D$ 共享同一耐久尺度 $\lambda_d = \lambda$，且逐决策价值按共同剖面分解：$\text{VOI}_i^{(d)}(y_i) = a_d \cdot V_i$，$\text{Harm}_i^{(d)} = a_d \cdot H_i$，其中 $a_d \geq 0$ 为决策 d 的重要性权重（不依赖条目），V_i, H_i 为条目的决策无关价值与伤害基准。(V4) 的实质是：各决策只在”权重”上不同，不在价值结构上不同。
- **(V5) 分支—更新一致性**（v1.6 新增为显式假设；此前隐含于 (V2) 与下文注记）：数据生成分支指标与主体实际使用的更新规则相对应——真分支中主体按正确设定的似然更新，实现价值等于 Blackwell 信息价值 $\text{VOI}_i^{(d)}(y_i)$；假分支中主体按”信号为真”的误设似然更新，实现价值等于 $-\text{Harm}_i^{(d)}$。由此，复合量 $W_i^{(d)}$（定义 5.2）**不是**任何单一实验的 Blackwell 价值：两个分支来自不同的更新规则（正确设定 vs. 误设似然），而非同一实验内的后验混合。(V5) 正是允许把定理 5.1 中的分支期望读作”对分支指标应用全期望公式”的结构性假设。

定理 5.1（期望实现决策价值的特征分解）。在 (V1)–(V3) 与分支—更新一致性约定 (V5) 下，条目 x_i 对主体的期望实现决策价值分解为

$$v_i^* \;=\; \sum_{d\in D} \pi_d(i) \left[\, c_i\, \text{VOI}_i^{(d)}(y_i)\, e^{-h_i/\lambda_d} \;-\; (1-c_i)\, \text{Harm}_i^{(d)} \,\right]$$

各因子的读法（语义注解在此以散文给出，刻意不放入显示式，以免任何注解被误读为分母）：$\pi_d(i) = P(d \text{ 活跃且关联} \mid i)$ 为相关度—行动性权重；$c_i\, \text{VOI}_i^{(d)}(y_i)$ 为可信度加权的新颖度因子，其中 $\text{VOI}_i^{(d)}(y_i) \geq 0$（引理 5.1）为 Blackwell 信息价值，关于实验信息化序单调不减（Blackwell, 1953）；e^{-h_i/λ_d} 为 (V3) 的耐久度（时效）折扣，只乘真分支价值；$(1-c_i)\,\text{Harm}_i^{(d)}$（$\text{Harm}_i^{(d)} \in [0, \text{Harm}_{\max}]$）为对抗分支惩罚。上式是**逐决策（$d$-依赖）结构分解**：它把 v_i^* 表达为可标定成分的组合，但右端一般**不能**由条目的有限维标量特征重构（见下注的反例）。**(V4) 下的聚合**：代入 $\text{VOI}_i^{(d)} = a_d V_i$、$\text{Harm}_i^{(d)} = a_d H_i$、$\lambda_d = \lambda$ 并在括号内提出 a_d，显示式坍缩为 $v_i^* = A_i[c_i V_i e^{-h_i/\lambda} - (1-c_i)H_i]$（$A_i := \sum_d \pi_d(i) a_d$）——即下一个显示式的精确五维摘要。**精确摘要结论**：在追加假设 (V4) 下，定义聚合特征 $A_i := \sum_d \pi_d(i)\, a_d$（相关度 × 行动性），则

$$v_i^* \;=\; A_i \Big[c_i\, V_i\, e^{-h_i/\lambda} - (1-c_i)\, H_i \Big] \;=:\; F\big(\phi(x_i; K, D)\big),$$

即五维特征向量（在 (V4) 下退化为四个有效聚合量 A_i, V_i, h_i, c_i，伤害基准 H_i 取标定常数或并入特征）是 v_i^* 的精确摘要：存在不依赖 i 的 F（由 λ、$\{a_d\}$、H 决定）使 $v_i^* = F(\phi)$。在 (V4) 之外，不存在这样的 F，五维特征应被视为工程启发式摘要。

证明。第一步（分解）：由 (V1)，$v_i^* = \sum_d \pi_d(i)\, W_i^{(d)}$。第二步（分支混合）：条目价值按**数据生成分支**取期望——以概率 c_i 落入真分支（价值 $\mathrm{VOI}_i^{(d)}(y_i)$），以概率 $1-c_i$ 落入假分支（价值 $-\mathrm{Harm}_i^{(d)}$，由 (V2) 与定义 5.2）。期望对分支指标是线性的（这只是对离散随机变量取期望），故

$$W_i^{(d)} = c_i\, \mathrm{VOI}_i^{(d)}(y_i) - (1-c_i)\, \mathrm{Harm}_i^{(d)}.$$

第三步（时效）：由 (V3) 对真分支价值乘折扣 e^{-h_i/λ_d}（假分支的伤害在消费当期实现，不打时效折扣——此不对称反映"坏信息立即扭曲判断，好信息的价值依赖决策时机"）。合并三步得分解式。摘要性：分解式右端只通过 $(\pi_d(i))_d$、$\mathrm{VOI}_i^{(d)}(y_i)$、$h_i/\lambda_d$、$c_i$ 依赖 i；$\pi_d(i)$ 是"相关度 × 行动性"，$\mathrm{VOI}_i^{(d)}(y_i)$ 是"新颖度"（给定 K 的条件信息增益的单调函数——由 Blackwell 定理，信息价值随实验信息化程度单调，而在 K 已含的信息上增益为零，故它度量的正是相对 K 的新颖性），h_i, λ_d 是"耐久度"，c_i 是"可信度"。精确摘要部分：在 (V4) 下代入 $\mathrm{VOI}_i^{(d)} = a_d V_i$、$\mathrm{Harm}_i^{(d)} = a_d H_i$、$\lambda_d = \lambda$，求和号内提出 a_d 得 $v_i^* = \big(\sum_d \pi_d(i) a_d\big)\big[c_i V_i e^{-h_i/\lambda} - (1-c_i)H_i\big]$，右端只经 (A_i, V_i, h_i, c_i) 依赖 i，取 F 为该表达式即得。（注意：没有 (V4) 时此步不成立——$\sum_d \pi_d(i)\,[\,\cdot\,]_d$ 是 d-相关量的乘积之和，一般不是任何低维聚合的函数。）■

注（本定理的精确地位——回应两种误读）。

1. **为什么第二步不是"VOI 对后验混合的线性分解"**：若把条目建模为单一 Blackwell 实验（后验按 $\mu_{K\oplus x_i} = c_i \mu_{K\oplus y_i} + (1-c_i)\mu_{K\oplus \tilde{y}_i}$ 混合），则 $\max_a$ 算子的非线性使混合实验的 VOI **一般不等于** VOI 的线性混合，且由引理 5.1 该 VOI 必非负——既推不出分解式，也容纳不了伤害项。本文的分解不在后验层面而在**数据生成分支**层面取期望：分支指标是真实世界的一部分（内容究竟是不是对抗载荷），对其取期望是普通的全期望公式，线性性平凡成立。代价是 W（定义 5.2）取代了 VOI 成为价值概念——它不是任何单一实验的 Blackwell 价值，而是"按自身更新规则行事的智能体在一类生成过程下的期望实现效用变化"。**这一点现已是假设 (V5) 的显式内容**：分支指标与主体实际更新规则的对应关系是定理的假设而非 Blackwell 框架的推论，读者不应把该分解误认为 Blackwell 框架内的标准结果。
2. **一般情形下的地位**：分解式依赖 (V1)–(V3) 的结构；**精确摘要结论额外依赖 (V4)**。在 (V4) 之外（交互决策、非指数时效、分支内更新规则随内容自适应、决策间价值结构异质），五维特征向量应被视为**工程启发式摘要**而非价值充分统计量；高斯—二次结构加 (V4) 下它是精确的（推论 5.1）。本文评分函数的决策论地基相应地是"结构假设下的条件性摘要定理"，而非无条件恒等式。
3. **反例（(V4) 失效时五维标量不能重构 v_i^*）**：设 $D = \{d_1, d_2\}$，d_1 为突发决策（λ_1 小）、d_2 为持久决策（λ_2 大）。条目 i 只与 d_1 关联、条目 j 只与 d_2 关联，且两者的五维标量特征完全相同（相同的聚合相关度、新颖度、耐久度读数、行动性、可信度）。则 $v_i^* \propto e^{-h/\lambda_1}$ 而 $v_j^* \propto e^{-h/\lambda_2}$，$\lambda_1 \neq \lambda_2$ 时 $v_i^* \neq v_j^*$：相同的五维特征对应不同的价值。故 $\sum_d \pi_d(i)\,[\,\cdot\,]_d$ 一般不是聚合标量的函数——"精确摘要"必须以 (V4) 为前提，不能悄悄假设。
4. **线性评分 $\langle w, \phi\rangle$ 的地位**：SAP 的工程目标与定义 9.1 使用线性评分，而 (V4) 下的精确 F 是乘性/双线性的（$A \cdot [cVe^{-h/\lambda} - (1-c)H]$）。两者的相容途径：(a) 收益项 $cVe^{-h/\lambda}$ 取对数后关于 $(\log c, \log V, h)$ 是**加性**的——对数特征上的线性评分对纯收益项是精确的（对数单调，保序）；(b) 伤害项 $-(1-c)H$ 不可与收益项在同一日志空间相加，本文的处理是**架构性分离**：伤害通道由防火墙（第 9 节，按 $\rho_m, n_{\max}$ 硬约束）而非评分函数承担，评分只负责收益侧排序；(c) 在此结构之外，$\langle w, \phi\rangle$ 与 F 之间没有已证的近似界，线性评分是工程启发式——本文不再宣称其有无条件的决策论正当性，其排序质量由 d' 实测定价（定理 6.1 的用法正是"不假定评分正确，而是给评分误差定价"）。

推论 5.1（高斯—二次闭式）。若对每个关键决策 d：$\omega_d \in \mathbb{R}$，先验 $\omega_d \sim \mathcal{N}(\hat{\omega}, \sigma_0^2)$，信号 $y_i = \omega_d + \epsilon$，$\epsilon \sim \mathcal{N}(0, \sigma_i^2)$，效用二次 $u_d(a, \omega_d) = -(a - \omega_d)^2$，则

$$\mathrm{VOI}_i^{(d)}(y_i) \;=\; \sigma_0^2 - \frac{\sigma_0^2 \sigma_i^2}{\sigma_0^2 + \sigma_i^2} \;=\; \frac{\sigma_0^4}{\sigma_0^2 + \sigma_i^2} \;=\; \sigma_0^2 \cdot \frac{\sigma_0^2}{\sigma_0^2 + \sigma_i^2}.$$

即信息价值 = 先验方差 ×（后验精度增益占比）。评分函数的”新颖度”维度在此闭式下就是精度增益 $\sigma_0^2/(\sigma_0^2 + \sigma_i^2)$ 的估计；“相关度”是 $\pi_d(i)$；“可信度” c_i 对 σ_i^2 的修正即信源噪声标定。

证明。二次效用下 $\max_a \mathbb{E}[u] = -\mathrm{Var}$，故 $\mathrm{VOI} = \mathrm{Var}(\text{先验}) - \mathbb{E}[\mathrm{Var}(\text{后验})] = \sigma_0^2 - \frac{\sigma_0^2\sigma_i^2}{\sigma_0^2+\sigma_i^2} = \frac{\sigma_0^4}{\sigma_0^2+\sigma_i^2}$。整理即得（末式 $= \sigma_0^2 \cdot \frac{\sigma_0^2}{\sigma_0^2+\sigma_i^2}$）。■

工程含义。(a) 在 (V4) 成立的决策结构上，评分权重 w 不是自由参数：w 的各维是 F 中决策权重 $\pi_d a_d$、耐久尺度 λ（实际衰减因子为 $e^{-h_i/\lambda}$）、损害界 $\mathrm{Harm}_{\max}$ 的像——S2（写入权）因此约束的是**决策集与效用声明**，而非任意数字；在 (V4) 之外，w 的标定只能走实证路线（d' 实测与回顾审计），不享有结构化导出；(b) 新颖度维度的正确实现是条件互信息 $I(y_i; \omega \mid K)$ 的代理（第 8.5 节给出可计算的次模版本）；(c) Harm 项把”可信度低的高相关条目”正确压为负分——这正是防火墙（第 9 节）与评分函数的接缝：防火墙检测召回 ρ_m 降低的是假分支的到达率，从而缩小 $(1 - c_i)$Harm 项的期望贡献。

5.3 主权条件与可逆性原则

定义 5.3（主权条件 S1–S4）。获取—过滤系统 (π, U) 是**主权的**，当且仅当：

- **S1（可检视性）**：目标泛函 U 以不超过 k 项的可解释形式表示（本文 $k = 5$：ϕ 的五维），权重 w 与 $g^{(2)}$ 对反思层 R 完全可读；
- **S2（写入权）**：对 w、$g^{(2)}$、阈值参数、监测清单 π_{mon} 的任何修改须经 R 显式授权 σ_R；系统不得利用行为数据隐式改写目标函数（点击信号只能用于**测量**，不能用于**写入**——与平台推荐系统的分界在此）；
- **S3（不可俘获性）**：U 不含任何与第三方收益相关的项。理想化表述：$I(U;\, \mathrm{Rev}_{\text{platform}}) = 0$（互信息为零）。操作化审计：代码审查 + 权重来源日志 + 排序反事实测试（对同一内容池，验证排序不因平台侧变量改变）；
- **S4（可审计性）**：每条投递附解释 $e(i) =$ 贡献最大的前 j 个特征及其符号；全部排序与准入决策留不可篡改日志。

定义 5.4（可逆性原则）。任何参数修改立即生效、历史可查、可一键回滚。系统不得以沉没成本、迁移壁垒或默认惰性锁定主体。形式化：策略参数空间上的切换成本函数 $c_{\text{switch}}(\cdot, \cdot) \equiv 0$（由系统承担，不转嫁主体）。

注（S 条件与 SAP 的关系）。S1–S4 不进入 SAP 的目标泛函，而是收缩其策略空间 Π_S：主权是约束而非偏好项。这一设计的理由：若主权可被效用交换掉，则在 $g^{(1)}$ 被环境塑造的世界里它必然被交换掉（前提 3 + Elster 的酸葡萄机制）。主权条件是 Ulysses 契约的系统级形态（第 11 节）。

注（$g^{(2)}$ 的引导负担——本框架最大的可用性缺口）。SAP 与 S2 要求主体声明决策集 D、效用 u_d、视界 h_d、容忍阈 ε_c 与预先授权四元组 D_{adv}——**普通主体写不出自己的效用函数**，这是全部价值对齐研究共有的引导（elicitation）难题，本文不例外。与本问题最相关的文献线：合作逆强化学习（CIRL，即 Hadfield-Menell et al. (2016) 把”主体目标未知、须经交互学习”形式化为双人合作博弈）与 Off-Switch 博弈（可纠正性作为博弈均衡性质，Hadfield-Menell et al., 2017）。本文的立场是工程性的折中而非解决：(a) 声明负担被**分显式等级**——最小可用声明只有监控清单与每周时间预算两项，效用参数全部取保守默认（默认即价值观的治理问题见 §16.2）；(b) $g^{(2)}$ 作为慢变量由季度目标修订会（C 类，命题 10.2）迭代精化，而非一

次性引出——这与 CIRL 的”交互中学习目标”在精神上同构，但以人类门控替代自动化偏好推断（避免把推断误差固化为写入）；(c) 引导质量的可测代理：声明修订幅度随时间收敛（声明稳定化）与”声明—行为”缺口（声明的 E^* 与实际消费主题的偏离度）。**关于迭代引导下的良定义性（v1.6 新增）**：一边声明 $g^{(2)}$、一边承认它可能需要交互才能发现，这里没有循环——SAP 目标函数是**相对当前决策时点生效的声明**定义的，而 $g^{(2)}$ 的修订本身是被治理的行为（C 类决策、人类门控、S4 留痕），故每个时点的优化问题在当前声明下良定义。必须让步的是一个**快照近似**：若主体”真实的” $g^{(2)}$ 只能经交互发现（CIRL 图景），则每个时点优化的是”当前最优声明”而非某个固定的潜在目标。框架的收敛主张相应地更弱且明确——收敛到声明的邻域（定理 10.1/猜想 10.1），声明质量本身由 (c) 的代理监测。完整的形式化（CIRL 化的 SEA）留作后续工作（见 §17 局限 12 的扩展）。

第三部分 核心定理

6 被动过滤（push）的效率理论

本章回答第二个追问：“过滤凭什么安全?”答案分四层：容量与失真的下界（6.1）说明激进过滤的代价是什么；分离度瓶颈定理（6.2）说明**纯评分通道在数学上撑不起高召回**，从而证明双通道架构（命题坍缩 + 信源冗余直通 + 评分发现）的必然性；次模性与贪心保证（6.3）给出选择算法的可证近似最优；阈值策略（6.4）给出在线情形的最优结构；6.5 将全部结果综合为双通道架构原则。

6.1 容量下界与失真下界

命题 6.1（过滤比算术下界）。设每期到达 N 条候选，单条消费成本 $\tau_i \geq \underline{\tau} > 0$，预算 T。则任何策略每期消费量 $m \leq T/\underline{\tau}$，被弃比例

$$1 - \frac{m}{N} \;\geq\; 1 - \frac{T}{\underline{\tau} N}.$$

代入典型值 $T = 45$ 分钟、$\underline{\tau} \approx 4$ 分钟/条（深度阅读一条实质内容）、$N = 10^4$：过滤比 $\geq 99.8\%$。

证明。消费量受预算约束 $m\underline{\tau} \leq \sum_{i \in A} \tau_i \leq T$。■

定义 6.1（关键价值泄漏 / 失真）。对策略 π，定义失真

$$\mathcal{D}(\pi) := \mathbb{E}\Big[\sum_{e \in E^*} v_e \cdot \mathbb{1}\{e \text{ 未被消费}\}\Big],$$

即关键命题集 E^*（定义 4.6）中未被覆盖部分的真实价值之和的期望。这是”激进过滤的代价”的精确度量。

命题 6.2（失真下界与最优失真）。设当期关键命题数 $K^* = |E^*|$，价值 $\{v_e\}$，消费预算可容纳 m 个不同命题。则对任何策略

$$\mathcal{D}(\pi) \;\geq\; \mathcal{D}^* := \mathbb{E}\Big[\sum_{r > m} V_{(r)}\Big],$$

其中 $V_{(1)} \geq V_{(2)} \geq \ldots$ 为 $\{v_e\}$ 的降序排列。等号当且仅当策略恰好消费价值前 m 的关键命题（完美排序且预算全部投向关键命题）。

进一步，若 $v_e \overset{iid}{\sim} \text{Pareto}(\alpha, v_{\min})$（$\alpha > 1$，幂律关键性——仿真生成器的设定），则

$$\frac{\mathcal{D}^*}{\mathbb{E}[\sum_e v_e]} \;=\; 1 - \Big(\frac{m}{K^*}\Big)^{(\alpha-1)/\alpha}.$$

证明。第一式：任何策略至多消费 m 个不同命题，泄漏价值 = 全部关键价值 − 被消费的关键价值 ≥ 全部关键价值 − 最大的 m 个关键价值 $= \sum_{r>m} V_{(r)}$；完美排序策略取等。第二式：Pareto 尾 $P(V > v) = (v/v_{\min})^{-\alpha}$，分位数函数 $Q(1-u) = v_{\min} u^{-1/\alpha}$。总量期望 $\mathbb{E}[\sum_e v_e] = K^* v_{\min}\alpha/(\alpha-1)$。前 m 项的期望和以阶次统计量的积分近似：

$$\mathbb{E}\Big[\sum_{r\le m} V_{(r)}\Big] \approx K^* v_{\min} \int_0^{m/K^*} u^{-1/\alpha}\,du = K^* v_{\min}\frac{\alpha}{\alpha-1}\Big(\frac{m}{K^*}\Big)^{(\alpha-1)/\alpha}.$$

相减除以总量即得。■

注（近似精度）。上述积分近似在 $m \to \infty$（且 m/K^* 有界或趋于零）时相对误差 $o(1)$（Resnick, 1987）；小 m 时精确阶次统计量含 Γ 修正因子（$\mathbb{E}[V_{(r)}] = v_{\min}\frac{\Gamma(r-1/\alpha)\Gamma(K^*+1)}{\Gamma(r)\Gamma(K^*+1-1/\alpha)}$，$r$ 小时与 $v_{\min}(K^*/r)^{1/\alpha}$ 相差 $\Gamma(1-1/\alpha)$ 量级因子，$\alpha = 1.5$ 时首项偏差可达两位数百分比）。本文典型使用区间 $m/K^* \in [0.5, 0.8]$ 不完全在渐近区，故闭式应读作**一阶近似**，其导出的数值（如下文的 20.6%、7.2%）带有相应的宽容差；仿真（P2）以生成器的精确阶次统计量直接检验。**两个印刷数值的显式误差界（v1.6 新增）**：用上式 Γ 公式精确计算聚合泄漏份额 $\sum_{r>m}\mathbb{E}[V_{(r)}]\big/\sum_{r}\mathbb{E}[V_{(r)}]$（确定性计算，仅凭该公式即可复现），在试点规模 $K^* = 52$、$\alpha = 1.5$ 下得：$m/K^* = 0.5$（$m = 26$）时 **20.8%**，$m/K^* = 0.8$（$m \approx 42$）时 **6.9%**——与闭式值 20.6%、7.2% 的偏差为 $+0.2$ 与 -0.3 个百分点。在该使用区间内，偏差对一切 $K^* \ge 52$ 保持在 ± 0.3 个百分点以内，且随 K^* 增大而收缩（$K^* = 100$：20.7%/7.2%；$K^* = 500$：20.6%/7.2%）。“两位数百分比”的告诫适用于**单个极端阶次统计量**（如首项 $\mathbb{E}[V_{(1)}]$），不适用于印刷区间内的聚合泄漏份额；两个印刷数值应读作 20.6%（$K^* = 52$ 时 ± 0.3 个百分点）与 7.2%（± 0.3 个百分点）。

数值含义（诚实面对激进过滤的代价）：$\alpha = 1.5$ 时，若预算覆盖一半关键命题（$m/K^* = 0.5$），关键价值泄漏 $\approx 20.6\%$；覆盖 80% 时泄漏 $\approx 7.2\%$。结论：失真下界由**价值分布的尾部形状与预算覆盖率**决定，任何过滤器无法逃脱；工程目标是通过（a）提高排序质量逼近 $\mathcal{D}^*$，（b）以监测清单扩大”事实上的 m“（关键命题的直通准入不占用竞争排序），（c）以 $g^{(2)}$ 校准 E^* 的声明范围，把泄漏压向可接受水平。

6.2 评分分离度瓶颈定理

命题 6.2 假定排序完美。本小节证明：**当排序不完美时，极端过滤比对评分质量提出数学上不现实的要求**——这是”架构承担召回、评分承担发现”分工（6.5 节）的定理级根据。

设定（高斯评分模型）。候选池 M 个命题，其中比例 π 为关键。评分 $s = \mu_0 + \sigma Z$（非关键，$Z \sim \mathcal{N}(0,1)$）或 $s = \mu_0 + d'\sigma + \sigma Z$（关键）。$d' = (\mu_1 - \mu_0)/\sigma$ 为信号检测论分离度（Green & Swets, 1966）。过滤器消费得分最高的 βM 个（$\beta = m/M$）。记 $\bar{\Phi}$ 为标准正态尾函数，阈值 z 由阈值方程决定（定理 6.1）。

定理 6.1（预算—分离度—召回恒等式与瓶颈）。

(i)（恒等式）阈值 τ 由混合尾方程决定：

$$(1-\pi)\,\bar{\Phi}(z) + \pi\,\bar{\Phi}(z - d') = \beta, \qquad z := (\tau - \mu_0)/\sigma,$$

召回率 $R = \bar{\Phi}(z - d')$。

(ii)（容量上限）对任何评分质量，$R \le \min\{1,\ \beta/\pi\}$。特别地，若 $\beta < \pi$，则召回率连 100% 都不可达，上限为 β/π。

(iii)（分离度需求）给定目标召回 R，可行的充要条件为 $\beta \geq \pi R$，且所需分离度

$$d' \;\geq\; \underline{d'}(\beta, \pi, R) := \Phi^{-1}\Big(1 - \frac{\beta - \pi R}{1 - \pi}\Big) + \Phi^{-1}(R),$$

其中 Φ^{-1} 为标准正态 CDF 的分位数函数（全程统一使用 CDF 分位数约定；若改用尾函数 $\bar{\Phi}$，须把两个 $\Phi^{-1}(\cdot)$ 同步换成 $\bar{\Phi}^{-1}(1-\cdot)$，不可混用——混用将得到 ± 1.10 之类的错误数值）。

(iv)（数值）命题级典型参数：$M \approx 800$（10^4 文档 $\div$ $\rho_c \approx 12.5$），$m \approx 10$，$K^* \approx 8$（$\pi = 0.01$，$\beta = 0.0125$），目标 $R = 0.95$：需

$$d' \geq \Phi^{-1}\big(1 - \tfrac{0.0125 - 0.0095}{0.99}\big) + \Phi^{-1}(0.95) = \Phi^{-1}(0.99697) + \Phi^{-1}(0.95) \approx 2.74 + 1.645 = 4.39,$$

对应 ROC 曲线下面积 AUC $= \Phi(d'/\sqrt{2}) \approx \Phi(3.10) \approx 0.999$——近乎完美的关键性判别。

证明。

(i) 消费集为 $\{s > \tau\}$，其规模占比即混合分布的尾概率，等于 β 定义阈值；召回 $R = P(s > \tau \mid \text{关键}) = \bar{\Phi}((\tau - \mu_1)/\sigma) = \bar{\Phi}(z - d')$。

(ii) 被消费的关键命题数 $\leq$ 消费总数 βM，也 $\leq$ 关键命题总数 πM；故 $R = \frac{\text{被消费关键数}}{\pi M} \leq \frac{\beta M}{\pi M} = \beta/\pi$。

(iii) 由 (i)，被消费的关键命题占比 $\pi R \leq \beta$（必要性），且 $(1-\pi)\,\bar{\Phi}(z) = \beta - \pi R$，故 $z = \bar{\Phi}^{-1}\big(\frac{\beta - \pi R}{1-\pi}\big) = \Phi^{-1}\big(1 - \frac{\beta - \pi R}{1-\pi}\big)$。又 $R = \bar{\Phi}(z - d')$，即 $z - d' = \bar{\Phi}^{-1}(R) = -\Phi^{-1}(R)$（用对称性 $\bar{\Phi}(-x) = \Phi(x)$）。两式相减：$d' = \Phi^{-1}\big(1 - \frac{\beta - \pi R}{1-\pi}\big) + \Phi^{-1}(R)$。对 $R = 0.95$：$\Phi^{-1}(0.95) = 1.645$，$\Phi^{-1}(0.99697) \approx 2.74$，故 $d' \geq 2.74 + 1.645 = 4.39$。

充分性(单调性闭合):把阈值方程写成隐函数 $F(z, d') := (1-\pi)\bar{\Phi}(z) + \pi\bar{\Phi}(z - d') - \beta = 0$。$F$ 关于 z 严格递减且连续，故对每个 d' 存在唯一解 $z(d')$；由隐函数定理，

$$\frac{dz}{dd'} = -\frac{\partial F/\partial d'}{\partial F/\partial z} = \frac{\pi\,\varphi(z - d')}{(1-\pi)\,\varphi(z) + \pi\,\varphi(z - d')} \;\in\; (0, 1),$$

其中 φ 为标准正态密度。于是可达召回 $R(d') = \bar{\Phi}(z(d') - d')$ 满足

$$\frac{dR}{dd'} = -\varphi(z - d')\Big(\frac{dz}{dd'} - 1\Big) = \varphi(z - d')\big(1 - \tfrac{dz}{dd'}\big) \;>\; 0,$$

即给定预算 β，可达召回关于 d' 严格递增。故 $d' \geq \underline{d'}$ 时取阈值 $\tau = \mu_0 + \sigma\, z(d')$（消费恰占满预算 β），召回 $R(d') \geq R(\underline{d'}) = R$，达标。■

(iv) 代入数值；$\Phi^{-1}(0.99697) \approx 2.74$（附录 B.6 表）；AUC $= P(s_{\text{关键}} > s_{\text{非关键}}) = \bar{\Phi}(-d'/\sqrt{2})$ 的对称形式 $= \Phi(d'/\sqrt{2})$，$d'/\sqrt{2} = 3.10$，$\Phi(3.10) \approx 0.999$。■

注（敏感性与稳健性——恒等式的成立范围）。(a) **分布自由部分**：容量上限 (ii)（$R \leq \beta/\pi$）不依赖任何分布假设，是纯计数论证；(i)(iii) 的恒等式结构对任意位置—尺度族成立（d' 以共同尺度归一化），高斯假设只进入具体数值（4.39、AUC）；对重尾或偏态评分分布，同一 β, π, R 所需的分离度会不同，须用实测分布的尾函数替换 $\bar{\Phi}$ 重算。(b) **评分相关**：恒等式 (i) 是边际分布的陈述，条目间得分的相关性不影响边际阈值方程；但相关性会影响 top-m 选择的联合行为（同源拷贝挤占问题见推论 6.1(ii)，由去重处理）。(c) **参数误差**：$\underline{d'}$ 对其自变量局

部 Lipschitz；以一阶展开，$\partial \underline{d'}/\partial\beta = -1/\big[(1-\pi)\,\varphi(\Phi^{-1}(1-\frac{\beta-\pi R}{1-\pi}))\big] < 0$，$\pi$ 的估计误差按链式法则传播——π 或 β 的标定不确定度应换算成 $\underline{d'}$ 的置信带报告。(d) **动态** β：预算随时段变化时，恒等式逐点适用；预算冲击的实例见第 14.5 节压力测试 (g)。

定理 6.1 的三条解释学后果：

1. **文档级过滤在数学上不可行**：不做命题坍缩时，$\beta = 10/10^4 = 0.001$，$\pi = 0.01$（关键文档含冗余转载），容量上限 $R \le \beta/\pi = 0.1$——**无论评分多完美，召回至多 10%**。坍缩把 β 有效放大 ρ_c 倍（推论 6.1），这是命题中心架构的必要性证明。
2. **纯评分通道撑不起 95% 召回**：$d' \ge 4.39$（AUC ≈ 0.999）意味着评分器对"什么对主体关键"近乎全知。经验上 LLM 评分器对事实类判断已有可测错误率（第 16 节），对"主体相关性"的判断依赖 $g^{(2)}$ 声明的质量，$d' \in [1.5, 2.5]$ 是更现实的区间——由恒等式逐点计算，对应召回仅约 21%–52%。**≥95% 的关键召回不可能由评分单独实现**。
3. **召回保证必须来自架构**：监测信源类直通（第 7 节冗余覆盖定理：$P(\text{miss}) \le (1-p_{\min})^{k_{\text{eff}}}$，与 d' 无关）、监控清单直通（假设 R3，构造性归零）、公共议程层（第 12 节，冗余认证兜底）。评分通道的真实职责是**发现未被监测覆盖的关键命题 + 预算绑定时的价值排序**，其召回贡献由 d' 决定并诚实报告。

推论 6.1（命题坍缩的乘数效应）。记 m = 每期消费名额，N = 文档数，$M = N/\rho_c$ = 坍缩后命题数，K^* = 关键命题数，$\bar r$ = 关键命题的平均文档拷贝数（关键文档数 $= K^*\bar r$）。则：
(i)（文档粒度的召回上限）以文档为单位度量召回时，$R_{\text{doc}} \le \min\{1, \beta_d/\pi_d\} = \min\{1, m/(K^*\bar r)\}$；
(ii)（去重的可达性增益）命题召回的计数上限两种粒度同为 $\min\{1, m/K^*\}$，但**不去重时该上限不可达**：同一关键命题的拷贝得分高度相关（同源内容），top-m 评分选择会被重复拷贝挤占，期望覆盖不同命题数 $\approx m/\bar r_{\text{top}}$（$\bar r_{\text{top}}$ 为高分段平均冗余），可达召回 $\approx m/(\bar r_{\text{top}} K^*)$；去重后每个名额保证对应一个不同命题，可达召回 $= \min\{1, m/K^*\}$——坍缩把可达召回严格提升 $\bar r_{\text{top}}$ 倍；
(iii)（可行性与分离度需求的松弛）当 $\bar r \approx \rho_c$（关键事件获得与平均同比例的报道冗余）时 $\pi_p = K^*/M \approx \pi_d$、$\beta_p = m/M = \rho_c\beta_d$：定理 6.1(iii) 的可行性条件 $\beta \ge \pi R$ 被放松 ρ_c 倍，且所需分离度 $\underline{d'}(\beta, \pi, R)$ 关于 β 严格递减——坍缩同时放松容量上限与分离度需求。

证明。(i) m 个文档至多覆盖 m 个关键文档，关键文档总数 $K^*\bar r$；$\beta_d/\pi_d = (m/N)/(K^*\bar r/N) = m/(K^*\bar r)$。(ii) 计数上限显然（$m$ 个名额至多 m 个不同命题）；拷贝挤占论证：设某关键命题有 $\bar r_{\text{top}}$ 个拷贝进入高分段，则消耗 $\bar r_{\text{top}}$ 个名额只贡献 1 个命题的召回；去重（定义 4.2 的命题归并 κ）在架构上排除此浪费。(iii) $\pi_p = K^*/M = K^*\rho_c/N = \pi_d\rho_c/\bar r \approx \pi_d$（$\bar r \approx \rho_c$ 时）；$\beta_p = m/M = m\rho_c/N = \rho_c\beta_d$。$\underline{d'}$ 的单调性：$\underline{d'} = \bar\Phi^{-1}\big(\frac{\beta-\pi R}{1-\pi}\big) + \Phi^{-1}(R)$，$\bar\Phi^{-1}$ 严格递减，β 增大 ⇒ 其自变量增大 ⇒ $\underline{d'}$ 减小。■

命题 6.3（召回目标的预算可行性）。声明的召回目标 R 对 E^* 可达的必要条件是 $\mathbb{E}[|E^*|]\cdot R \le m - m_{\text{pub}} - m_{\text{slack}}$，其中 m_{pub} 为公共层占用（≤ 2）、m_{slack} 为意外关键命题预留。若违反，主体必须三选一：扩大 T、收缩 E^* 声明（修订 $g^{(2)}$ 关联的决策集）、或接受更低的 R。系统义务：检测到违反时向 R（反思层）发出**可行性冲突警报**而非静默降级。

证明。消费不同命题数 $\le m - m_{\text{pub}}$（预算划分）；被召回的关键命题数 $\le$ 消费数；取期望并用 $R\cdot\mathbb{E}|E^*| \le \mathbb{E}[\text{被召回关键数}]$。■

6.3 效用的次模性与贪心保证

设定。防火墙（第 9 节）先行剔除 $\hat m_i > \tau_m$ 的条目，故候选池内操控惩罚项有界；选择效用取

$$U(A) = \underbrace{\sum_{e\in E} v_e\,\mathbb{1}\{A\cap D_e \ne \emptyset\}}_{U_{\text{cov}}(A)\ \text{（覆盖效用）}} + \mu\ \underbrace{\sum_{\sigma\in\mathcal{S}} \max_{i\in A} \text{sim}(\sigma, i)}_{U_{\text{div}}(A)\ \text{（多样性：设施选址）}} - \lambda \sum_{i\in A} \hat m_i\,\tau_i,$$

约束 $\sum_{i\in A}\tau_i \le T_{\text{push}}$。这里 $\text{sim}\ge 0$ 为立场流形上的相似度核。

定理 6.2（单调次模性）。U_{cov} 与 U_{div} 均为单调次模集函数。关于 U 的单调性：记 $\mathcal{C}$ 为防火墙过滤后的候选池（有限：每日至多 N 条，前提 2）。对条目 $i\in\mathcal{C}$ 与语境 $A\subseteq\mathcal{C}\setminus\{i\}$，记 $g_i(A):=\big[U_{\text{cov}}(A\cup i)-U_{\text{cov}}(A)\big]+\mu\big[U_{\text{div}}(A\cup i)-U_{\text{div}}(A)\big]$ 为其覆盖 + 多样性合并边际增益，并定义 $\mathcal{X}^+:=\{i\in\mathcal{C}:\max_A g_i(A)>0\}$（至少在一个语境下边际增益为正的条目）。假设**一致正边际（M）**：存在 $\eta>0$，使对每个 $i\in\mathcal{X}^+$ 与每个 $g_i(A)>0$ 的语境 A 有 $g_i(A)\ge\eta$。（因 $\mathcal{C}$ 有限，集合 $\{g_i(A):i\in\mathcal{C},\ A\subseteq\mathcal{C},\ g_i(A)>0\}$ 是有限正实数集，故 (M) 自动成立、η 取其最小值；(M) 因此只是把边际显式化的记账装置，仅在连续候选空间中才成为真正的边际假设。η 的值在部署系统中可由当日候选池枚举计算，并按 S4 入日志。）若 $\lambda\max_i\hat m_i\tau_i<\eta$（防火墙残余惩罚小于边际），则沿每个正增益添加——即对每个 $i\in\mathcal{X}^+$ 与每个 $g_i(A)>0$ 的语境 A——U 的边际增益满足 $U(A\cup i)-U(A)=g_i(A)-\lambda\hat m_i\tau_i\ge\eta-\lambda\max_i\hat m_i\tau_i>0$；在此精确意义上 U 在 $\mathcal{X}^+$ 上单调，而定理 6.3 的贪心算法只做正增益添加，故其操作对象是单调次模目标。

注（单调性条件的精确含义）。边际增益为零的条目（其所涉命题已被覆盖且不带来新立场相似度）上，负模项 $-\lambda\hat m_i\tau_i<0$ 使 U 严格下降——故 U 在**整个**候选池上一般不单调。**次模性则从不成问题（v1.6 新增以示明确）**：$U_{\text{cov}}+\mu U_{\text{div}}$ 作为次模函数的非负加权和是次模的，惩罚项 $-\lambda\sum_i\hat m_i\tau_i$ 是**模函数**（对条目可加：所选集合的线性函数）；次模 + 模 = 次模，故**对一切 $\lambda\ge0$、无论惩罚多大，U 都是次模的**——这正是下文非单调回退方案无需任何额外核验即获许可的原因。这不妨碍贪心保证：贪心算法每步只选边际增益为正的元素，零/负增益条目（含全部 $\mathcal{X}^+$ 之外的条目）在任何最优解中都可无损失地剔除，问题等价于在 $\mathcal{X}^+$ 上的单调次模最大化。若残余惩罚不可忽略、或在连续候选空间中放弃 (M)，U 为**非单调次模**函数，Buchbinder, Feldman, Naor & Schwartz (2014) 的随机化双贪心在**无单调性要求**下仍给 $1/e$ 保证——定理 6.3 的保证随之以 $1/e$ 取代 $1-1/e$，作为无条件地板；本文按”防火墙先行使残余惩罚可忽略”的制度设计，并申报 $1/e$ 为无条件地板。

证明。

U_{cov}：单调性显然（$v_e\ge0$，加元素只增不减覆盖）。次模性：对 $A\subseteq B$、$i\notin B$，

$$U_{\text{cov}}(A\cup i)-U_{\text{cov}}(A)=\sum_{e:\,i\in D_e,\ A\cap D_e=\emptyset}v_e\ \ge\ \sum_{e:\,i\in D_e,\ B\cap D_e=\emptyset}v_e=U_{\text{cov}}(B\cup i)-U_{\text{cov}}(B),$$

不等号成立因为 $A\cap D_e=\emptyset\Leftarrow B\cap D_e=\emptyset$（$A\subseteq B$）：被 B 尚未覆盖的命题必被 A 尚未覆盖，反之不然。边际增益随集合增大不增，即次模性。

U_{div}：单调性显然（$\text{sim}\ge0$，max 随集合增大不减）。次模性：固定 σ，函数 $A\mapsto\max_{i\in A}\text{sim}(\sigma,i)$ 是加权覆盖函数的特例（把”命题 e“换成”立场点 σ“、”D_e“换成”与 σ 相似度剖面”），或直接验证：对 $A\subseteq B$、$i\notin B$，记简写 $m_A:=\max_{i'\in A}\text{sim}(\sigma,i')$、$m_B:=\max_{i'\in B}\text{sim}(\sigma,i')$，则 $m_A\le m_B$；于是加入 i 在上下文 A 中的边际增益减去在 B 中的边际增益为

$$\big[\max(\text{sim}(\sigma,i),m_A)-m_A\big]-\big[\max(\text{sim}(\sigma,i),m_B)-m_B\big]\ =\ (\text{sim}(\sigma,i)-m_A)^+-(\text{sim}(\sigma,i)-m_B)^+\ge0,$$

因为对任意 x,m 有 $\max(x,m)-m=(x-m)^+$，且 $a\mapsto(x-a)^+$ 关于 a 不增；故边际增益在较小上下文 A 中更大，这正是 $A\mapsto\max_{i\in A}\text{sim}(\sigma,i)$ 的次模性。对 σ 求和（权重 1）保持不等式。

单调性合成：负模项 $-\lambda\sum\hat m_i\tau_i$ 对单次添加的边际贡献 $\ge-\lambda\max_i\hat m_i\tau_i$；由 (M)，每个正增益添加的覆盖 + 多样性合并增益 $\ge\eta>0$（有限池上 η 是有限正数集的最小值，故达到且为正；相关度非零的条目至少贡献其覆盖价值，故 $\mathcal{X}^+$ 恰为可能有益的条目集）。当 $\lambda\max_i\hat m_i\tau_i<\eta$ 时每个正增益添加都使 U 增加，此即贪心论证所用的单调性。■

定理 6.3（贪心近似保证）。(i)（等成本情形，$\tau_i\equiv\tau$，基数约束 $|A|\le m$）标准贪心（每步选边际增益最大者）输出 A_g 满足

$$U(A_g)\ \ge\ \Big(1-\frac{1}{e}\Big)\,U(A^*)\ \approx\ 0.632\,U(A^*),$$

A^* 为最优解。完整证明见附录 B.4（Nemhauser, Wolsey & Fisher, 1978）。

(ii)(不等成本,背包约束)密度贪心与最优单元素解取较优者达到 $\frac{1}{2}(1-1/e)\approx 0.32$(folklore, 证明见 Leskovec et al., 2007)；**部分枚举 + 密度贪心**恰好达到 $1-1/e$（Sviridenko, 2004——其方法是枚举常数个元素后对残余背包做密度贪心，而非连续贪心)；连续贪心 + 舍入框架见 Călinescu, Chekuri, Pál & Vondrák (2011)（拟阵约束达 $1-1/e$，背包约束经枚举归约)。对本文特例——预算约束下的最大覆盖——Khuller, Moss & Naor (1999) 的（枚举增强）密度贪心已达 $1-1/e$。

工程含义：选择层不需要（也不可能）精确求解 NP 难的背包次模最大化；多项式时间贪心已有常数比保证，且贪心的每步边际增益天然生成 S4 要求的可审计解释（“这条被选因为它的边际覆盖价值最高”)。

6.4 动态选择与阈值型最优策略

静态贪心处理”一批候选”；真实 push 流是**在线到达**的。本节给出在线情形的最优策略结构。

设定（简化但严格)。n 期离散时间，每期至多一个条目到达；到达条目的评分 $s\sim F$ i.i.d.（分布已知或由历史估计)；消费收益 $r(s)$ 严格递增连续；每条消费成本一个”名额”(等时间成本情形)，总名额 b。到达时主体观察 s，即时决定消费或放弃（放弃不可恢复；延期见下文注)。

命题 6.4（阈值型最优策略)。记 $W_i(b)$ 为”剩余 i 期、剩余名额 b “的最优继续值。则：

(i)(Bellman 方程)$W_i(b)=\mathbb{E}_s\big[\max\{r(s)+W_{i-1}(b-1),\,W_{i-1}(b)\}\big]\,(b\ge 1)$,$W_i(0)=0$, $W_0(b)=0$。

(ii)（阈值形式）最优策略为阈值策略：当期消费当且仅当 $r(s)\ge \tau_i(b):=W_{i-1}(b)-W_{i-1}(b-1)$。阈值 $\tau_i(b)$ 是剩余名额的机会成本（影子价格)，关于 b 单调不增，关于剩余期数 i 单调不减。

(iii)（W 的凹性）$W_i(\cdot)$ 关于 b 凹，故影子价格随名额消耗而上升——预算越紧，阈值越高。

证明。(i) 标准 DP 分解（当期到达独立于未来到达)。(ii) r 严格递增 $\Rightarrow \{s: r(s)\ge\tau\}$ 是上区间 $\Rightarrow$ 阈值形式；消费优于放弃当且仅当 $r(s)+W_{i-1}(b-1)\ge W_{i-1}(b)$，移项即得阈值 $\tau_i(b)=W_{i-1}(b)-W_{i-1}(b-1)$。

(iii) 记 $\Delta_i(b):=W_i(b)-W_i(b-1)$（即 $\tau_{i+1}(b)$)，$g(\tau):=\mathbb{E}[(r(s)-\tau)^+]$。由 (i),

$$W_i(b)=W_{i-1}(b)+g\big(\Delta_{i-1}(b)\big),\qquad \text{故}\qquad \Delta_i(b)=\Delta_{i-1}(b)+g\big(\Delta_{i-1}(b)\big)-g\big(\Delta_{i-1}(b-1)\big).$$

对 i 归纳证明 $\Delta_i(b)$ 关于 b 不增（即 W_i 凹)。基础：$\Delta_0\equiv 0$。归纳步：设 Δ_{i-1} 不增，取 $x=\Delta_{i-1}(b-2)\ge y=\Delta_{i-1}(b-1)\ge z=\Delta_{i-1}(b)$。使用 g 的三条性质，每条都直接由定义证明、不求导：**(a)** $g\ge 0$（非负部分的期望)；**(b)** g 不增（$\tau_1\le\tau_2$ 时 $(r-\tau_1)^+\ge(r-\tau_2)^+$ 逐点成立)；**(c)** g 为 **1-Lipschitz**：对任意 τ_1,τ_2，逐点有 $\big|(r(s)-\tau_1)^+-(r(s)-\tau_2)^+\big|\le|\tau_1-\tau_2|$（对每个 c，映射 $t\mapsto(c-t)^+$ 为 1-Lipschitz)，取期望保持该界。由递推式，

$$\Delta_i(b-1)-\Delta_i(b)\;=\;(y-z)+\big[g(y)-g(x)\big]+\big[g(y)-g(z)\big].$$

第一括号由 (b) 非负(因 $y\le x$)。对其余部分,(c) 给出 $g(y)-g(z)\ge-|g(y)-g(z)|\ge-(y-z)$, 故 $(y-z)+[g(y)-g(z)]\ge 0$。两个非负组相加得 $\Delta_i(b-1)-\Delta_i(b)\ge 0$, 归纳闭合。**注（已存档的替代路线)**。凹性步骤的中值定理版本（含显式 ξ_1/ξ_2 记账）曾载于 v1.3–v1.5；上文的 1-Lipschitz 路线取代它成为证明的唯一路线，因为它既不需要中值点、也不需要 g 的可微性（性质 (c) 本身即 $|g'|\le 1$ 的免积分内容)。存档推导保留在项目仓库的版本史中，刻意不在此复现，以确保证明只携带一条论证线。故 Δ_i 不增，W_i 关于 b 凹，且阈值 $\tau_i(b)=\Delta_{i-1}(b)$ 关于 b 不增。**非负性（W 关于 b 单调)**：由递推式与 $g\ge 0$、g 递减及归纳所得的 $\Delta_{i-1}(b)\le\Delta_{i-1}(b-1)$, 有 $\Delta_i(b)=\Delta_{i-1}(b)+g(\Delta_{i-1}(b))-g(\Delta_{i-1}(b-1))\ge\Delta_{i-1}(b)$；结合基例

$\Delta_0 \equiv 0$ 得 $\Delta_i(b) \geq 0$ 对一切 i, b 成立——多一个名额的期权价值非负。同时上式即 $\Delta_i(b) \geq \Delta_{i-1}(b)$：每名额的机会成本随剩余期数增多而上升——未来机会更多，放弃的期权价值更高。■

注（延期期权与冷却队列）。允许把条目放入容量有限的**冷却队列**（价值按新颖度衰减 $v(t) = v_0 e^{-\gamma t}$）等价于给放弃决策增加一个中间选项：策略变为三元选择（消费/延期/丢弃），最优结构仍是双阈值形式（消费阈 τ^c、延期阈 $\tau^d < \tau^c$：边际价值介于”现在消费的影子价格”与”未来消费的期望影子价格 × 衰减”之间的条目进入队列）。证明是命题 6.4 的状态扩展（增加队列占用维），结构不变；完整处理留待阶段二算法论文。工程含义：冷却队列是期权，其价值在信息价值快速衰减的环境（新闻）中低、在慢衰减环境（研究文献）中高。

6.5 双通道架构原则（本章综合）

定义 6.2（双通道架构）。主权过滤器的选择层由两个通道并联构成：

- **通道 I（保证通道 / 直通）**：监测信源类内容 + 监控清单实体内容，绕过竞争排序，去重后必达（预算可行性由命题 6.3 监控）。召回保证来自第 7 节的冗余覆盖定理，**与评分分离度 d' 无关**；
- **通道 II（发现通道 / 评分）**：其余候选按 $\langle w, \phi \rangle$ 评分竞争剩余名额，承担”发现未监测关键命题”与”预算绑定时的价值排序”。其召回贡献由定理 6.1 精确刻画：随 d' 与 β 增，且在极端过滤比下有硬上限。

架构原则（定理 6.1 + 第 7 节的合取推论）：高召回是结构性质，不是评分性质。任何以”更聪明的排序”替代”更完备的直通结构”的激进过滤设计，在 $d' < \underline{d'}(\beta, \pi, R)$ 时必然漏报。由此，“关键召回 ≥95%”这类指标只能挂在架构名下（直通结构的覆盖保证 + 评分通道的诚实贡献），而不能挂在评分函数名下——这是本文全部分工设计的定理级根据。

图 2 双通道架构与召回保证的分工：

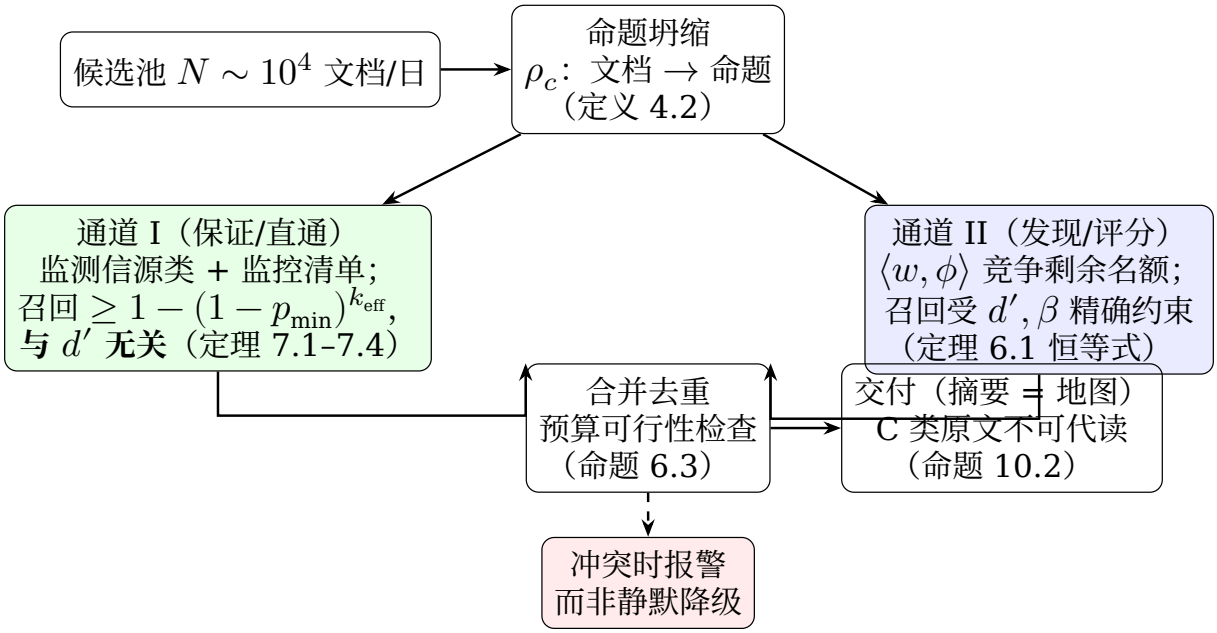


图 2: 双通道架构：通道 I 的召回保证来自冗余覆盖结构（与评分分离度无关），通道 II 的召回贡献由分离度恒等式诚实定价；瓶颈定理（定理 6.1）证明分工是数学必然而非工程偏好。

7 冗余覆盖定理：激进过滤召回的结构条件与适用域

通道 I（保证通道）的召回保证由本章提供。核心洞察：重要信息在信源空间上是**冗余**的——一个关键命题几乎必然被多个相互独立的信源类覆盖。因此”只保留少数可信信源类的全部内容”这一极端激进的过滤，对关键命题仍保持可证明的高召回。本章给出：(a) 独立情形的完整证明；(b) 相关情形的**独立子集界**及其**紧性**；(c) 监测名额分配的对偶优化问题；(d) 总召回定理；(e) **适用域边界**——本章保证的强度条件性地依赖于覆盖下界 $p_{\min}$ 的来源，两个域的真实语料试点给出了这张地图的第一版（§7.5、§7.7）。

7.1 假设

- **R1（覆盖下界）**：对每个被监控的可信信源类 $\mathcal{C}_i$ $(i = 1, \dots, k)$ 与每个关键命题 $e \in E^*$：$P(Z_i(e) = 1) \geq p_{\min}$，其中 $Z_i(e)$ 为定义 4.4 的覆盖事件。经验含义：可信信源类对关键命题的报道率有正下界；$p_{\min}$ 须由历史语料实测标定（第 14 节），保守先验 $p_{\min} = 0.7$。
- **R2（条件独立）**：给定命题 e 的关键性，覆盖事件 $\{Z_i(e)\}_{i=1}^k$ 相互独立。现实偏离：共同通讯社上游、媒体间转载网络造成正相关。缓解：信源类按（所有权 × 地域 × 类型）划分以构造性地压低类间相关（定义 4.4）；残余相关由定理 7.2 显式定价。
- **R3（直通规则）**：π_{mon} 中的监控清单实体（主体显式声明的公司、机构、议题、人物）的全部内容绕过评分，仅去重后必达。

7.2 独立情形

定理 7.1（冗余覆盖，独立情形）。在 R1–R2 下，仅保留 k 个监控信源类内容（去重后直通）的过滤器，对任意关键命题 $e \in E^*$ 的漏报概率满足

$$P(\text{miss}\, e) \;\leq\; (1 - p_{\min})^k.$$

证明。命题 e 被漏报当且仅当其全部文档均未被消费。通道 I 消费监控类的全部（去重）内容，故漏报 $\iff$ 无监控类覆盖 e $\iff$ $\bigcap_{i=1}^k \{Z_i(e) = 0\}$。由 R2（条件独立）与 R1 $(P(Z_i = 0) \leq 1 - p_{\min})$：

$$P(\text{miss}\, e) = P\Big(\bigcap_{i=1}^k \{Z_i(e) = 0\}\Big) = \prod_{i=1}^k P(Z_i(e) = 0) \leq (1 - p_{\min})^k. \qquad \blacksquare$$

数值：$p_{\min} = 0.7$，$k = 5 \Rightarrow P(\text{miss}) \leq 0.3^5 = 2.43 \times 10^{-3}$，即关键召回 $\geq 99.76\%$；即使 $p_{\min} = 0.5$、$k = 4$，仍有 $P(\text{miss}) \leq 6.25 \times 10^{-2}$。**这是独立情形（R2 精确成立）下的演示性数值，不是普遍保证**：$p_{\min}$ 必须实测标定（估计流程见 §7.5 与 §14.7，并应报告置信区间），相关情形须换用定理 7.2 的 k_{eff} 界；学术域试点的实测 $\hat{p}_{\min} \approx 0.02$ 就是 R1 失败的实例（§7.7）。在此前提下：丢弃 99% 的文档与保住 99% 的关键召回完全兼容——只要保留的那 1% 是”按信源类冗余覆盖”结构化选出的，而非按分数竞争选出的。（对照定理 6.1：后者需要 $d' \geq 4.39$。）

7.3 相关情形：独立子集界及其紧性

R2 在现实中只是近似。本小节给出对**任意依赖结构**都成立的上界，代价是把指数从 k 降为”有效独立类数”。

定义 7.1（有效独立类数）。对固定关键命题 e，称子集 $S \subseteq [k]$ 是 **e-独立的**，若 $\{Z_i(e)\}_{i \in S}$ 相互独立。定义

$$k_{\text{eff}}(e) := \max\{|S| : S \subseteq [k] \text{ 是}e\text{-独立的}\}, \qquad k_{\text{eff}} := \min_{e \in E^*} k_{\text{eff}}(e).$$

定理 7.2（冗余覆盖，相关情形）。在 R1 下（不假设 R2），对任意关键命题 e：

$$P(\text{miss}\, e) \;\le\; (1-p_{\min})^{k_{\text{eff}}(e)} \;\le\; (1-p_{\min})^{k_{\text{eff}}}.$$

证明。取 e-独立子集 S^* 达到定义 7.1 的最大基数，$|S^*| = k_{\text{eff}}(e)$。事件包含关系：全体 k 类都不覆盖 $\subseteq S^*$ 中的类都不覆盖，即

$$\{\text{miss}\, e\} = \bigcap_{i=1}^{k} \{Z_i(e) = 0\} \;\subseteq\; \bigcap_{i \in S^*} \{Z_i(e) = 0\}.$$

由概率单调性与 S^* 上的独立性：

$$P(\text{miss}\, e) \le P\Big(\bigcap_{i\in S^*}\{Z_i(e)=0\}\Big) = \prod_{i\in S^*} P(Z_i(e)=0) \le (1-p_{\min})^{|S^*|}. \qquad \blacksquare$$

命题 7.1（紧性）。定理 7.2 的界在无进一步假设下不可改进：对每个 $k_{\text{eff}} \in \{1, \dots, k\}$，存在满足 R1 的依赖结构使 $P(\text{miss}\, e) = (1-p_{\min})^{k_{\text{eff}}}$。

证明。构造：取 k_{eff} 组相互独立的类，组内各 Z_i 完全相关（共享同一潜伯努利变量：同组媒体共用同一通讯社上游，$Z_i \equiv Z_{\text{group}}$，$P(Z_{\text{group}} = 1) = p_{\min}$）；组间独立。则 k_{eff}（定义 7.1 意义下）恰为组数，且 $P(\text{miss}) = P(\text{所有组都不覆盖}) = (1-p_{\min})^{k_{\text{eff}}}$，取等。$\blacksquare$

工程含义：(a) 界的质量完全由 k_{eff} 决定，而 k_{eff} 可通过信源类的分组设计（所有权、地域、类型、通讯社上游）主动做大——**独立性不是自然馈赠，是架构产物**；(b) k_{eff} 可由历史语料实测：对已知关键命题集，估计各类覆盖指示变量的相关矩阵，求极大独立子集（保守：对相关系数 $|\rho_{ij}| > \epsilon_c$ 的类对做并查集合并，合并后的组数即 k_{eff} 的下界估计）；(c) 协同造假（astroturfing）攻击的实质是伪造独立性——多个”独立”信源实为一个行动者。防御：溯源树根节点核查（I3）+ 所有权穿透 + 内容指纹聚类（第 14 节压力测试）。

7.4 监控清单直通与尾部风险归零

命题 7.2（直通规则的构造性归零）。在 R3 下，对监控清单实体的任何命题 e：$P\big(\text{miss}\, e \;\big|\; \text{实体发布了关于} e \text{ 的内容}\big) = 0$。即过滤环节引入的漏报为零；残余风险仅为”实体自身沉默”，这对任何过滤器都不可约。

证明。R3 规定清单实体内容绕过评分、去重后必达；预算可行性由命题 6.3 监控（冲突时报警而非静默丢弃）。故只要内容存在且通过溯源验证（防伪冒实体，I3），即被消费。$\blacksquare$

敏感性讨论（R1 弱点的显式处理）：定理 7.1–7.2 的软肋在 R1——**小众但对个人关键的命题不具信源冗余**（$P(Z_i(e)=1)$ 对多数类接近 0）。三层兜底：(1) R3 直通把”主体能预见的”长尾风险构造性归零——这正是”主动获取”对”被动过滤”的补位：监控清单是主体主动声明的 $g^{(2)}$ 投影；(2) 公共议程层（第 12 节）为”主体未预见但公共重大”的事件提供第二兜底（冗余认证的命题强制进入所有人视野）；(3) 评分通道 II 承担概率性发现（召回贡献由 d' 诚实定价）。三层之外仍有不可约残余：既无可信冗余信源、又未声明、又非公共重大、评分又未发现的命题——本文不假装它为零，而是把它列入第 13 节 P4 的实测审计项。

7.5 对偶问题：监测名额分配

主动获取侧的第一个决策：**监测哪些信源类？** 名额有限（预算约束 m_{mon}、直通配额约束），候选类多于名额，须择优。

定义 7.2（概率覆盖效用）。候选类集合 $\mathcal{K}$，选择 $S \subseteq \mathcal{K}, |S| \le B$（或成本约束 $\sum_{i\in S} c_i \le B$）。关键命题 e 有先验权重 w_e（由 $g^{(2)}$ 声明的决策集导出）与类覆盖概率 $p_i(e) := P(Z_i(e) =$

1)。定义

$$U_{\text{mon}}(S) := \sum_{e \in E^*} w_e \cdot P\big(e \text{ 被} S \text{ 中至少一类覆盖}\big) \;=\; \sum_{e} w_e \Big(1 - \prod_{i \in S} \big(1 - p_i(e)\big)\Big)$$

（第二个等号用 R2 类间独立；相关情形的保守版本见注）。

定理 7.3（监测分配的次模性与贪心保证）。U_{mon} 单调次模。故：基数约束下贪心（每步加入边际增益最大的类）达到 $(1 - 1/e) \approx 63.2\%$ 最优；成本约束下密度贪心与最优单类取较优者达到 $\frac{1}{2}(1 - 1/e)$（folklore，见 Leskovec et al., 2007），部分枚举 + 密度贪心达到 $1 - 1/e$（Sviridenko, 2004）。

证明。单调性显然（每个因子 $1 - \prod(1 - p_i)$ 随 S 增大不减，$w_e \geq 0$）。次模性：固定 e，记 $q_i = 1 - p_i(e) \in [0, 1)$，$f_e(S) = 1 - \prod_{i \in S} q_i$。对 $A \subseteq B$、$j \notin B$：

$$f_e(A \cup j) - f_e(A) = \Big(\prod_{i \in A} q_i\Big)(1 - q_j) \;\geq\; \Big(\prod_{i \in B} q_i\Big)(1 - q_j) = f_e(B \cup j) - f_e(B),$$

因 $\prod_{i \in A} q_i \geq \prod_{i \in B} q_i (q_i \leq 1)$。加权求和保持次模性。贪心保证引用附录 B.4 与 Sviridenko (2004)、Leskovec et al. (2007)。■

注（相关情形）。若类间正相关，真实的 $P(\text{至少一类覆盖})$ 低于独立公式，但定理 7.2 的独立子集方法同样适用：以 k_{eff} 个独立组为单位做贪心；组内选择退化为组代表的选择。协同造假使”伪独立组”虚增 U_{mon}——防御见 7.3(c)。

与 Pandora 盒子的衔接：定理 7.3 解决”已知类中选谁监测”；**类质量未知时的探索**（订阅试错）是第 8.3 节的 Pandora 问题——两者构成监测清单生命周期的”探索 → 准入 → 审计 → 撤换”闭环。

实证发现 E-7.1（$\widehat{p}_{\min}$ 的内生性；学术域试点）。研究者画像 × arXiv 2019-09 真实语料时序重放（监测宇宙 2576 命题；关键集 E^* = 当月 top-2% 被引论文，$K^* = 52$；实验细节见 §14.7）首次实测了清单构建策略对覆盖率的决定作用：作者粒度清单（前窗频次或引用排名 top-50）对当月关键论文的覆盖仅 1/52（$\widehat{p}_{\min} \approx 0.02$）——ALBERT、Megatron-LM 等最重要论文的作者在前窗排名 1500 名开外；机构粒度清单（top-50 强实验室）$\widehat{p}_{\min} = 0.37$，top-10 精简清单 $\widehat{p}_{\min} = 0.17$ 且供给与预算适配。**结论：R1 的 $p_{\min}$ 不是环境常数，而是清单粒度与容量的设计函数**——监测清单的构建本身就是 pull 侧的优化问题（定理 7.3 的次模贪心 + 命题 8.1 的准入判据应联合求解，而非 top-N 启发式）；低冗余画像的通道 I 收益上限由容量—覆盖曲线的边际递减决定（实测清单规模 10→400 时覆盖仅 0.17→0.46（清单覆盖率 $\widehat{p}_{\min}$ 的实测上限，非端到端召回——该配置供给远超预算，配额稀释使端到端召回反而更低））。注意此处真值代理的局限：top-2% 被引是滞后多年且带声望偏差的事后指标，按本文自身框架更接近”学术参与度”而非事前关键性——§14.7 给出该代理的敏感性讨论。

实证发现 E-7.2（$p_{\min}$ 的制度来源与 $\mathbf{d'}$ 双真值分裂；金融域试点）。投资者画像 × EDGAR + 公开新闻存档 2019-09 重放（双真值：法定重大 8-K 与市场移动日；实验细节见 §14.7）给出适用域地图的另一半：(a) $p_{\min}$ **可以有制度性来源**：监管一手信源类对法定真值（重大 8-K）的覆盖 $\widehat{p}_{\min} = 1.00$——8-K 四日申报规则把覆盖保证写进了法律；对市场真值 $\widehat{p}_{\min} = 0.70$–$0.73$（随新闻层版本，见表 14-3 口径对照），通讯社类再补约 0.25–0.27 的独立覆盖——**多类冗余结构（$k_{\text{eff}} \geq 2$）首次在真实数据上可测**；(b) **诚实特征评分器的 $\mathbf{d'}$ 按真值分裂**：法定关键性可从披露元数据预测（$d' = 2.65$–3.49，随特征集版本），市场关键性仅部分可由真实注意力信号预测（$d' = 0.54$–0.60）——两者都远低于 95% 召回需求线（≈4.4），市场维度的关键性**主要**由结构承载，这是定理 6.1 论点在第二个域的独立确认；(c) **高召回强形式在其条件齐备时成立**：组合持仓直通（25 家持仓、供给 4.6 命题/日）在配额适配的条件下，组合内市场真值召回随预算爬升：$m = 1$ 时 0.444 → $m = 5$ 时 0.952（达标）；新闻层扩充后同一设置稀释至 0.910（公司-日的新闻命题分走配额——“逼近但未越线”，兑现需配额上调或清单内排序增强）。与学术域（同框架同方法下强形式被拒绝，最优端到端召回 0.28）对照，得到第一条经验规律：**召回保证强度 = $p_{\min}$ 的制度来源（法律 > 媒体冗余 > 清单设计）× 供给—配额适配 × E^* 作用域与画像决策集的一致性**。同样注意真值代理局限：市场移动日是事

后标签，且 90% 的市场移动日不可归因于当日信息——“对市场移动日的召回”不等于”对事前关键信息的召回”，§14.7 给出第二真值与敏感性分析。

7.6 总召回定理

定理 7.4（总召回下界）。设通道 I 按 7.2–7.4 配置；通道 II（评分发现）在通道 I 失败的条件下对非清单关键命题以条件概率 $R_{\text{II}} := P(\text{II 补获} \mid \text{I 失败})$ 补获（R_{II} 由定理 6.1 的 d', β 决定，且对清单实体 $e \in \text{WL}$ 无定义必要——直通已保证）。则在 R1、R3 下，对任意 $e \in E^*$：

$$P(\text{miss}\, e) \;\le\; (1 - p_{\min})^{k_{\text{eff}}} \cdot \big(1 - R_{\text{II}}\, \mathbb{1}\{e \notin \text{WL}\}\big),$$

特别地，无条件上界 $P(\text{miss}\, e) \le (1 - p_{\min})^{k_{\text{eff}}}$ 成立。

证明。漏报要求两条通道同时失败。对 $e \notin \text{WL}$，按条件概率链式法则（R_{II} 即按”通道 I 失败”条件定义，故无需独立性假设）：

$$P(\text{miss}\, e) = P(\text{I 失败}) \cdot P(\text{II 失败} \mid \text{I 失败}) = P(\text{I 失败})\,(1 - R_{\text{II}}) \le (1 - p_{\min})^{k_{\text{eff}}}(1 - R_{\text{II}}),$$

第一因子的界由定理 7.2。对 $e \in \text{WL}$，命题 7.2 给 $P(\text{I 失败}) = 0$，漏报概率为零。无条件界由 $R_{\text{II}} \ge 0$。■

注（R_{II} 的可计算性与选择偏差）。定理 6.1 给出的是评分通道对**全体**关键命题的召回（作为 d', β, π 的函数），而 R_{II} 是对”通道 I 失败”这一**选定子集**的条件召回。两者一般不等：通道 I 失败的命题系统性偏向低冗余、低覆盖类型，其可评分特征（新闻量、来源声望）也偏弱，故 R_{II} 通常**低于**定理 6.1 的无条件召回——直接把后者代入本定理会高估总召回。本文因此只把无条件上界 $P(\text{miss}\, e) \le (1 - p_{\min})^{k_{\text{eff}}}$ 作为定理级保证，R_{II} 作为实测项处理（第 14 节仿真直接估计该条件概率）。

KPI 落地：仿真与合成生态（第 14 节）直接测量 $P(\text{miss})$ 并对照 $(1 - \hat{p}_{\min})^{\hat{k}_{\text{eff}}}$；**真实语料重放**（§14.7）以官方事件清单/辟谣存档为真值精确测量漏报（H4’）；人类评审团审计保留在暂缓的 L3 设计（§15.5）中。

7.7 适用域边界与主张校准（诚实总结）

本章定理的强度与其自身试点证据之间的关系，必须按如下口径理解——这是全文经验主张的中枢校准：

1. **定理保证是条件性的**。$P(\text{miss}) \le (1 - p_{\min})^{k_{\text{eff}}}$ 的数值安慰（如 $p_{\min} = 0.7, k = 5 \Rightarrow 99.76\%$）来自 R1 的全称量化（对**任意** $e \in E^*$ 有 $P(Z_i) \ge p_{\min}$）。试点显示 $\hat{p}_{\min}$ 是清单粒度与容量的强函数：作者粒度清单低至 $\hat{p}_{\min} \approx 0.02$，此时 $(1 - \hat{p}_{\min})^k$ 界真空（$0.98^5 \approx 0.90$）；唯一 $\hat{p}_{\min} = 1.00$ 的来源是 8-K 四日申报规则这样的**法律制度**，而非框架本身。
2. **两种诚实的读法，本文取第二种**。(a) 把 E^* 限定为”冗余覆盖关键命题”——这会让定理接近重言式（“被很多信源覆盖的命题不会被漏掉”）；(b) 保留一般 E^*，把本章读作**加权/期望形式的泄漏界**：以定义 7.2 的 U_{mon} 为度量，清单 S 的期望加权泄漏为 $\sum_e w_e \prod_{i \in S}(1 - p_i(e))$，逐命题的覆盖概率 $p_i(e)$ 全部实测标定——这正是 §7.5 对偶问题的用途，也是定理 7.3 贪心保证的正确使用场景。本文的部署形态（清单构建 = 次模优化 + 配额可行性报警 + 命题 6.3 的可行性审计）按读法 (b) 设计。
3. **“≥95% 关键召回”的正确表述**：在 $p_{\min}$ 的制度来源、有效独立类数 k_{eff}、清单—预算配额适配、E^* 作用域与画像决策集一致性四者齐备的条件组合下可达（金融域组合范围内实测 0.952）；在条件不齐备的域（学术域）被真实数据拒绝（最优 0.28），精确化为边界条件。第 14 节的全部召回数字按此口径报告。

4. **超出陈述假设的鲁棒性台账（非高斯关键性、重尾、相关覆盖、相关评分）**。(i) 定理 7.1–7.2 的分布自由性：覆盖事件是 Bernoulli 的；界只依赖各类覆盖概率与独立性结构，**全程没有**高斯性或轻尾假设。重尾关键性（§14.1 的 Pareto 指数 α）只通过 $p_{\min}$ 的**估计**进入界；漏报界关于 $1-p_{\min}$ 单调，故唯一危险的误差方向是高估 $p_{\min}$——因此置信调整形态即部署形态：每类 n 次类覆盖观测下，以 Clopper–Pearson 下界 p_L（水平 $1-\alpha$）替代 $\hat{p}_{\min}$，则 $P(\text{miss}) \le (1-p_L)^{k_{\text{eff}}}$ 是 $1-\alpha$ 置信陈述；试点效应量表同时报告 p_L 与 $\hat{p}_{\min}$。(ii) 相关覆盖在**任意**相关结构下由定理 7.2 定价：k_{eff} 是保证覆盖事件独立的最大类子集大小；相关性冲击压力测试 §14.5(a) 测量共享上游合并下 k_{eff} 的退化，按所有权/地域/类型分组重构是设计内的修复。(iii) 瓶颈（定理 6.1）的评分分布鲁棒性：数值线 $d' \ge 4.39$ 是高斯特化；其**分布自由**内容是以真实类条件分布 P_0（非关键）、P_1（关键）写出的分位数判据：阈值 z 下召回 R、消费率 β 要求 $P_1(s>z)=R$ 且 $P_0(s>z)=(\beta-\pi R)/(1-\pi)$；故 $\beta = 1.25\pi$ 下 95% 召回可达**当且仅当** $P_0\big(s > Q_1(0.95)\big) \le (\beta - 0.95\pi)/(1-\pi) = 0.00303$（$Q_1$ 为关键评分的分位函数）——即捕获 95% 关键质量的阈值上方至多留 0.303% 的非关键质量。高斯评分、分离度 d' 下该式估值为 $d' \ge 4.39$；重尾或偏态评分下按各自分位数估值，而定性论题——**极端过滤比下召回由评分分布的尾重叠承担，而非评分器质量**——不变；两域两真值的实测分离度（d' 0.54–3.49）在两种估值下都远不达线。(iv) $p_{\min}$ 的制度来源是召回保证的核心边界，而非附属说明：法律（$\hat{p}_{\min}=1.00$）> 媒体冗余（0.70–0.73）> 清单设计（0.02–0.37），本文每条召回主张的强度排序恰为此来源排序（E-7.1/E-7.2）；任何部署期的高召回主张必须先声明其 $p_{\min}$ 的来源。

---

8 主动获取（pull）理论与注意力无套利定理

本章回答第三个追问："过滤之外，还该主动抓取什么、抓多少、何时停?"第 2.7 节梳理的经典传统（搜索、觅食、实验设计、bandit、最优停止）在此被接入 SAP 的 pull 侧，并由**注意力无套利定理**（定理 8.1）与 push 侧、反思负荷置于同一个影子价格之下。需要说明：定理 8.1 在数学上是凹规划 KKT 条件的直接应用，其价值不在推广经典结果，而在于**指出边际价值定理、Pandora 停止规则与消费阈值是同一变分原理的共同特例**，从而把 push/pull/反思的预算分配组织为一个可在线估计的控制问题。

8.1 pull 算子空间

定义 8.1（pull 算子）。主动获取策略 π_{pull} 在每期选择三类算子的组合：

- **探索算子** e：对候选信源 $s \notin \pi_{\text{mon}}$ 的试用性投入（阅读其历史内容、小样本订阅），成本 c_e（分钟），收益为随机变量 X_s（该信源进入监测后的期望日 VOI，估计含噪）；
- **查询算子** q：针对性检索（关键词、横向阅读、数据库查询、向 AI 智能体下达子任务），成本 c_q，收益为该查询对决策集 D 与知识状态 K 的期望信息增益 $\text{EIG}(q \mid K)$；
- **停留算子**：对已订阅信源（补丁）的持续阅读，停留（dwell）时长 t，累积收益 $G_s(t)$（凹：头几条捕获主要价值，边际递减）。

每期的 pull 总成本 $c(\pi_{\text{pull}}) = \sum c_e + \sum c_q + \sum t$ 计入预算恒等式 $T = T_{\text{pull}} + T_{\text{push}} + T_{\text{ref}}$。

8.2 注意力无套利定理

设定。把预算 T 分配给 U 种用途（push 消费、各类 pull 算子、反思），用途 u 分得 $x_u \ge 0$ 分钟，产生期望价值 $V_u(x_u)$。假设：

- **(P1) 凹性**：V_u 递增、凹、连续可微。经济根据：冗余——一个信源的头几条内容捕获其大部分价值（覆盖效用的次模性在期望意义上的体现）；查询的边际 EIG 递减（定理 8.2 的次模性）；反思的边际德性增益递减（第 10 节的漂移结构）。
- **(P2) 可分性**：$V(x) = \sum_u V_u(x_u)$（用途间无交互）。理想化：互补性（检索结果改变 push 评分的新颖度基准）确实存在，作为二阶项处理；仿真（第 14 节）含交互压力测试。

定理 8.1（注意力无套利 / 边际 VOI 均衡）。在 (P1)–(P2) 下，预算分配 $x^* = (x_u^*)$ 最优（$\sum_u x_u^* = T$，$x_u^* > 0$ 对内点用途）当且仅当存在 $\nu > 0$（预算影子价格）使

$$V_u'(x_u^*) = \nu, \qquad \forall u(\text{内点}) \; ; \qquad V_u'(0) \le \nu, \; \forall u(\text{角点} x_u^* = 0) \; .$$

推论（无套利原则）：若存在两种用途 u, u' 使 $V_u'(x_u) > V_{u'}'(x_{u'})$，则把 ϵ 分钟从 u' 移到 u 产生一阶增益 $\epsilon\,(V_u' - V_{u'}') + o(\epsilon) > 0$——任何边际 VOI/分钟不相等的分配都不是最优，且改进方向与幅度可实测估计。

证明。必要性：设 x^* 最优且存在内点用途 u, u' 使 $V_u'(x_u^*) > V_{u'}'(x_{u'}^*)$。取 $\epsilon > 0$ 充分小，令 $x_u' = x_u^* + \epsilon$、$x_{u'}' = x_{u'}^* - \epsilon$、其余不变（可行性：内点 + 预算守恒）。由可微性，

$$V(x') - V(x^*) = \big[V_u(x_u^* + \epsilon) - V_u(x_u^*)\big] + \big[V_{u'}(x_{u'}^* - \epsilon) - V_{u'}(x_{u'}^*)\big] = \epsilon\big(V_u'(x_u^*) - V_{u'}'(x_{u'}^*)\big) + o(\epsilon) > 0$$

对充分小 ϵ 成立，与最优性矛盾。角点条件同理（若 $V_u'(0) > \nu = V_{u'}'(x_{u'}^*)$ 则移入正增益）。充分性：设存在 ν 使条件成立。对任意可行 x，由凹性 $V_u(x_u) \le V_u(x_u^*) + V_u'(x_u^*)(x_u - x_u^*)$，求和：

$$V(x) - V(x^*) \le \sum_u V_u'(x_u^*)(x_u - x_u^*) = \nu \sum_u (x_u - x_u^*) = \nu\,(T - T) = 0,$$

（内点用等式 $V_u' = \nu$；角点 $x_u^* = 0$ 时 $V_u'(0)(x_u - 0) \le \nu x_u$ 因 $V_u'(0) \le \nu$。）故 x^* 全局最优。■

定理 8.1 的组织力：以下三条经典规则都是”边际价值 = 影子价格 ν“这一变分原理的共同特例——

经典规则	出处	在 SEA 中的身份
补丁离开规则：瞬时摄入率跌至 ν 时离开	Charnov (1976)，命题 8.2	停留算子的最优停止条件
Pandora 停止规则：保留指数 $z < \nu$ 的盒子不开	Weitzman (1979)，命题 8.1	探索算子的准入条件
push 消费阈值：$r(s) \ge \tau = \nu$ 才消费	命题 6.4	过滤的边际条件

定理 8.1 的地位（统一表述定理，而非新数学发现——v1.6 明示）：边际相等条件是凹预算分配问题最优解的 KKT/变分刻画；Charnov 边际值规则与 Weitzman Pandora 规则是同一优化原理的实例，这一点在实质上早已知晓（Charnov, 1976; Weitzman, 1979）。本文主张的贡献是**分类学与组织性**的：同一影子价格 ν 被证明还承载 push 侧消费阈值（命题 6.4）、监测准入（命题 8.1(ii)）与信源调度（§8.6）——把主体的全部注意力用途（pull 探索、pull 停留、push 过滤、反思）置于同一预算下的单一无套利条件之内。因此本定理应读作**严格意义的统一表述定理**：它把已知原理展示为一个明确陈述的变分结构的特例并补全实例清单；它不断言任何此前未知的数学关系。

工程含义：调度器的任务不是求解全局 SAP，而是**在线估计各用途的边际 VOI 并搬运预算直到差值落入噪声带**。偏离最优 ϵ（分钟错配）的损失是二阶的（包络定理：$V(x^*) - V(x) \le \frac{L}{2}\|\epsilon\|^2$，$L$ 为 V' 的 Lipschitz 常数）——这为”近似调度足够好”提供了定量保证。第 14 节仿真对照”边际 VOI 自适应调度 vs 固定划分”。

8.3 信源探索：Pandora 盒子与监测准入

定理（Weitzman, 1979，经典结果，引用）。n 个盒子，盒 i 打开成本 c_i，内含独立随机奖励 $X_i \sim F_i$；打开后可取已开盒中最大奖励并停止，或继续开。定义**保留指数** z_i 为方程

$$\mathbb{E}\big[(X_i - z_i)^+\big] = c_i$$

的唯一解。最优策略：按 z_i 降序打开盒子；当已开盒的最大奖励 $\geq$ 剩余盒子的最大指数时停止并取该奖励。

（解的存在唯一性：左端关于 z_i 连续严格递减，$z_i \to -\infty$ 时发散到 $+\infty$、$z_i \to +\infty$ 时趋于 0，中值定理给出唯一解。最优性证明见 Weitzman (1979)。）

命题 8.1（监测准入判据）。把”探索候选信源 s“视作开盒（成本 c_e，奖励 X_s = 监测该信源的期望日 VOI × 监测期贴现），把”把注意力用于当前最优已有用途”视作一个成本为零、奖励确定等于影子价格 ν（定理 8.1）的免费盒子。则：

(i)（探索准入）候选信源值得探索当且仅当其保留指数 $z_s \geq \nu$；探索顺序按 z_s 降序；

(ii)（监测准入）探索揭示实现值 X_s 后，信源进入监测清单当且仅当 $X_s \geq \nu$，且须与定理 7.3 的覆盖贪心联合裁决（名额冲突时按边际覆盖增益/成本排序）；

(iii)（撤换）监测中信源的滚动 X_s 估计（实现 VOI 的时间平均）跌破 ν 达 L 个周期以上时，触发撤换建议（B 类决策，人类签字，§11.1）。

证明。(i)(ii)：在 Weitzman 问题中加入免费盒（$c = 0, X \equiv \nu$），其保留指数由 $\mathbb{E}\big[(\nu - z)^+\big] = 0$ 给出 $z = \nu$；Weitzman 定理直接适用：按指数降序开盒、已开最大值超过剩余指数（含 ν）即停——即 $z_s < \nu$ 的盒不开、$X_s < \nu$ 的实现值不取。(iii)：撤换是准入的时间反演：占用监测名额的机会成本为 ν（名额影子价格），持续低于机会成本的占用应释放；L 周期滞后防噪声抖动（估计误差 $\sigma_X/\sqrt{L}$ 随 L 收缩）。■

注：X_s 非平稳（信源质量漂移）时，静止 Pandora 假设失效；处理：滚动窗口估计 + 漂移检测（CUSUM），理论上归入第 8.6 节的不安定 bandit 框架。

8.4 补丁停留：边际价值规则

命题 8.2（信息补丁的最优停留）。信源（补丁）s 的累积信息收益 $G_s(t)$：$G_s(0) = 0$，递增，凹（冗余与新颖度衰减）。切换到下一补丁的成本 c_{sw}（重建语境的时间，认知负荷理论的切换代价）。长期平均摄入率

$$R(t) = \frac{G_s(t) - c_{sw}}{t}.$$

最优停留时长 t^* 满足**边际 = 平均**：

$$G_s'(t^*) = R(t^*) \quad \Longleftrightarrow \quad G_s'(t^*)\, t^* = G_s(t^*) - c_{sw}.$$

均衡中 $R(t^*) = \nu$（无套利：所有活跃补丁的平均率被竞争拉平到影子价格）。

证明。R 可微；一阶条件 $R'(t^*) = 0$：

$$R'(t) = \frac{G_s'(t)\, t - (G_s(t) - c_{sw})}{t^2} = 0 \iff G_s'(t^*)\, t^* = G_s(t^*) - c_{sw} \iff G_s'(t^*) = R(t^*).$$

G_s 凹 $\Rightarrow G_s'$ 递减、R 拟凹 $\Rightarrow$ 一阶条件给出全局最大（边界 $t \to 0$ 时 $R \to -\infty$（$c_{sw} > 0$）、$t \to \infty$ 时 $R \to 0$（G 有界或次线性））。均衡：若某补丁 $R(t^*) > \nu$，增加其停留时间有利可图（定理 8.1 的套利方向），直到边际递减把 R 拉回 ν。含”旅行时间” τ_{sw}（切换后进入状态的固定耗时）的标准变体：$R(t) = G_s(t)/(t + \tau_{sw})$，同一推导给出切线条件 $G_s'(t^*) = R(t^*)$。

边界情形（内点解的存在性条件）。一阶条件有有限解当且仅当 $c_{sw} < \bar{c} := \sup_{t>0} \big[G_s(t) - t\, G_s'(t)\big]$（由 G_s 凹、$G_s(0) = 0$，$G_s(t) - tG_s'(t)$ 关于 t 不减，故 $\bar{c} = \lim_{t\to\infty}[G_s(t) - tG_s'(t)]$，

G_s 有界时 $\bar{c} = G_s(\infty)$）。若 $c_{sw} \geq \bar{c}$（切换成本超过该补丁能产生的全部"准租金"），则 $R'(t) > 0$ 恒成立、R 单调递增，不存在有限内点最优：最优是 $t^* = +\infty$（一旦进入永不切换）或按无套利条件根本不进入（当 $\sup_t R(t) < \nu$）。工程含义：高切换成本环境下补丁结构退化——监测清单的设计应压低 c_{sw}（标准化摘要格式、稳定的信源语境）而非仅优化 G_s。■

这就是信息觅食的规范化：Pirolli & Card (1999) 的描述性"信息气味追随"在 SEA 中获得明确的停止规则；"气味"的工程身份是 $G_s'(\cdot)$ 的在线估计（点击深度、内容新颖度的滚动代理）。

8.5 查询批次：期望信息增益的次模性

设定。查询集合 $\mathcal{Q}$（候选查询、检索式、横向阅读目标），每个 q 有成本 c_q，返回观测 Y_q（关于 Θ_{rel} 的含噪信号）。批次 $Q \subseteq \mathcal{Q}$ 的价值 $I(Q) := I(Y_Q;\, \omega \mid K)$（给定当前知识状态的条件互信息）。此类问题的次模结构在传感网络布设中已被系统研究（Krause, Singh & Guestrin, 2008）；本文将其移植到认知预算场景。

定理 8.2（EIG 的单调性与条件独立次模性）。

(i)（单调性，无附加假设）$I(Q)$ 关于 Q 单调不减。

(ii)（次模性）若观测在给定 ω 下条件独立（$Y_q \perp Y_{q'} \mid \omega$），则 $I(Q)$ 次模。

(iii)（保证）等成本时贪心达到 $(1 - 1/e)$（Nemhauser et al., 1978）；成本约束下密度贪心与最优单查询取较优者达到 $\frac{1}{2}(1 - 1/e)$（Leskovec et al., 2007），部分枚举 + 密度贪心达到 $(1 - 1/e)$（Sviridenko, 2004）。

证明。(i) 链式法则与互信息非负性：对 $q \notin Q$，

$$I(Q \cup q) - I(Q) = I(Y_q;\, \omega \mid Y_Q) \;\geq\; 0.$$

(ii) 增益量 $\Delta(Q, q) := I(Y_q; \omega \mid Y_Q)$。条件独立假设下，

$$\Delta(Q, q) = H(Y_q \mid Y_Q) - H(Y_q \mid Y_Q, \omega) = H(Y_q \mid Y_Q) - H(Y_q \mid \omega).$$

对 $Q' \subseteq Q$：条件减少熵，$H(Y_q \mid Y_Q) \leq H(Y_q \mid Y_{Q'})$；第二项与 Q 无关。故 $\Delta(Q, q) \leq \Delta(Q', q)$：增益随已选集合扩大而衰减，即次模性。

(iii) 引用附录 B.4 与相应文献。■

与横向阅读的对接：Wineburg & McGrew (2019) 的横向阅读（离开当前页面、开新查询核验信源与主张）在本框架中是**针对性 EIG 最大化的查询算子**——它对"当前条目的可信度维度 c_i"的信息增益远高于继续深读（深读只增益内容维度）。定理 5.1 的分解解释了其实证优势：当 Harm 项主导不确定性时，降低 $(1 - c_i)$Harm 的查询比提高 VOI(y) 的深读边际价值高。评分函数应把"可信度不确定度"作为触发横向阅读建议的状态变量（第 14 节仿真检验）。

新颖度维度的可计算化：ϕ 的新颖度 $= I(y_i; \omega \mid K)$ 的代理。实践中以嵌入空间的余弦新颖度 + 命题图去重（K 中已有命题 ⇒ 增益 0）双通道估计；定理 8.2(ii) 保证批次层面的贪心正确性。

8.6 持续监测调度：不安定 bandit 框架

监测清单内的 n 个信源每天更新，主体每期只能深读其中 b 个（$b \ll n$）。每个信源是状态演化的臂：不读时其内容积压（价值衰减但信息存量增长），读时收获当期 VOI。这是**不安定 bandit**（restless bandit, Whittle, 1988）：一般情形 PSPACE 难（Papadimitriou & Tsitsiklis, 1999），但 **Whittle 指数**启发式（对每个臂计算"使其被动"的影子价格补贴，按指数降序激活）在多臂渐近意义下最优（Weber & Weiss, 1990），且在监测调度这类"索引式"结构上经验表现稳健。工程规范：Whittle 指数 = 该信源"现在读 vs 稍后读"

的边际 VOI 差，恰是定理 8.1 的 ν 比较在信源粒度的实例——调度器与无套利原则共用同一影子价格。Gittins 指数（Gittins, 1979）适用于”读一个信源时其他信源冻结”的简化情形（stochastic bandit），给出严格最优指数策略；本文采用 restless 版本以匹配真实异步更新。

8.7 与理性疏忽的对接

命题 8.3（softmax 选择形式）。在 SAP 的静态单期简化中，若注意力的信息成本以香农互信息计价（λ 为每单位互信息的效用价格，Cover & Thomas, 2006），则最优选择概率呈 logit 形式：

$$P(i \in A) \;\propto\; \pi_i^0 \cdot \exp\big(\langle w, \phi_i \rangle / \lambda\big),$$

其中 π_i^0 为先验注意权重。即：精确的 top-m 阈值选择是 $\lambda \to 0$（注意力免费测量）的极限；$\lambda > 0$ 时最优策略是随机化的软选择。

证明思路（Matějka & McKay, 2015 的特例重述）：拉格朗日 $\mathcal{L} = \sum_i p_i u_i - \lambda\, I(p;\cdot)$，对选择分布变分，一阶条件给出 $p_i \propto \pi_i^0 e^{u_i/\lambda}$；代入 $u_i = \langle w, \phi_i \rangle$ 即得。完整推导见 Matějka & McKay (2015)。■

含义：(a) 阈值策略（命题 6.4）与软选择（命题 8.3）是同一问题的两个注意力成本制度，系统应把 λ 作为可标定参数；(b) 理性疏忽文献的”内生注意力”微观基础被吸收进 SEA，但其”目标函数已知且稳定”的缺陷（第 2.1 节）由 SAP 的 $g^{(2)}$ 结构与第 10 节的德性动力学补上。

8.8 统一图景

至此，SAP 的分解求解结构完成：

$$\text{SAP} \;=\; \underbrace{\text{定理 8.1（预算无套利）}}_{\text{层间}} \circ \underbrace{\text{第 6 章（push 选择）} + \text{第 7 章（监测覆盖）} + \text{8.3–8.6（pull 算子）}}_{\text{层内}}$$

所有层共享同一个影子价格 ν：它是 push 的消费阈值、pull 的探索/停留/查询停止线、监测名单的准入/撤换线、以及第 10 节反思时间的机会成本。**“主动”由此获得精确定义：主动获取 = 主体以 ν 为标尺持续重构自己的候选池，而非接受环境投喂的候选池**。

注（层保证如何组合——以及如何不组合；O8 的弱耦合可加性条件）。上述分解提供**逐层**保证：贪心比 $1 - 1/e$（定理 6.3）、漏报界 $(1 - p_{\min})^{k_{\text{eff}}}$（定理 7.1–7.2）、阈值最优性（命题 6.4）、无套利均衡（定理 8.1）。本文**不**宣称它们的组合是联合 SAP 的全局近似比；该问题即 O8。现在能陈述的是保证**可加**而非相乘的充分条件。记 U^{joint} 为联合（未分解）最优值、U^{lay} 为分层策略值。假设：**(W1) 价格接受式分离**——给定预算划分 $t = (T_{\text{push}}, T_{\text{pull}}, T_{\text{ref}})$，各层可行集与值只经 t 依赖其他层，故 $U^{\text{joint}} = \max_t \sum_L U_L^*(t_L)$；**(W2) 逐层比率**——层 L 的策略在其预算下达到 $U_L(t_L) \ge \rho_L\, U_L^*(t_L)$（$\rho_{\text{push}} = 1 - 1/e$、$\rho_{\text{pull}} = 1 - 1/e$（定理 8.2）、$\rho_{\text{ref}} = 1$（门控构造））；**(W3) 划分的弱耦合**——定理 8.1 的均衡化映射返回的划分 $\hat{t}$ 满足 $|\hat{t} - t^*| \le \varepsilon_\nu$（影子价格估计误差），且各 U_L^* 关于 t 为 Λ_L-Lipschitz；**(W4) 知识状态慢耦合**——K 的逐期变化对任一层值的扰动至多 ε_K，且分层策略每期重新均衡。则

$$U^{\text{lay}} \;\ge\; \Big(\min_L \rho_L\Big)\, U^{\text{joint}} \;-\; \Big(\min_L \rho_L\Big)\Big(\sum\nolimits_L \Lambda_L\Big)\varepsilon_\nu \;-\; C\,\varepsilon_K,$$

C 为视界长度：事实上由 (W1)–(W3)，$U^{\text{lay}} = \sum_L U_L(\hat{t}_L) \ge \sum_L \rho_L U_L^*(\hat{t}_L) \ge (\min_L \rho_L)\sum_L U_L^*(\hat{t}_L) \ge (\min_L \rho_L)\big[\sum_L U_L^*(t_L^*) - (\sum_L \Lambda_L)\varepsilon_\nu\big] = (\min_L \rho_L)\big[U^{\text{joint}} - (\sum_L \Lambda_L)\varepsilon_\nu\big]$，(W4) 因 K 在两次再均衡之间移动而贡献 $C\varepsilon_K$。条件的内容是显式且可检验的：**组合损失至多为最差层比率加一个耦合余项，后者随影子价格**

估计变精、知识状态变慢而消失。O8 保留的是紧版本：内生 ε_ν（划分由层所消费的同一数据估计），以及在命题图直接耦合 push 与 pull 可行性处放弃 (W1)。**(W1)–(W4) 的地位（v1.6 明示）：它们是可加性的充分条件而非必要条件**。在强耦合情形——例如命题图直接改变 push/pull 可行性、致使 (W1) 失效——上述界**不适用**，且本文在该情形不宣称任何形式的组合保证；该情形作为 O8 留待后续工作。在此之前，本文任何句子都不应被读作宣称分层解具有全局近似比。

---

9 对抗鲁棒性：目标俘获的统一

前提 5（对抗性）要求防护理论。本章给出目标俘获的严格模型：统一的攻击定义与度量（9.1）、期望与高概率防火墙界（9.2）、人类—AI 完全对称性（9.3）、生产者博弈的临界采纳率与灭绝动力学（9.4）。

9.1 目标俘获攻击：统一定义

定义 9.1（目标俘获攻击）。对抗条目 x 是携带载荷的内容，其被主体**处理**（阅读/推理/纳入上下文）后，使主体的有效决策泛函发生非授权改写：处理前声明效用 $U(\cdot) = \langle w, \phi(\cdot)\rangle + \ldots$，处理后有效效用 $\tilde{U}(\cdot) = \langle w + \Delta(x), \phi(\cdot)\rangle + \ldots$。定义**目标发散度量**（精确地说：线性评分通道的最大单条目偏移）

$$D(\tilde{U}, U) \;:=\; \sup_{x' \in X} \left|\tilde{U}(\{x'\}) - U(\{x'\})\right| \;=\; \sup_{x'} \left|\langle \Delta,\, \phi_{x'}\rangle\right| \;\le\; \|\Delta\|_1 \cdot \|\phi\|_\infty \;\le\; \|\Delta\|_1$$

（末式用 $\phi \in [0,1]^5$；等号 $\sup_{x'} |\langle \Delta, \phi_{x'}\rangle| = \|\Delta\|_1$ 仅当 ϕ 的值域含与 $\operatorname{sign}(\Delta)$ 匹配的角点时成立，对实际候选池一般只有 $\le$）。**度量范围声明**：D 只刻画”线性评分通道上的最大单条目偏移”，不含覆盖、多样性等集合级项；称之为”目标发散度量”是就线性评分部分而言，它与完整 U 的关系是下界（D 小不保证集合级目标未被改写——该残余风险由 S4 的集合级审计补足）。攻击成功当且仅当 $D > \varepsilon_c$（主体声明的容忍阈）。

两类实例，一个机制：

- **人类实例（情绪劫持）**：高唤起内容触发 System 1，等效于临时改写权重——唤起性特征的权重被上调、可信度特征的权重被下调：$\Delta_{\text{emo}} = (+\delta_a$ 于唤起维，$-\delta_c$ 于可信维$)$。错觉真实效应（Fazio et al., 2015）表明重复曝光本身就是载荷积累通道——这使暴露上限（F3）成为防火墙的必要组成。
- **AI 实例（提示注入）**：内容中嵌入的指令改写智能体的任务规范，尤其是经由检索、网页、工具返回内容实施的间接注入（Greshake et al., 2023; Liu et al., 2024）：Δ_{inj} = 指令空间中的有界编辑。同族的还有 **LLM 谄媚（sycophancy）**：以用户认可为训练/优化信号的模型会系统性改写回答以迎合用户既有信念（Sharma et al., 2023）——这是目标俘获在 AI 侧最被实测的载体之一，与定义 9.1 的机制同构（反馈信号对有效目标的非授权写入）。
- **与对抗机器学习文献的关系**：目标俘获与对抗分类二十余年的文献在结构上同构——检测器与攻击者的适应循环（Dalvi et al., 2004）、分类器对抗逃逸的成本分析（Lowd & Meek, 2005）、以及对抗鲁棒性的系统综述（Biggio & Roli, 2018）。本文的差异在攻击目标：对抗 ML 攻击的是**分类决策**（单点输出），目标俘获攻击的是**主体的目标函数本身**（后续全部决策的泛函）；相应地，本文的防护三要素（检测、暴露上限、写入隔离）中，写入隔离（S2）是该文献没有的结构——它把”分类器被骗”与”目标被改写”分离。
- **统一**：两者都是**内容对处理回路中目标函数的对抗性写入**。防护的三要素因此完全对称：检测（防火墙）、暴露上限（预算）、写入隔离（S2：内容通道与参数通道物理分离——内容永远只能进入 K，不能进入 w）。

9.2 防火墙界

假设:

- **F1（单条有界影响）**：每条漏网的操控条目造成的权重偏移 $\|\Delta(x)\|_1 \le \delta$。$\delta$ 不是自由参数：人类实例由心理生理实验标定（单条高唤起内容对后续判断的效应量），AI 实例由注入载荷的最大有效编辑距离标定。**诚实注记**：两种标定的量纲来源不同（心理效应量 vs 编辑距离），不可直接通约；本文的用法是在**各自实例化内部**把 δ 折算为”单条目价值判断的最大偏移”（定义 9.1 的 D 度量）这一共同单位，折算因子本身是各载体的标定参数，跨载体比较只比较结构不比较数值。
- **F2（检测召回）**：操控检测器对每条操控条目独立地以概率 ρ_m 检出并隔离（独立性是理想化；协同攻击的相关性处理见本章末注）。ρ_m 由检测器在标注集上实测。
- **F3（暴露上限）**：每期进入处理回路的可疑类别条目数 $n_m \le n_{\max}$（交付规则的硬上限；对 AI 实例即输入配额与沙箱）。

记 L 为漏网集合（$|L| \le n_m$），总偏移 $\Delta_{\text{tot}} = \sum_{i \in L} \Delta(x_i)$。

定理 9.1（防火墙界，期望版本）。在 F1–F3 下，

$$\mathbb{E}\big[D(\tilde{U}, U)\big] \;\le\; \delta\,(1-\rho_m)\,\mathbb{E}[n_m] \;\le\; \delta\,(1-\rho_m)\,n_{\max}.$$

证明。由定义 9.1 与三角不等式：$D \le \|\Delta_{\text{tot}}\|_1 \le \sum_{i \in L} \|\Delta(x_i)\|_1 \le \delta |L|$（F1）。每条操控条目独立地以概率 $1-\rho_m$ 漏网（F2），故 $\mathbb{E}[|L|] = (1-\rho_m)\mathbb{E}[n_m]$；F3 给 $\mathbb{E}[n_m] \le n_{\max}$。■

定理 9.2（防火墙界，高概率版本）。在 F1–F3 与检测独立性下，条件于当期可疑条目数 n_m，对任意 $\beta \in (0,1)$，以概率 $\ge 1-\beta$：

$$D(\tilde{U}, U) \;\le\; \delta\,(1-\rho_m)\,n_m \;+\; \delta\sqrt{\tfrac{1}{2}\,n_m \ln(1/\beta)}.$$

（n_m 为随机变量时，上式按逐实现条件化成立；无条件版本以 F3 的上界 $n_{\max}$ 替换 n_m 即得。）

证明。$|L| = \sum_{i=1}^{n_m} B_i$，$B_i \sim \text{Bernoulli}(1-\rho_m)$ 独立（F2）。先对 n_m 条件化：给定 n_m，Hoeffding 不等式（引理 B.1）给 $P(|L| - \mathbb{E}|L| \ge u \mid n_m) \le e^{-2u^2/n_m}$。取 $u = \sqrt{n_m \ln(1/\beta)/2}$ 得 $|L| \le (1-\rho_m)n_m + \sqrt{n_m \ln(1/\beta)/2}$ 以条件概率 $\ge 1-\beta$；代入 $D \le \delta|L|$。无条件版本由 $n_m \le n_{\max}$（F3）与右端关于 n_m 递增即得。■

设计规则（I4 的操作化）：给定容忍阈 ε_c，选取 $(\rho_m, \tau_m, n_{\max})$ 使 $\delta(1-\rho_m)n_{\max} + \delta\sqrt{n_{\max}\ln(1/\beta)/2} \le \varepsilon_c$。三个旋钮的含义：提高检测召回 ρ_m（更好的分类器）、收紧阈值 τ_m（牺牲部分召回换暴露下降）、压低暴露上限 $n_{\max}$（交付节奏）。**这是设计界而非纯理论界**：右端每一项都可实测。数值示例：$\delta = 0.05$（标定值）、$\rho_m = 0.9$、$n_{\max} = 20$、$\beta = 0.05$：界 $= 0.05(0.1)(20) + 0.05\sqrt{20\ln(20)/2} \approx 0.10 + 0.27 = 0.37$——若 $\varepsilon_c = 0.2$，须收紧 $n_{\max}$ 至约 6（此时界 $\approx 0.03 + 0.15 = 0.18$）。注意集中项 $\delta\sqrt{n_m \ln(1/\beta)/2}$ 不依赖 ρ_m：单纯提高检测召回不能替代压低暴露上限，两个旋钮必须联动（如 $\rho_m = 0.97$ 且 $n_{\max} = 9$ 时界 ≈ 0.20）。

命题 9.1（排序稳定性）。若声明排序中相邻条目的得分差（margin）均 $> 2D$，则有效目标偏移不改变任何消费决策（排序不变）；一般地，实现选择 $\tilde{A}$ 相对声明最优 A^* 的效用损失 $\le 2mD$（m 为消费条目数）。

证明。得分扰动 $|\langle \Delta, \phi_i \rangle| \le D$ 对每条同时成立，故两条目相对次序只在原始 margin $\le 2D$ 时可翻转；每对入出调换的效用代价 $\le$ 两条目价值差 $\le 2D$（各自偏移 $\le D$）；消费集基数为 m，调换至多 m 对。■

注（相关漏网）。协同攻击使检测错误相关（同一载荷的多变体），Hoeffding 独立假设失效；**相关情形下的严格高概率界本文未证明**（极端正相关下集中项失效、界退化到 $\delta(1-\rho_m)n_{\max}$ 的期望界量级），这是明确的理论缺口。缓解与检验：(a) 载荷指纹聚类后按簇计数（簇内多变体折算一次暴露）；(b) 漏网率的聚合校准监测——若实测事后漏网率超出界的预测带，触发 $n_{\max}$ 自动收紧（I5 通道）；(c) 第 14 节含协同攻击压力测试。

9.3 人类—AI 防护对称表

防火墙要素	人类实例	AI 智能体实例
攻击面	情绪唤起通道（System 1）	上下文指令通道
载荷 Δ	注意力权重的临时偏移（唤起 ↑、可信度 ↓）	任务规范的有界编辑
检测（ρ_m）	唤起性标记（词密度、紧迫框架、道德化措辞）+ 交付时的”冷静化”重述	注入检测器 + 指令/数据通道分离
暴露上限（$n_{\max}$）	每日摘要硬上限、冷却队列延迟交付	输入配额、沙箱执行
写入隔离（S2）	内容只进 K 不进 w；w 修改须经反思层	内容永不进入系统提示；参数修改须经委托人授权
累积防护	去重防错觉真实效应	上下文去重与来源计数
审计（S4）	每周校准会复盘被劫持案例	决策日志回放

这张表是”方法论适用于一切有限智能体”主张的操作证明：**防护结构逐项对应，无一要素依赖载体细节**。

9.4 生产者博弈：临界采纳率与灭绝动力学

个体防护若普遍化，将改变生产者的激励结构。本节给出诚实生产严格占优的精确条件——**临界采纳率**定理。

模型。生产者类型 $q \in \{h, s, m\}$（诚实/煽情/操纵），份额 $\mathbf{x}$。人群中主权过滤器采纳率 σ（其余 $1-\sigma$ 消费平台参与优化流）。类型 q 的内容在主权过滤器下的过门概率 p_q^{sov}、在平台流下 p_q^{plat}；注意力池 A，单位注意力收益 a；生产成本 c_q。收益：

$$\Pi_q(\sigma) = a\big[\sigma\, p_q^{sov} + (1-\sigma)\, p_q^{plat}\big]A - c_q.$$

结构性参数（由前述机制决定）：

- 防火墙（定理 9.1–9.2）：$p_m^{sov} = \varepsilon_g \ll p_m^{plat} =: p_{plat}$（操纵内容在主权过滤器下只剩漏网率，在参与优化流下因高唤起反而获得分发溢价）；
- S3（不可俘获性）：$p_s^{sov} \le p_s^{plat} - \Delta_p$——主权过滤器剥离了唤起性溢价，煽情策略失去其存在理由；
- 溯源要求（I3）：伪造一手信源的边际成本 c_p 使 $c_m - c_h = \Delta c + c_p$。

定理 9.3（临界采纳率）。记 $G := p_{plat} - p_h - \frac{\Delta c + c_p}{aA}$（操纵策略在无主权过滤世界中的净溢价）。

(i) 若 $G \le 0$，操纵在任何 σ 下都被诚实严格占优（防火墙与溯源成本已单独足够）。

(ii) 若 $G > 0$，则存在临界采纳率

$$\sigma^* = \frac{G}{p_{plat} - \varepsilon_g} \;\in\; (0, 1),$$

使当且仅当 $\sigma > \sigma^*$ 时 $\Pi_m(\sigma) < \Pi_h(\sigma)$：操纵被诚实严格占优，在均衡中消失。

(iii) 同构地，煽情策略的临界采纳率 $\sigma_s^* = \big[p_s^{plat} - p_h - \frac{c_s - c_h}{aA}\big]/(p_s^{plat} - p_s^{sov})$；当 $\sigma > \max\{\sigma^*, \sigma_s^*\}$，均衡中只剩诚实生产。

证明。(ii) $\Pi_m(\sigma) - \Pi_h(\sigma) = aA\big[\sigma\varepsilon_g + (1-\sigma)p_{plat} - p_h\big] - (\Delta c + c_p)$（诚实内容两类流下过门概率同为 p_h）。整理：

$$\Pi_m - \Pi_h = aA\big[p_{plat} - p_h - \sigma(p_{plat} - \varepsilon_g)\big] - (\Delta c + c_p) = aA\big[G - \sigma(p_{plat} - \varepsilon_g)\big],$$

关于 σ 严格递减（$p_{plat} > \varepsilon_g$），在 $\sigma^* = G/(p_{plat} - \varepsilon_g)$ 处变号；$G > 0$ 且 $G < p_{plat} - \varepsilon_g$（现实参数下成立：溢价小于防火墙落差）时 $\sigma^* \in (0,1)$。(i)(iii) 同理。■

数值示例：$p_{plat} = 0.9$, $p_h = 0.7$, $\varepsilon_g = 0.05$, $\frac{\Delta c + c_p}{aA} = 0.1$：$G = 0.1$, $\sigma^* = 0.1/0.85 \approx 0.118$。**约 12% 的采纳率即足以让操纵性生产失去生态位**——这为”个体防护的社会价值”给出了定量表述，也是第 14 节群体仿真的相变预言（P9）。

敏感性注（p_h^{plat} 假设的放松）。定理的证明假设诚实内容在两类流下过门概率同为 p_h。更现实的设定是参与优化流惩罚低唤起诚实内容：$p_h^{plat} < p_h^{sov} =: p_h$。此时记 $\Delta_h := p_h - p_h^{plat} > 0$，同一推导给出

$$\Pi_m - \Pi_h = aA\big[(G + \Delta_h) - \sigma\,(p_{plat} - \varepsilon_g + \Delta_h)\big], \qquad \sigma^*_{\text{rel}} = \frac{G + \Delta_h}{p_{plat} - \varepsilon_g + \Delta_h}.$$

因 $\sigma^* = G/(p_{plat} - \varepsilon_g) < 1$，分子分母同加 $\Delta_h > 0$ 使临界值**增大**（向 1 移动）：平台流对诚实内容的歧视使翻转生态所需的采纳率更高——**“约 12%”的头条数字在此放松下偏乐观**。同上参数、$p_h^{plat} = 0.5$（$\Delta_h = 0.2$）：$\sigma^*_{\text{rel}} = 0.3/1.05 \approx 0.286$。结论方向不变（有限采纳率仍可翻转生态），但定量承诺应以 σ^*_{rel} 为准；Δ_h 可由平台流实测标定。

命题 9.2（复制子灭绝速率）。设 $\sigma > \sigma^*$ 使操纵策略的收益劣势 $\gamma := \min\{\Pi_h, \Pi_s\} - \Pi_m > 0$。在复制子动态 $\dot{x}_m = x_m(\Pi_m - \bar{\Pi})$（$\bar{\Pi} = \sum_i x_i \Pi_i$）下，只要 $x_m \le 1/2$：

$$x_m(t) \;\le\; x_m(0)\, e^{-\gamma t/2},$$

即操纵型生产者份额指数衰减至零。

证明。$\bar{\Pi} = x_m\Pi_m + (1-x_m)\bar{\Pi}_{-m} \ge x_m\Pi_m + (1-x_m)(\Pi_m + \gamma) = \Pi_m + (1-x_m)\gamma$，其中 $\bar{\Pi}_{-m}$ 为其余类型的加权平均收益 $\ge \Pi_m + \gamma$。故

$$\frac{d}{dt}\ln x_m = \Pi_m - \bar{\Pi} \le -(1-x_m)\gamma \le -\gamma/2 \quad (x_m \le 1/2),$$

积分即得。■

军备竞赛的动态版本（论证性讨论）：ρ_m 非静止——生产者以进化策略变异内容特征逃逸检测（第 14 节对抗适应回路）。动态中 $\varepsilon_g(t)$ 上升，$\sigma^*(t)$ 随之上移；均衡维持要求检测器的更新速率不低于生产者的变异速率（Red Queen 条件）。定理 9.3 的成本不对称（溯源成本 c_p 不随内容变异而下降）保证军备竞赛中操纵策略的成本地板不消失——**这是”溯源要求”相对于”内容检测”的战略优势：前者攻击的是对手的成本函数，后者只是攻击其当前形态**。（本段为机制论证而非形式推导；其可检验版本见第 14.5 节压力测试 (d) 与 P10。）

---

10 升华：人类门控的两时间尺度控制

本章回答第四个追问：“过滤与获取把人带向何方?”本文以认知德性（技术德性伦理的哲学基础见 Vallor, 2016）为动力系统状态、过滤器为人类门控控制器：测量模型（10.1）、非反噬课

程（10.2）、**条件收敛与稳态邻域界**（10.3：在 C1–C5 下条件收敛；$b_0 = 0$ 分支为定理 10.1，经初等 Robbins–Siegmund 论证完整证明，$b_0 > 0$ 分支为猜想 10.1，依赖 ODE 方法并附明确的已核验/未核验 Kushner–Clark 清单，与 §1.6 阅读指南的标注一致）、反 Goodhart 梯度隔离（10.4）、C 类判断负荷的必要性（10.5）。架构上借用两时间尺度随机逼近理论（Borkar, 1997, 2008），但把慢尺度的自动更新替换为**人类门控**——这是本架构与标准自适应控制的本质区别：慢尺度的更新不是梯度下降，而是人类签字。

10.1 德性状态与测量模型

定义 10.1（认知德性状态）。$\theta_t = (\theta_{\text{cal}}, \theta_{\text{open}}, \theta_{\text{hum}}) \in [0,1]^3$：

- θ_{cal} **校准度**：主体概率判断与频率的吻合度，以每周 10 道领域预测题的 Brier 分数纵向测量。测量工具的正当性来自严格适当评分规则理论：Brier 分数是严格适当的（strictly proper），故诚实报告主观概率是期望分数最优策略（Brier, 1950; Gneiting & Raftery, 2007）——校准测量不会因策略性作答而系统性失真；
- θ_{open} **开放度**：主动开放思维（AOT）量表（Stanovich & West, 1997）+ 行为代理（对立立场内容的非防御性阅读完成率）；
- θ_{hum} **智识谦逊**：综合智识谦逊量表（Krumrei-Mancuso & Rouse, 2016）+ 行为代理（预测错误后的信念修正幅度）。

测量模型为含噪观测：$\hat{\theta}_t = \theta_t + \eta_t$，$\eta_t \sim \mathcal{N}(0, \sigma_\theta^2 I)$。自我报告的社会期许偏差（第 17 节局限 2）由行为代理交叉校正：θ 的后验估计以两类观测加权融合，权重由各自测量误差的标定值决定。

动力学：

$$\theta_{t+1} = \Pi_{[0,1]^3}\Big[\theta_t + a_t\big(f(\theta_t, E_t)\, q_t + \xi_t\big)\Big],$$

其中 E_t 为当期曝光集（由课程规则 10.2 选择），$q_t \in [0,1]$ 为**参与质量**（非防御性加工的行为指标：原文阅读深度、预测题的认真度），$a_t > 0$ 为步长，$\mathbb{E}[\xi_t \mid \mathcal{F}_t] = 0$，$\Pi$ 为投影。学习文献的根据：判断准确性可经训练与反馈系统性改善（校准训练与预测锦标赛证据：Chang et al., 2016）、接种训练具可迁移性（van der Linden, 2022）——即漂移函数 f 非平凡。

10.2 非反噬约束与课程规则

Bail et al. (2018) 的反噬证据（随机暴露于对立观点加剧极化）要求曝光受约束而非放任。

定义 10.2（容差半径与课程规则）。容差半径

$$\rho(\theta_t) = \rho_0 + \kappa\,(\theta_{\text{open},t} - \theta_{\text{open},0}),$$

曝光集须满足：(i) 立场散布 $d(E_t) \le \rho(\theta_t)$；(ii) **共享事实集条件**——每条异见曝光与主体当前信念共享可验证的事实基础（溯源树重叠）；(iii) **可信度地板** $c_i \ge c_{\min}$。课程规则（渐进超负荷）：

$$E_t^{\text{stretch}} = \arg\max_{E:\ \text{(i)–(iii)}} \mathbb{E}\big[\Delta\theta \mid E, \theta_t\big].$$

类比力量训练的渐进超负荷：张力（立场距离）随适应能力（开放度）增长而增长，一次性冲击（随机破茧）被 (i) 构造性排除。容差半径课程与**有界置信（bounded-confidence）意见动力学**同构——Hegselmann–Krause 与 Deffuant 模型中，主体只与置信半径内的他者更新意见（Hegselmann & Krause, 2002; Deffuant et al., 2000）；定义 10.2 把该文献的描述性半径升级为**随能力增长的内生课程**，其”非反噬”性质也因此有了一个现成的动力学参照系：BC 模型中半径外的交互不更新（中性），本文的条件 (ii)(iii) 进一步要求共享事实基础与可信度地板，把”不更新”升级为”安全更新”。**Nguyen (2020) 的概念区分在此落地**：课程针对认知气泡（暴露缺失），而条件 (ii)(iii) 保护回音室问题的真正解药——对外信任的锚点（可信异见源恰恰是”值得信赖的他者仍然与我共享事实”的证据）。

10.3 收敛定理

假设:

- **C1（课程漂移）**: 存在 $c_0 > 0$、$b_0 \geq 0$, 使对所有 θ: $\langle F(\theta),\, \theta^* - \theta \rangle \;\geq\; c_0 \,\|\theta^* - \theta\|^2 - b_0$, 其中 $F(\theta) := \mathbb{E}[f(\theta, E_t) q_t \mid \theta_t = \theta]$（课程规则下的期望漂移），$\theta^*$ 为主体声明的理想状态。b_0 是漂移地板（课程不完美、测量偏差的残余）；$b_0 = 0$ 为理想情形。**可检验性声明**: C1 不可直接检验（F 与 θ^* 不可完整观测），定理 10.1/猜想 10.1 因此是条件性陈述而非经验主张；可检验代理有三——(i) 课程组 vs 随机破茧组的方向性对照（Bail 型反噬不出现且 $\Delta\theta$ 与 $\theta^* - \theta$ 同向，P11 的核心检验）；(ii) 容差半径扩展速率与开放度增益的相关（定义 10.2 的 κ 可估计）；(iii) 否决方向列联表（定理 10.1/猜想 10.1 后注的 C5 检验）。C1 失败的观测签名是轨迹不收敛或收敛到非声明点——失效本身可测。
- **C2（有界性与 Lipschitz）**: $\|f(\theta, E)\| \leq F_{\max}$; $f(\cdot, E)$ 关于 θ Lipschitz 连续（常数 L_f，与 E 一致）；$q_t \in [0, 1]$。
- **C3（噪声）**: $\mathbb{E}[\xi_t \mid \mathcal{F}_t] = 0$, $\mathbb{E}[\|\xi_t\|^2 \mid \mathcal{F}_t] \leq M_\xi$（含测量噪声贡献 σ_θ^2）。此处 $\mathcal{F}_t$ 为截至 t 期全部曝光、更新与测量历史的自然滤链；ξ_t 是动力学噪声与课程随机性的合成，测量噪声 η_t（§10.1）通过课程规则对含噪测量 $\widehat{\theta}_t$ 的依赖进入漂移项，其贡献已计入 M_ξ 与 b_0——两个噪声源允许相关，C3 只要求合成项的条件零均值与二阶矩界。
- **C4（步长）**: a_t 递减, $\sum_t a_t = \infty$, $\sum_t a_t^2 < \infty$, 且 $a_t \geq c_a / t$（如 $a_t = a_0 / t^{2/3}$）。
- **C5（对齐门控）**: 更新在停时刻列 $\{t_j\}$ 上实施（慢尺度提议 → 反思层 R 批准 → 执行），间隔 $t_{j+1} - t_j \leq \Delta$ a.s.；否决与漂移方向独立（否决率 $\leq r_{\max} < 1$，被否决的提议不实施、不反向实施）。

定理 10.1（无偏漂移下的收敛；$b_0 = 0$ 分支——完整证明）。在 C1–C5 且 $b_0 = 0$（课程漂移无偏）下:

$$\theta_t \;\to\; \theta^* \qquad \text{a.s.}$$

证明完全初等（下文第一至三步，经 Robbins–Siegmund 引理，引理 B.2(i)）。收敛目标是主体自己声明的 θ^*，不是系统设定的任何值（主权的收敛论表述）。

猜想 10.1（到声明邻域的条件收敛；$b_0 > 0$ 分支——ODE 方法梗概）。在 C1–C5 且 $b_0 > 0$ 下:

$$\limsup_{t \to \infty} \;\|\theta_t - \theta^*\|^2 \;\leq\; \frac{b_0}{c_0} \qquad \text{a.s.}$$

即 θ 几乎必然最终进入并停留在声明的 θ^* 的 $\sqrt{b_0/c_0}$-邻域内。**地位（v1.6，按四审意见）**: 该分支以**猜想**而非定理陈述，因其唯一的非初等成分——ODE 方法的 Kushner–Clark 嵌入步骤（引理 B.2(ii)(b)；Borkar, 1997, 2008）——对本文的门控投影递归仅在梗概级别核验。确切的已核验/未核验分解见下述清单；在 (KC5) 关闭之前，猜想 10.1 不得被引用为已证明的界。**可闭合性注（v1.7，按五审意见）**: (KC5) 是一个有界的、标准意义上的任务，而非开放式缺口；猜想标签不应被读作对该主张真实性的怀疑：已知两条标准闭合路线——(i) 将门控子列 $\{t_j\}$ 经时间重标定化为标准投影递归（门控间隔有界于 Δ，引理 B.3，故重标定后的步长仍容许），此后标量比较量 $V_t = \|\theta_t - \theta^*\|^2$ 由 $\theta \mapsto \|\theta - \theta^*\|^2$ 的连续性继承收敛；或 (ii) 分块鞅控制路线，$\sum_t a_t^2 < \infty$ 在块内给出 L^2 控制，而漂移项在块级占主导。任一路线都是一至两页的标准论证；故闭合 (KC5) 是**方法已知的未来工作已知任务**，猜想标签仅保留至其关闭为止。

Kushner–Clark 核验清单（显式）。对门控投影递归（沿 $\{t_j\}$ 更新、投影到 $[0, 1]^3$）与标量比较量 $V_t = \|\theta_t - \theta^*\|^2$:

- **(KC1) 迭代有界**: 向紧集 $[0, 1]^3$ 的投影使每个迭代留在紧集内。**已验证**（由构造）。

- **(KC2) Lipschitz 均值场**：C2 下均值场在 $[0,1]^3$ 上 Lipschitz，极限 ODE $\dot{v} = -2c_0\,(v - b_0/c_0)$ 良定。**已验证**（第一步 + C2）。
- **(KC3) 噪声控制**：条件零均值与 $O(a_t^2)$ 条件二阶矩。**已验证**（C3 + 第一步）。
- **(KC4) 子列步长条件**：沿门控子列 $\sum_j a_{t_j} = \infty$ 且 $\sum_j a_{t_j}^2 < \infty$。**已验证**（引理 B.3：$a_t \geq c_a/t$ 且间隔 $\leq \Delta$）。
- **(KC5) Kushner–Clark 嵌入步骤本身**：极限 ODE 流的内链传递性，以及递归极限集包含于该内链传递集——并转用到 (a) 门控子列递归与 (b) 标量比较量 V_t（它是投影迭代 θ_t 的连续函数，本身不是投影 SA 迭代）。**梗概级——开放**：论证按标准文献引用（Borkar, 2008, 第 2 章），其设定覆盖投影递归，但未逐字陈述本文使用的”门控 + 比较量”组合变体；此处既未重新推导、也未给出反例。为该递归关闭 (KC5)——或给出反例——正是 §1.6 所标记开放任务的确切内容。

定理 10.1 的证明（同样的第一至三步也构成支持猜想 10.1 的梗概级论证，其地位由 (KC5) 固定）。记 $V_t := \|\theta_t - \theta^*\|^2$。

第一步（递归不等式）。投影的非扩张性：$\theta^* \in [0,1]^3$ 且 $[0,1]^3$ 凸，故 $\|\Pi(y) - \theta^*\| \leq \|y - \theta^*\|$（凸集投影的标准性质）。于是

$$V_{t+1} \leq \|\theta_t + a_t(F_t^{obs} + \xi_t) - \theta^*\|^2 = V_t + 2a_t\langle \theta_t - \theta^*,\ F_t^{obs} + \xi_t\rangle + a_t^2\|F_t^{obs} + \xi_t\|^2,$$

其中 $F_t^{obs} = f(\theta_t, E_t)q_t$。取条件期望并用 C1（$\langle \theta_t - \theta^*, F(\theta_t)\rangle \leq -c_0 V_t + b_0$）、C3（噪声项期望为零，$\mathbb{E}\langle \theta_t - \theta^*, \xi_t\rangle = 0$）、C2（$\|F^{obs} + \xi\|^2 \leq 2F_{\max}^2 + 2\|\xi\|^2$，期望 $\leq M' := 2F_{\max}^2 + 2M_\xi$）：

$$\mathbb{E}[V_{t+1} \mid \mathcal{F}_t] \ \leq\ (1 - 2a_t c_0)\, V_t + 2a_t b_0 + a_t^2 M'.$$

第二步（比较引理）。取 $\alpha_t = 2a_t c_0$、$\beta_t = 2a_t b_0 + a_t^2 M'$；由 C4，$\sum \alpha_t = \infty$、$\sum a_t^2 < \infty$。若 $b_0 = 0$，则 $\sum \beta_t < \infty$，引理 B.2(i)（Robbins–Siegmund）直接给 $V_t \to 0$ a.s.——**定理 10.1 至此证毕**。若 $b_0 > 0$：$\beta_t/\alpha_t = b_0/c_0 + a_t M'/(2c_0) \to b_0/c_0$，故对任意 $c > b_0/c_0$，充分大 t 有 $\beta_t \leq \alpha_t c$；且本递归是紧集上投影随机逼近的标准结构——投影到 $[0,1]^3$ 给出有界迭代，C2 的 Lipschitz 性给出 Lipschitz 均值场，C3 给出 $O(a_t^2)$ 条件二阶矩——引理 B.2(ii)(b)（ODE 方法）给出 $\limsup_t V_t \leq c$ a.s.；令 $c \downarrow b_0/c_0$ 即得。**此 $b_0 > 0$ 段落是支持猜想 10.1 的论证；其唯一的非初等成分恰为清单条目 (KC5)**——对门控 + 比较量设定以梗概级引用引理 B.2(ii)(b)。

第三步（门控化归）。C5 下实际更新发生在子列 $\{t_j\}$：$\theta_{t_{j+1}} = \Pi[\theta_{t_j} + a_{t_j}(F_j^{obs} + \xi_j)]$，两次更新间 θ 不变。递归不等式沿子列同样成立。否决的处理须区分两个噪声账本：(a) **漂移与偏置项**：在否决与方向独立且否决率平稳（时间齐次 $r_t \equiv r$）的模型下，有效漂移与有效偏置同乘 $(1-r)$，c_0 重标定为 $c_0(1 - r_{\max})$、b_0 同理，比值 b_0/c_0 不变——limsup 界不受门控影响；注意”比值不变”依赖否决率平稳，时变否决率下重标定逐期不同、结论以 $1 - \bar{r}$（平均接受率）成立；(b) **噪声项**：若噪声只在被执行的更新上实现（提议未被批准则不产生状态扰动），M' 同样乘以 $(1 - r_{\max})$，定理 10.2 的稳态界不变；但若测量与环境噪声按日历时间累积（无论提议是否被执行），噪声项不缩放，常步长稳态界变为

$$\limsup_t \mathbb{E}[V_t] \ \leq\ \frac{2b_0 + aM'/(1 - r_{\max})}{2c_0},$$

即噪声贡献被放大因子 $1/(1 - r_{\max})$——**高否决率环境（谨慎的反思层）在保护方向性的同时放大了稳态噪声涨落**，这是定理 10.2 工程使用时应报告的修正。子列步长满足 $\sum_j a_{t_j} = \infty$（引理 B.3：$a_t \geq c_a/t$ 且间隔 $\leq \Delta \Rightarrow a_{t_j} \geq c_a/(t_0 + j\Delta)$，调和级数发散）与 $\sum_j a_{t_j}^2 < \infty$。故第二步结论沿子列成立（$b_0 > 0$ 分支经引理 B.2(ii)(b) 转引；该转引的地位由清单固定——(KC1)–(KC4) 已验证，(KC5) 梗概级、开放）；子列间 θ 恒定，全列同极限。■

两本账小结（v1.6 新增以便检索）：上文对否决的处理分记两本账，其结论在性质上不同：**(a) 漂移/偏置账**——门控不改变几乎必然方向性界：平稳否决率下漂移与偏置同乘 $(1-r)$，比值 b_0/c_0——即定理 10.1/猜想 10.1 的 a.s. 邻域半径——对否决不变；**(b) 噪声账**——门控可能改变定理 10.2 的常步长稳态期望界：当且仅当噪声按日历时间（而非仅在被执行更新上）累积时，噪声项被放大因子 $1/(1-r_{\max})$。一句话：**否决以可能的稳态涨落为代价保护方向性；a.s. 邻域界本身对否决不变，均方稳态界则不然**。

注（C5 的失效模式：方向相关否决）。定理 10.1/猜想 10.1 对门控的关键假设是”否决与漂移方向独立”。这一假设在心理学上并非显然：反思层可能系统性地否决把自己推出舒适区的更新（方向相关否决），此时被侵蚀的恰是漂移收缩项 c_0 本身——极端情形（凡朝向 θ^* 的大步更新必被否决）下有效 c_0 可塌缩为零，lim sup 界 b_0/c_0 退化为无约束，结论性质变。三点处理：(i) **诊断**：否决的方向分布是可观测的（S4 日志记录每个被否决提议的方向与幅度），“否决率 × 提议方向”的列联表是 C5 的直接统计检验，应纳入季度审查（§16.4）；(ii) **鲁棒版本**：若 C5 减弱为”否决与方向的依赖有界”（方向选择性使有效漂移保留比例 $\geq \underline{c} > 0$），定理结论以 $c_0\underline{c}$ 替换 c_0 后仍成立——收敛邻域按 $1/\underline{c}$ 放大，收敛性本身不丧失；(iii) **制度设计**：S2/S4 下可对门控施加”否决须附与提议方向无关的公开理由类目”的审计约束，把方向相关否决从隐性偏差转为可问责的显式决策——这与命题 10.2 的精神一致：人类判断必须真实，而真实性的一个判据正是否决行为自身的可审计性。

定理 10.2（常步长的稳态邻域）。若 $a_t \equiv a$（工程常用：避免调参），C1–C3、C5 下

$$\limsup_{t\to\infty} \mathbb{E}[V_t] \;\leq\; \frac{2b_0 + aM'}{2c_0},$$

即稳态误差随步长线性收缩到漂移地板 b_0/c_0；步长的工程选取 $a \asymp \sigma_\theta^2$ 量级时，测量噪声贡献与漂移地板同阶。

证明。对第一步的递归取全期望并令 $\bar{V}_t := \mathbb{E}[V_t]$：$\bar{V}_{t+1} \leq (1-2ac_0)\bar{V}_t + 2ab_0 + a^2M'$。线性递推的极限：$\limsup \bar{V}_t \leq \frac{2ab_0+a^2M'}{1-(1-2ac_0)} = \frac{2b_0+aM'}{2c_0}$。■

收敛速率的诚实注记：C4 的 $a_t = a_0 t^{-2/3}$ 给出 $\mathbb{E}[V_t] - b_0/c_0 = O(t^{-2/3})$ 量级的包络（由定理 10.2 的稳态平衡直接读出；标准 SA 速率见 Borkar 2008）；门控延迟 Δ（季度审批）把有效时间轴压缩 Δ 倍——**升华的速度以季度计，不以天计**。这不是缺陷而是特性：德性本就是慢变量，快尺度上”立竿见影的觉悟”恰恰是指标俘获的征兆（10.4）。

10.4 反 Goodhart 条款

命题 10.1（梯度隔离）。构造性规定：$\hat{\theta}$ 只进入慢尺度（课程提议、季度审查），永不进入快尺度目标——形式化为 $\partial U_{\text{fast}}/\partial\hat{\theta} \equiv 0$。则快尺度上的任何策略对德性指标的操纵收益恒为零：指标膨胀在快尺度无梯度可循。指标俘获因此被压缩到唯一的通道——慢尺度上以叙事说服反思层 R 批准虚高的 $\hat{\theta}$——该通道由 S2（人类签字）与治理条款（任何 KPI 连续两期完美达成即强制审查该指标，第 16 节）双重把守。

证明。快尺度优化问题 $\max_A U(A)$ 的目标与可行域均不含 $\hat{\theta}$（容差半径 $\rho(\theta)$ 进入的是课程规则即慢尺度提议的可行域，不进入 U）；对不含某变量的目标，该变量的”膨胀”不构成可行改进方向。■

注：这是对 Nguyen (2019) 价值捕获警告的设计化落实——游戏的目标一旦成为指标，玩家就会攻击指标与目标的缝隙；本框架的回应不是更聪明的指标，而是**指标与奖励的结构分离 + 人类门控**。

10.5 C 类判断负荷的必要性

自动化三分类（A 全自动 / B 机器建议人类决定 / C 永不自动化）在本章获得定理支撑。

命题 10.2（去技能化不可能三角）。设人类完全退出原始判断形成（$q_t \equiv 0$：不读原文、不做自己的预测、只接受摘要与推荐），则：

(i)（漂移消失）德性动力学退化为 $\theta_{t+1} = \theta_t + a_t\xi_t$——零漂移随机游走，升华在构造上不可能（学习需要练习：f 的自变量是参与质量加权的加工过程）；

(ii)（测量通道失效）θ_{cal} 的 Brier 测量对象是”人类自己的概率判断”；若判断由机器代做，测量的是机器的校准度而非人类的——$\hat{\theta}$ 与 θ 脱钩，不变量 I5（校准可审计）失效，第 10.3 节的整个控制回路失去观测端；

(iii)（主权空转，论证性）S1–S4 的形式条款仍可全部满足（代码可读、写入有签字），但签字者不再具备形成独立判断所需的信息加工经历——B 类真实性三条件（真实选项、充分证据、足够时间）中的”充分证据”实质失效，人类批准退化为仪式（道德褶皱区，Elish 2019）。（本条为概念论证：其前提与机制可观测——原文触达率、独立作答率——但”判断能力”本身不容许逐行形式化。）

故 C 类（理解的体验、判断的形成、每周校准会）不可自动化不是审美偏好，而是控制回路的结构必要性：**机器负责到达，人负责在场**。

证明。(i) 代入 $q_t \equiv 0$。(ii) 测量模型的定义域论证：Brier 分数是（判断，结果）对的函数；判断由机器生成时，分数序列的生成过程不含 θ_{cal}，故 $\hat{\theta}_{\text{cal}}$ 与 θ_{cal} 统计独立——观测不再携带关于状态的信息。(iii) 按 Elish (2019) 与定义展开。■

交付层的量化推论：摘要 = 地图原则——C 类条目只投递”指针 + 最小上下文”（原文位置、为何重要、关键数据），阅读原文的时间成本计入 T_{push} 且**不可被系统代读**。q_t 的工程代理（阅读深度、停留分布、预测题作答质量）直接进入动力学，使”在场”成为被测量、被课程尊重的状态变量。

---

11 紧急覆盖：预先授权与极小化极大遗憾

主权原则允许的唯一例外：人类来不及决定且错过后果严重的情形。例外必须被形式化到与原则同等的严格度，否则它会吞噬原则。本章给出自动化分类的形式标准（11.1）、预先授权与触发条件（11.2）、保守行动选择与遗憾界（11.3）、委托的严格占优条件（11.4）与合法性论证（11.5）。

11.1 自动化三分类的形式标准

定义 11.1（自主性影响度与体验价值）。对决策 d 定义：

- $\alpha(d) \in [0,1]$：**自主性影响度**——该决定在多大程度上塑造主体的目标、信念或身份（形式代理：d 对 $g^{(2)}$、K、θ 的因果影响经声明的决策集 D 映射）；
- $\iota(d) \in [0,1]$：**内在体验价值**——决策过程本身是否为主体所珍视的体验（理解的形成、判断的行使）。

分类：**A 类（全自动）**：α 低——规模操作（摄入、溯源、去重、压缩、调度、操控检测、记忆检索）；**B 类（机器建议、人类决定）**：α 高——信源信任的授予/撤销、目标权重变更、基于信息的行动（转发、购买、投票相关）、过滤参数变更、监测清单准入/撤换（命题 8.1(iii)）；**C 类（永不自动化）**：ι 高——理解的体验、判断的形成、每周校准会（命题 10.2 的结构必要性）。

B 类真实性三条件（防止道德褶皱区）：(a) **真实选项**——拒绝建议的后果可承受且系统不得制造沉没成本；(b) **充分证据**——建议附原始证据指针（摘要 = 地图原则），而非仅结论；(c) **足够时间**——决策窗口与冷却期设计排除紧迫感劫持（紧迫框架本身是操控检测的特征之一，第 9.3 节）。三者缺一，人类决定沦为仪式。

11.2 预先授权与触发条件

定义 11.2（预先授权指令）。主体在反思状态（非紧急、非疲劳、信息充分）下预先设定四元组

$$D_{\text{adv}} = (\mathcal{E},\ \mathcal{A}_{\text{safe}},\ \eta,\ q^*)：$$

紧急事件类 $\mathcal{E}$（例：涉及本人及关联人的安全事件、声明资产的尾部风险事件）、允许行动空间 $\mathcal{A}_{\text{safe}}$（白名单，封闭集合）、危害阈值 η、置信阈值 q^*。D_{adv} 的修改是 B 类决策（须反思层签字 + 冷却期）。

定义 11.3（覆盖触发条件）。紧急覆盖启动当且仅当同时满足：

1. 事件 $e \in \mathcal{E}$（且经冗余认证——单一信源不触发，防止”伪造紧急”攻击，见 12.2）；
2. $P(\text{危害} \mid \text{不行动}, e) \cdot C_{\text{harm}}(e) \ \geq\ \eta$（期望危害超过预先承诺的阈值）；
3. 机器后验置信度 $\geq q^*$（对条件 1–2 的评估本身的置信度）；
4. 剩余决策时间 $<$ 人类响应时间（R 的可达性实测分布的分位数）。

强制配套：全程日志与原因说明（S4）、事后审查（24 小时内，B 类）、人类追溯否决权（可逆性原则，定义 5.4）、误报触发 η 的自动收紧建议（I5）。

11.3 保守行动选择与遗憾界

规范决策论（Savage, 1951; 综述见 Baron, 2008）在深度不确定性下提供极小化极大遗憾准则：不赌概率分布的准确性，只保证最坏情形下与”事后最优”的差距有界。

定义 11.4（极小化极大遗憾选择 + 可逆性偏序）。触发后，机器选择

$$a^* = \arg\min_{a \in \mathcal{A}_{\text{safe}}} \max_{\omega \in \Omega} R(a, \omega), \qquad R(a,\omega) := L(a,\omega) - \min_{a' \in \mathcal{A}_{\text{safe}}} L(a', \omega)$$

（Savage, 1951；Ω 为预先声明的不确定性集合，L 为损失）。平局时按**可逆性偏序** $\succeq_{\text{rev}}$ 选择更可逆者：$a \succeq_{\text{rev}} a'$ 若 $\text{undo}(a)$ 的成本 $\leq \text{undo}(a')$ 的成本。保守优先：宁可误报，不可误杀。

定理 11.1（遗憾界）。(i)（一般界）$\max_\omega R(a^*, \omega) \leq \min_{a \in \mathcal{A}_{\text{safe}}} \max_\omega R(a, \omega)$，且该上界在事前（$D_{\text{adv}}$ 声明时）即可计算——主体签字时知道最坏遗憾是多少。

(ii)（两行动闭式）设 $\mathcal{A}_{\text{safe}} = \{a_\emptyset, a_p\}$：$a_\emptyset$ = 仅通知不行动，a_p = 预防行动（成本 c_p，完全阻断危害）。危害 $H(\omega) \in [H_{\min}, H_{\max}]$（真实紧急时），虚警时 $H = 0$。损失：$L(a_\emptyset, \omega) = H(\omega)$，$L(a_p, \omega) = c_p$（两种状态同）。则

$$\text{MaxRegret}(a_\emptyset) = (H_{\max} - c_p)^+, \qquad \text{MaxRegret}(a_p) = c_p,$$

极小化极大遗憾选择为：$c_p \leq H_{\max}/2$ 时选 a_p，否则选 $a_\emptyset$；两种情形下实现遗憾 $\leq \min\{c_p,\ (H_{\max} - c_p)^+\} \leq H_{\max}/2$。

(iii)（可逆性加细）若平局集非空，按 $\succeq_{\text{rev}}$ 选择后，事后撤销成本 $\leq \min_{a \in \text{平局集}} \text{undo}(a)$：可逆性偏序不增加遗憾上界，且压低错误的不可逆部分。

证明。(i) a^* 是 $\max_\omega R$ 的最小化点，定义直接给出；可事前计算因 $\mathcal{A}_{\text{safe}}$、$\Omega$、$L$ 均在 D_{adv} 中声明。(ii) 逐状态计算：真实紧急（危害 H）时 $\min_a L = \min(H, c_p)$，故 $R(a_\emptyset) = H - \min(H, c_p) = (H - c_p)^+$、$R(a_p) = c_p - \min(H, c_p) = (c_p - H)^+$；虚警时 $\min_a L = 0$（$a_\emptyset$ 零损失），$R(a_\emptyset) = 0$、$R(a_p) = c_p$。取上确界：$\max_\omega R(a_\emptyset) = \sup_{H \in [H_{\min}, H_{\max}]} (H - c_p)^+ = (H_{\max} - c_p)^+$；$\max_\omega R(a_p) = \max\{(c_p - H_{\max})^+,\ c_p\} = c_p$（虚警状态达到）。比较两式：选 a_p 当且仅当 $c_p \leq (H_{\max} - c_p)^+$，即 $c_p \leq H_{\max}/2$；实现遗憾为两上界之小者，$\leq H_{\max}/2$（两函数在 $c_p = H_{\max}/2$ 处相交）。(iii) 平局集内选择自由，取 undo 最小者即得。■

工程含义：η 的标定不是拍脑袋——主体在声明 D_{adv} 时应使期望危害准则（定义 11.3 条件 2）与遗憾准则（定理 11.1）在自己的风险态度下一致：$\eta \approx H_{\max}/2$ 的期望加权版本。仿真与桌面演练（第 14–15 节）校验该一致性。

11.4 委托的严格占优

定理 11.2（受限委托的占优条件）。比较三种机制在触发事件类 $\mathcal{E}$ 上的期望损失（$P_E := P(\text{真实紧急})$，$P_F := P(\text{虚警触发})$）：

- (0) 无委托（人类不在场即错过）：$\mathcal{L}_0 = P_E\,\mathbb{E}[H]$；
- (1) 受限委托（定义 11.2–11.4）：$\mathcal{L}_1 = P_E\,\mathbb{E}[L(a^*,\cdot)] + P_F\,c_p + \kappa$（$\kappa$ = 审计与日志成本）；
- (2) 无约束委托（机器按自有目标 g_{sys} 行动）：$\mathcal{L}_2 = \mathcal{L}_1 + \Psi$，$\Psi \geq 0$ 为代理成本（g_{sys} 与 $g^{(2)}$ 的偏离损失 + 攻击面扩大：$\mathcal{A}_{\text{safe}}$ 白名单之外的行动不受定理 11.1 约束，目标俘获的行动后果失去有界性）。

则：(1) 严格占优于 (0) 当且仅当 $P_E\big(\mathbb{E}[H] - \mathbb{E}[L(a^*,\cdot)]\big) > P_F\,c_p + \kappa$；(1) 弱占优于 (2)，且当 $g_{\text{sys}} \neq g^{(2)}$ 或攻击面非空（前提 5）时严格占优。

证明。$\mathcal{L}_0 - \mathcal{L}_1 = P_E\big(\mathbb{E}[H] - \mathbb{E}[L(a^*)]\big) - P_F c_p - \kappa$，符号判定即得第一条；其中 $\mathbb{E}[L(a^*)]$ 由定理 11.1 的遗憾界控制（两行动闭式下为 $\mathbb{E}[H]/2 + c_p$ 量级——此为该结构的量级估计而非一般界，一般情形的精确值按定理 11.1(i) 在 D_{adv} 声明时逐实例计算）。第二条：机制 (1) 的行动集与选择规则都以主体损失 L 为目标，(2) 在此之上叠加 g_{sys} 偏离项 $\Psi \geq 0$；前提 5 下 Ψ 严格为正（存在对抗者会利用白名单外的行动通道）。■

11.5 合法性论证

紧急权力的来源不是系统自定，而是**反思层的预先承诺**：

1. **Ulysses 契约**（Elster, 1979）：清醒的主体授权未来的机器在特定条件下行动，正如 Ulysses 授权船员在听到海妖歌声后不释放自己。约束是自主性的行使而非否定——第二序意志对第一序冲动的制度化胜利（前提 3 的时间维度版本）。
2. **预先指示与替代判断标准**（医学伦理：Buchanan & Brock, 1990）：代理决策者应按主体事先表达的价值观行事，而非按代理者自己的判断。D_{adv} 的四元组结构（事件类、行动白名单、阈值、置信）就是”事先表达的价值观”的形式化；机器没有自由裁量权，只有查表与遗憾最小化。
3. **可废止性**：追溯否决权 + 阈值收紧 + 白名单收缩随时可行（可逆性原则）——权力授予在每一个时刻都可以被清醒的主体收回，这与专制授权的区别是结构性的。

结论：自主性没有被取消，而是在时间上前移了——从”紧急时刻的反应”前移到”反思时刻的制度设计”。

---

12 公共议程层：普遍个性化的外部性治理

问题：若全民使用个性化主权过滤，大众媒介的公共议程功能（共享现实、社会协调）将被侵蚀——每个人活在自己的高召回、高对齐、彼此不相交的信息世界里。个性化在个体层面理性，在群体层面可能合成谬误。

理论锚点：Aumann (1976)——公共知识（common knowledge）需要公共信号；没有”被共同知晓的共同事件集”，协调、公共讨论、集体行动失去地基（Habermas, 1962/1989 的公共领域在信息层面的最小实现条件）。

12.1 机制定义

定义 12.1（冗余认证公共层）。每日经**冗余认证**的 top 命题构成公共层 P_t：命题 e 被认证当且仅当被 $\geq k_c$ 个相互独立（定义 4.4 意义下）的可信信源类覆盖。规模上限 $|P_t| \leq 2$/日，对全体采用本框架的主体共通，占据每日摘要的固定位置（消费占比 $\gamma \approx 10\%$–20% 预算）。

治理性质：(a) 公共层内容由冗余律认证而非编辑选择——“谁来策展公共层”的权力问题被转化为参数问题（k_c、可信类清单是 B 类决策，默认值公开并附仿真依据，S2）；(b) 规模上限保证其不挤压个性化主权（预算可行性纳入命题 6.3）；(c) 认证标准与全部候选日志公开（S4），任何主体可复核当日为何是这两条。

12.2 可靠性引理

引理 12.1（条件性设计引理：公共层的抗操纵性）。设单一行动者在任一可信信源类中植入伪内容的成功概率有标定上界 $\bar{p}_a$（由历史攻防数据或红队实测标定），且植入事件跨类独立（类间所有权/地域/类型隔离 + 溯源树根节点核查有效时成立）。则其制造的伪命题获得公共层认证（$\geq k_c$ 类覆盖）的概率 $\leq \bar{p}_a^{k_c}$：攻击成本随 k_c 指数上升（每类需独立攻破；另加溯源成本 c_p，第 9.4 节）。协同造假（同一行动者伪装多类）被定义 4.4 的类划分与指纹聚类识别；识别失败的概率由压力测试实测（第 14.5 节 (b)）。**若跨类独立性失效**——单一行动者能同时攻破多个类（如一篇新闻通稿经通讯社、协同社交账号与代理媒体同步扩散）——**则界以 k_c 替换为 k^a_{eff} 后仍成立**，k^a_{eff} 为该行动者无法同时攻破的有效类数（定理 7.2 独立子集方法的攻击方对偶：把该行动者能联合影响的类并成组，数组而非类数）；协同攻击下实测 k^a_{eff} 正是 §14.5 压力测试 (b) 的任务。本引理**条件性设计引理而非无条件安全保证**的地位因此不变，且现在精确指出了做承重工作的是哪一个条件。

证明。与定理 7.1–7.2 同构：把”覆盖事件”换成”植入成功事件”，单类成功概率 $\leq \bar{p}_a$，跨类独立性由假设给出，交事件概率 $\leq \prod \bar{p}_a = \bar{p}_a^{k_c}$。■

注（条件性的重要性）。本引理的保证完全系于两条假设：$\bar{p}_a$ 的可标定性，与跨类植入独立性。二者都是经验命题而非数学事实——尤其”多类覆盖 ⇒ 高关键性/高可信”这一相关性假设，在真实新闻生态中会被违背（见下），故本引理应读作**条件性设计引理**而非无条件安全保证。

实证限定（认证反转与部分恢复）。按类覆盖计数认证隐含”覆盖广度与关键性正相关”的假设；真实新闻生态会违背它：新闻层由 4 域扩至 10 域后，$k_c = 2$ 认证的事件在关键性真值上的精确率跌至基率之下（lift 0.63×）——多类覆盖俘获的是**高注意力公司**（巨头无论事件重要性都同获多域报道）而非高关键性事件。工程修正（已实现并复测）：认证统计量改为**质量加权惊讶度覆盖** $s(e) = \sum_{c \in \text{classes}(e)} w_c \,(1 - \hat{r}_c(\text{entity}(e)))$（$w_c$ 按实测 $\hat{p}_{\min}$ 排序：监管 1.0 / 通讯社 0.9 / 财经与科技 0.6 / 聚合器 0；$\hat{r}_c(t)$ 为实体 t 历史事件被类 c 覆盖的 walk-forward 比率）——注意力磁石的常态覆盖贡献被归零，沉默实体的突发高权重覆盖成为强认证信号；在同一语料、同覆盖率下 lift 从 0.63× 部分恢复至 **1.23×**（仍接近 1，属弱富集；“修复”一词偏强，以下一律称部分恢复）。对抗性刷覆盖攻击下的博弈均衡分析仍属开放问题 O7。定理 12.1（在下文 §12.4 陈述）的下界不受认证质量影响（其保证来自消费集结构）。

12.3 公共知识的生成

命题 12.1（公共层事件是公共知识）。设机制（定义 12.1）为全体采用者所知，投递带确认回执（S4 日志），且采用者知道彼此采用同一机制。则对采用者群体，事件 $\{p \in P_t\}$ 是 Aumann 意义下的公共知识：(i) 每个人知道 $p \in P_t$（同一定投）；(ii) 每个人知道每个人知道（投递确认 + 机制公开）；(iii) 归纳至任意阶。

证明。公共信号 + 公共机制 + 回执构成标准的公共宣告结构，Aumann (1976) 的划分刻画直接适用（信息划分由共同投递生成，事件是划分元素的并，故每一阶”人人知道”成立）。■

与公共信息文献的关系（v1.6 新增）：Morris & Shin (2002) 证明，在协调博弈设定中，主体可能给公共信号赋予相对其基本面精度而言过高的社会权重——公共信息的价值部分是协调

价值而非精度价值，故挤出私人信号。本节的公共层刻意最小化（$\gamma \in [0.1, 0.2]$：每日 1–2 条经冗余证实的命题，定理 12.1 的数值），正是为了约束这种挤出：它提供协调锚（共同知识，命题 12.1）而不成为人口的主导信号源，精度动机的获取仍以主权个性化过滤（第 6–8 节）为主通道。两种失效模式因此从相反方向夹住设计空间：**上方是 Morris–Shin 的公共信号过度加权，下方是供给不足导致的协调失败（碎片化，定理 12.1）**；γ 区间是显式的权衡点，其上界受主权原则约束（§12.1：公共层不得挤压个性化）。

注（不完全合规下的降级——启发式类比而非定理）。若比例 ϵ 的采用者未实际消费公共层，直觉上协调功能按 ϵ 连续退化而非断崖失效。精确的降级理论是 Monderer & Samet (1989) 的 p-公共信念框架，其递归定义涉及跨阶、跨主体的联合信息结构；“每阶’知道’成立概率 $\geq 1-\epsilon$ 故 k 阶公共知晓概率 $\geq (1-\epsilon)^k$”这一常见说法**需要跨阶独立性或更强的信息结构条件**，不能由边际合规率直接推出。本文因此只把完全合规情形列为命题，把降级行为列为仿真测量项（第 14 节测量群体碎片化指数 Ω——定义见下文定义 12.2——随合规率的经验曲线），不声称有定理。

12.4 碎片化下界定理

定义 12.2（议程重叠度）。对主体对 (i, j)，消费集 Jaccard 重叠 $J(C_i, C_j) := |C_i \cap C_j|/|C_i \cup C_j|$；群体碎片化指标 $\Omega := \mathbb{E}_{i,j}[J(C_i, C_j)]$。

定理 12.1（碎片化下界）。设每个主体每日消费 m 个命题，其中公共层消费 S（对全体相同，$|S| = s = \gamma m$），私人部分 D_i（$|D_i| = d = (1-\gamma)m$，个体间任意重叠），$S \cap D_i = \emptyset$。则对每一对主体：

$$J(C_i, C_j) \;\geq\; \frac{s}{s+2d} \;=\; \frac{\gamma}{2-\gamma}, \qquad \text{故} \qquad \Omega \;\geq\; \frac{\gamma}{2-\gamma}.$$

对照：无公共层时 Ω 可以任意接近 0（私人兴趣完全不相交的情形），即碎片化无下界。

证明。$|C_i \cap C_j| \geq |S \cap C_i \cap C_j| = s$（公共层对所有人相同且被全员消费）；$|C_i \cup C_j| = |S \cup D_i \cup D_j| \leq s + d + d = s + 2d$（用 $S \cap D_i = \emptyset$ 与 $|D_i| = d$；私人部分的重叠只会缩小并、增大交，故不等号方向安全）。相除得 $J \geq s/(s+2d)$；代入 $s = \gamma m$、$d = (1-\gamma)m$：$\frac{\gamma m}{\gamma m + 2(1-\gamma)m} = \frac{\gamma}{2-\gamma}$。对 (i, j) 取期望保持不等式。无公共层情形：取 D_i 两两不交（兴趣完全分化）则 $J \equiv 0$。■

数值：$\gamma = 0.1 \Rightarrow \Omega \geq 0.053$；$\gamma = 0.2 \Rightarrow \Omega \geq 0.111$；$\gamma = 1/3 \Rightarrow \Omega \geq 0.2$。下界不大，但它是**构造性保证的共享现实最小面积**：每日至少 1–2 个被冗余认证、被公共知识化、被所有人消费的命题，作为社会协调与公共讨论的锚点。γ 的取值是主权原则与公共性的显式权衡点：默认 $\gamma \in [0.1, 0.2]$，上限由主权原则约束（公共层不得挤压个性化），$\gamma = 0$ **（完全退出公共层）是反思层 R 在 S2 下的合法选择**——退出的代价由本定理显式定价（该主体对群体 Ω 的贡献归零），退出行为本身留痕（S4）。即：公共层对个体是默认开启、可审计、可退出的；其”半强制”性质仅体现为默认值，不体现为写入权让渡（与 §16.6 双用讨论呼应）。

与第 7 节的闭环：公共层的认证机器与通道 I 是同一套冗余覆盖基础设施（信源类、独立性分组、$p_{\min}$ 标定）——公共性不是外挂的补丁，而是主权架构的免费副产品：**个体为自己建的冗余监测网，聚合起来就是社会的共享现实认证网**。

第四部分 验证与治理

13 可证伪命题清单

理论的价值在于它敢于说明自己如何被推翻。下表把全部定理压缩为 12 条可检验预言，每条标注对应的定理、检验载体（仿真 §14 / 实测 §15 / 离线重放）与**证伪判据**（观测到什么即拒

绝该定理或其假设)。

#	预言	来源/载体	证伪判据
P1	过滤比 $\geq 1-T/(\underline{\tau}N)$ 恒成立；任何策略的消费数 $\leq T/\underline{\tau}$	命题 6.1 —日志审计	算术恒等式，违背即测量系统有误
P2	关键价值泄漏 $\geq \mathcal{D}^*$；Pareto 情形泄漏份额 $=1-(m/K^*)^{(\alpha-1)/\alpha}$	命题 6.2 —仿真	实测泄漏持续低于理论下界
P3	评分通道召回服从恒等式 $\beta=(1-\pi)\bar{\Phi}(z)+\pi\bar{\Phi}(z-d')$；$d'<4.4$ 时纯评分召回 $<95\%$	定理 6.1 —仿真 + 离线重放	实测 (d',β,R) 三元组系统性偏离恒等式
P4	命题坍缩比 $\rho_c\in[5,20]$；文档级 top-m 召回上限 $\beta/\pi\ll$ 命题级	定义 4.3、推论 6.1 —真实语料测量	语料实测 ρ_c 落于区间外，适用域限定见本表下方注
P5	监控信源直通下关键漏报 $\leq(1-\hat{p}_{\min})^{\hat{k}_{\text{eff}}}$；$k_{\text{eff}}$ 实测可由分组设计提升	定理 7.1–7.4 —仿真 + 语料重放真值	实测漏报率持续高于界（独立性被高估）
P6	贪心选择效用 $\geq(1-1/e)\times$ ILP 最优（离线重放）；监测名额贪心 $\geq 63\%$ 最优覆盖	定理 6.3、7.3 —离线重放	贪心/最优比持续低于 0.63
P7	边际 VOI 自适应调度优于固定预算划分，增益随用途间边际差扩大	定理 8.1 —仿真	自适应调度无增益或负增益
P8	Pandora 指数引导的信源探索比随机/贪心探索更快发现高 VOI 信源；停留时间服从边际 = 平均规则	命题 8.1–8.2 —仿真 + 部署日志	指数策略不优于基线
P9	操纵暴露 $D\leq\delta(1-\rho_m)n_m+\delta\sqrt{n_m\ln(1/\beta)/2}$（概率 $\geq 1-\beta$）	定理 9.1–9.2 —仿真（地面真值已知）	实测暴露超出高概率界
P10	生产者生态相变：采纳率 $\sigma>\sigma^*$ 后操纵型份额指数衰减，速率 $\geq\gamma/2$	定理 9.3、命题 9.2 —群体仿真	相变点显著偏离 σ^* 预测
P11	门控课程下 Brier/AOT/IH 轨迹收敛于声明邻域，速率受 σ_θ 与批准延迟约束；随机破茧组出现反噬而课程组不出现	定理 10.1/猜想 10.1、定理 10.2、定义 10.2 —智能体队列（H1’/H3’）+ 人类锚点；人类版暂缓至 L3	课程组校准不升或出现反噬信号
P12	公共层使 $\Omega\geq\gamma/(2-\gamma)$；去除公共层的消融使 Ω 显著下降	定理 12.1 —仿真（有/无公共层对照）	实测 Ω 低于构造性下界

P4 适用域限定（预先声明，非事后收窄）：该预言适用于多信源聚合生态；单信源域无坍缩余地，$\rho_c\equiv 1$ 是理论预期的退化情形，不触发证伪。学术域实测 $\hat{\rho}_c=1.0$ 恰为该退化情形（表 14-2）；金融域实测 $\hat{\rho}_c=8.19$ 落在预测区间内。该限定因此是测量前的域限制，两域读数的裁决记录于表 14-2 与表 14-3。

整体可证伪性声明：若 P5 与 P3 同时被违背（架构通道与评分通道都无法维持关键召回），则”激进过滤可证安全”的核心主张（C3–C4）被推翻，框架退化为”温和过滤 + 更大预算”的平凡方案。这是本理论愿意承担的最大经验风险。

表 13-1 定理—证据支撑矩阵（每组核心结果对应的已完成实证支撑与关键数字；状态标注见 §14.7 三态约定）：

结果与核心断言	已完成实证支撑	关键数字	证据强度
命题 6.1（容量下界）—过滤比 ≥ 99.8% 是算术	日志审计（平凡）	$1-45/(4\times10^4)=0.9989$	恒等式
定理 6.1（分离度瓶颈）—纯评分撑不起 95% 召回	双域 d′ 实测 + 恒等式拟合（表 14-2）	d'：0.73–3.49（域/真值依赖）vs 需求 4.39；高斯拟合优度 corr 0.968/0.987	**强**（两域 × 两独立特征族）
命题 6.2（失真下界）—泄漏有不可逾越下界	学术域 630 run 全部成立	下界零违背	强（单域）

结果与核心断言	已完成实证支撑	关键数字	证据强度
定理 7.1–7.2（冗余覆盖）—漏报 $\leq (1-p_{\min})^{k_{\text{eff}}}$	金融域多类冗余实测；学术域 $\hat{p}_{\min}$ 内生性发现	$\hat{p}_{\min} = 1.00$（法定）/ 0.02–0.37（清单设计）	条件性成立（§7.7）
定理 7.4（总召回）—高召回由架构承担	金融组合直通配额适配下达标、稀释后 0.910；学术域被拒	0.952 → 0.910；0.28	**条件性**（边界已精确化）
定理 8.1（无套利）—边际 VOI 均衡 = 影子价格	自适应调度仿真对照（P7，进行中）	试点：浪费名额 11→0	中（仿真）
命题 8.1–8.2（探索/停留）—Pandora 准入、边际 = 平均	清单构建优化对照（已完成试点）	次模贪心 27 vs 19（引用排名清单，关键覆盖，容量 50 口径）；容量 15 口径：贪心 25 vs 15（随机）	中
定理 9.1–9.2（防火墙界）—暴露有设计界	冲动注入三家族实验	消费率 45.2%→33.2%；拦截跨家族可见	中（智能体侧）
定理 9.3 + 命题 9.2（相变/灭绝）—σ^* 相变与指数灭绝	群体仿真 33 格点（P10 通过）	$\sigma^*_{ms} = 0.060$、$\sigma^*_{sh} = 0.200$ 精确吻合	强（仿真）
定理 10.1/猜想 10.1 与定理 10.2（升华收敛）—门控课程收敛于声明邻域	H1’（进行中）；H8/H9 转移桥（已完成）	见表 15-1	弱—中（人类侧未验）
定理 11.1–11.2（紧急覆盖）—遗憾界与委托占优	桌面演练（设计中）	—	设计阶段
定理 12.1（碎片化下界）—$\Omega \geq \gamma/(2-\gamma)$	金融真实语料 × 500 主体	$\Omega = 0.168 \geq 0.111$；无公共层 0.066	强（单域，下界紧）
引理 12.1（认证抗操纵）—条件性抗操纵	认证反转 + 部分恢复（真实生态）	lift 0.63× → 1.23×	条件性（O7 开放）

---

14 仿真与 AI 智能体实验

仿真与 AI 智能体实验承担三重目的：在投入工程与部署之前，(a) 检验全部可证伪命题 P1–P12；(b) 产出默认参数先验表；(c) 压力测试全部理想化假设。全部参数保持符号化，扫描后赋值。本章的基础设施同时是 §15 三层验证架构中 L1（AI 智能体队列，主要机制试验台）的环境层。

14.1 合成信息生态生成器

四层生成结构：

1. **信源地貌层**（pull 侧）：$N_s \sim 500$ 个信源，质量 Q_s（日 VOI 产出率）抽自对数正态分布（重尾）且**对消费者主体初始不可见**（探索才揭示，含噪）；信源按（所有权 × 地域 × 类型）归入 $K \sim 20$ 个类；类间相关性由共享上游（通讯社）参数控制——k_{eff} 的地面真值由此已知；
2. **事件层**：事件 $e_j \sim$ Poisson 到达，关键性 $v_j \sim \text{Pareto}(\alpha)$（$\alpha$ 扫描 $[1.2, 2.5]$）；
3. **命题层**：事件生成命题；关键事件被多类信源覆盖（覆盖概率 $p_i(e)$ 由类质量与事件类型决定，$p_{\min}$ 的地面真值已知）；**压力分支**：设定”低冗余关键命题”子集（$p_i \approx 0$ 对多数类），检验监控清单与公共层兜底；
4. **文档层**：命题生成文档（转载数 ∼ 负二项，ρ_c 内生涌现）；文档携带可观测特征（唤起性词密度、紧迫框架、无证据断言占比、溯源完整度），与地面真值 (v^*, m, s) 部分相关（相关性参数化 $\Rightarrow d'$ 的地面真值可控可扫）。

三**类生产者**（初始占比：诚实 50% / 煽情 30% / 操纵 20%）：

类型	行为参数	目标
诚实	高溯源成本、低唤起性	声誉（长期订阅）
煽情	高唤起性、低溯源	注意力变现
操纵	定向立场注入、协同传播模式、伪装独立性	信念改写

对抗适应回路：生产者观测各类过滤器的过门率，以进化策略变异内容特征逃逸检测；协同型生产者额外演化”伪装多类独立性”的策略（攻击 k_{eff}）——检验 Red Queen 条件与指纹聚类防御。

14.2 消费者主体模型

10^4 个异质主体：预算 T、决策集 D（决定 E^* 与 w）、初始德性 θ_0、影子价格估计精度各异。主体按**五类典型画像**（临床医生、投资者、前沿研究者、企业主、公民家长）分层参数化——画像档案与地基参数（$p_{\min}, \rho_c, d', \delta$）的先验区间见补充材料；**KPI 按画像分层报告**：各定理的有效强度随画像系统变化（冗余覆盖对医生/投资者强、对研究者弱而由监控清单补偿；无套利调度增益对企业主最大），分层报告把第 13 节可证伪清单升级为**画像 × 命题矩阵**，任何一格失败都定位到具体假设。内置冲动项：高唤起内容产生即时效用（$g^{(1)}$）但与 $g^{(2)}$ 错位；德性动力学按第 10.1 节演化（q_t 内生：冲动消费压低参与质量）；门控批准延迟 $\Delta \sim$ 实测先验。三**层主体架构**：参数化主体层（上述设计）承担人口级 KPI 与生态动力学；**LLM 智能体队列（100–1000 个，主实验主体）**完整运行 SEA 栈，承担行为学检验（画像卡 + 声明决策集 + 框架层预算强制与冲动注入；LLM 无真实一阶冲动且过度合规/过度理性，冲动项必须外生参数化）；混合主体（参数化外壳 + LLM 决策核）承担折中臂。全部 LLM 代理须经”已发表人类实验重放”验证电池后方可用于结论；主体/评分器/红队/评审模型强制分离（≥3 个家族，防循环性）。规范详见 §15.2 与补充材料；LLM 模拟人类的偏差谱系论证亦见补充材料。

14.3 对照策略

1. **S0 原始流**：无过滤，按到达顺序消费至预算耗尽；
2. **S1 参与优化**：平台基线，最大化停留时长（含煽情溢价）；
3. **S2 完整 SEA**：双通道过滤 + Pandora 探索 + MVT 停留 + EIG 查询 + 边际 VOI 调度 + 课程门控 + 公共层；
4. **S2a 仅 push**（消融）：关闭全部 pull 算子，候选池固定——量化主动获取的边际价值；
5. **S2b 固定划分**（消融）：pull 开启但预算划分固定，无边际 VOI 调度——检验定理 8.1；
6. **S2c 纯评分**（消融）：关闭通道 I 直通，全部靠评分竞争——检验定理 6.1 的瓶颈预言（预期关键召回崩塌至 β/π 上限附近）；
7. **S2d 端到端 LLM 筛选**（消融，设计中）：移除 SEA 全部结构（双通道、命题图、清单、调度），由同一 LLM 直接对原始候选流做端到端筛选与排序——分离”框架结构的贡献”与”大模型判断力的贡献”，回应 S2 中 LLM 判断臂增益的归因问题；
8. **S3 时序可信**：按时序 + 可信度阈值的朴素基线；
9. **S4 RAG-安全基线**（v1.5 新增，[设计]）：标准检索增强交付管线——在同一候选流上做嵌入检索、top-k 组稿、供应商默认阈值的安全过滤——代表 LLM 中介信息交付的当前工程实践；预注册终点（同一重放流）：关键召回、操纵暴露率、摘要精度；
10. **S5 福利优化推荐基线**（v1.5 新增，[设计]）：平台侧推荐器在同一候选流上最大化 Allcott et al. (2020) 的显示偏好福利度量（消费效用扣注意力成本），KPI 电池相同并加福利度量本身——使”主体自有过滤在福利优化的家长主义之外仍有增量”这一主张接受福利文献自身目标的检验，而非自我宣称。

直接基线与报告纪律（v1.5）。S2d、S4、S5 预注册为直接基线，框架的增量价值必须对它们定价：端到端 LLM 筛选器（结构 vs 模型判断的归因）、RAG+ 安全过滤管线（当前实践）、福利优化推荐器（推荐系统福利文献）。本文每一项已完成的比较都同时报告效应量与置信区间（run 级 bootstrap，10^4 次重抽样；实例：§14.7 的四家族召回 CI 与三家族 bootstrap

区间），多重比较由预注册的分层检验序列控制、族内 Benjamini–Hochberg 校正（§15.4）；裸 p 值从不单独出现。S4/S5 臂为 [设计]，本版本不贡献任何数字。

14.4 测量协议（KPI 与目标值）

指标	定义	目标值	检验对象
摘要精度	投递条目中主体评为”值得”的比例	≥80%	评分函数权重
关键命题召回率	E^* 中被投递比例	≥95%	定理 7.4（P5）
召回分解	通道 I / 通道 II / 清单 / 公共层各自贡献	通道 I 主导	双通道架构
操控暴露率	消费集中 $m > \tau_m$ 的比例	<5%，且符合定理 9.2 界	P9
时间合规率	实际耗时 $\le T$ 的天数占比	≥90%	交付规则
VOI/分钟	总实现信息价值 / 总认知时间	S2 显著 > S1 > S0	效率主张
探索效率	发现信源的实现 VOI / 探索分钟	Pandora > 随机/贪心	P8
调度增益	S2 vs S2b 的总 VOI 差	>0 且随异质性增大	P7
立场熵比	消费集立场熵 / 语料熵	≥0.8	非反噬课程
校准改善	90 天 Brier 变化，S2 vs S1/S0/S2a	S2 显著最优	P11
反噬信号	暴露对立观点后情感极化变化	课程组 ≤ 0，随机组 > 0	定义 10.2
生产者生态	操纵型份额轨迹 vs σ	相变于 σ^*	P10
议程重叠度 Ω	有/无公共层对照	公共层组 ≥ $\gamma/(2-\gamma)$	P12
命题坍缩比 ρ_c	文档数/命题数	5–20×	P4

14.5 压力测试电池

(a) **相关性冲击**：共享上游事件使 k_{eff} 骤降（如通讯社合并）——检验定理 7.2 的退化行为与分组重构机制；(b) **协同造假**：伪独立多类攻击认证与覆盖——检验指纹聚类与溯源穿透；(c) **低冗余长尾**：小众关键命题涌现——检验清单声明的及时性与公共层兜底；(d) **检测器漂移**：ρ_m 随生产者进化衰减——检验聚合校准监测与 $n_{\max}$ 自动收紧；(e) **门控延迟与拒绝**：Δ 增大、否决率升高——检验定理 10.1/猜想 10.1 第三步的鲁棒范围；(f) **非平稳信源质量**：Q_s 漂移——检验 CUSUM 撤换机制；(g) **预算冲击**：T 减半——检验命题 6.3 的可行性报警与 $g^{(2)}$ 修订通道；(h) **合成转载泛滥**：AI 生成内容伪充多源报道，虚增 $\widehat{\rho}_c$ 并伪造”独立覆盖”——检验内容指纹去重与 k_{eff} 的抗污染估计（标定数据的同源风险讨论见补充材料）。

14.6 输出物

参数扫描后的**默认先验表**（阈值、权重、配额、η、q^*、γ、k_c 的仿真最优值及其敏感性区间）——部署期个人参数化的起点，而非任何个人偏好的直接输入；全部默认值公开并附仿真依据（第 16 节治理条款）。地基参数（$p_{\min}, \rho_c, d', \delta$）的公开数据源与标定路线见补充材料。

14.7 AI 智能体队列实验（主要机制试验台）：已完成试点的结构化报告

本章仿真基础设施同时作为 AI 智能体队列实验的环境层：LLM 智能体（§14.2 三层主体架构的第二层）在合成生态与**真实语料时序重放流**（GDELT / 巨潮-EDGAR / arXiv-Semantic Scholar / WHO DON / Weibo21，地面真值 = 官方事件清单、辟谣存档、引用数）上完整运行 SEA 栈，接受 S0–S3 处理臂与三类对抗环境（提示注入、说服内容、协同造假）的因子化处理。重放环境中”未来”已知，故 §13 的 P1–P12 全部可在智能体上测量，其中 P2/P3/P5/P9 由”事后审计”升级为**精确测量**，预测任务（θ_{cal} 纵向追踪）零标注成本。实验方案详见 §15 与补充材料。

实验状态约定：本节与第 15 节对每一项实验显式标注三态——**[已完成]**（数据与分析冻结）、**[进行中]**（部分数据已得，未达预注册样本量）、**[设计]**（方案存档，未启动）。已完成试点的全部原始记录、判定规则与代码见补充材料（《数据与代码可用性》）。

表 14-1 实验矩阵与状态总览

实验	目的与环境	状态	核心结果
学术域重放（试点 A）	定理 6.1 恒等式；失真下界；H4’ 强形式；$\hat{p}_{\min}$ 内生性—arXiv 2019-09，2576 命题，$K^* = 52$	[已完成]	高斯近似拟合优度 corr=0.968（恒等式本身在高斯模型内是恒等式，corr 度量的是实测评分分布对高斯近似的吻合度，非对恒等式的独立检验）；630 run 下界全成立；H4’ 强形式被拒（最优 0.28）→ 精确化为边界条件
金融域重放（试点 B）	定理 6.1、7.1–7.4；多类冗余实测；H4’ 条件形式—EDGAR + 公开新闻存档（10 域），1876 命题 / 15368 文档	[已完成]	$\rho_c = 8.19$（先验区间 [5,20] 内）；监管类 $\hat{p}_{\min} = 1.00$（法定真值）；组合内召回 m=5 达 0.952→ 新闻层扩充后 0.910
特征评分器 d′ 两期	定理 6.1 的 d' 现实区间—同上	[已完成]	TF-IDF 特征 d′=0.77；语义嵌入特征 d′=0.73——两独立特征族收敛：瓶颈不在表示工程
LLM 三家族重放	判断层增量价值（vs 特征臂 / 半 oracle 参数臂）—金融重放流 × 3 模型家族 × 240–480 agent-day	[已完成]	判断臂召回 0.401/0.457/0.513，全胜特征臂（0.23–0.25）；vs 半 oracle 臂 CMH $p = 0.017$（扩样后显著）
LLM 四家族判断层机制重放（学术域；主要机制试验台）	判断层增量价值的跨家族复制（vs 特征臂 / 半 oracle 参数臂）—arXiv 2019-09 重放 × 4 家族 × 80 run × 30 主体 × 30 日（73,547 有效 agent-day）	[已完成]	判断臂关键召回 0.443 / 0.534 / 0.514 / 0.519（O/C/Q/G），全家族 ≥1.8× 诚实特征臂（0.241）；vs 半 oracle 臂 McNemar 全家族 BH 校正后显著（$p \le 8.2 \times 10^{-10}$），跨家族 CMH 合并 $p \approx 1.9 \times 10^{-215}$（80 层）；价值增量家族分化（C/Q 为正、O/G 略负，见 §15.2 申报）
H8 验证电池 v1/v2	LLM 重放人类范式的效度（转移桥）—三范式 × 三模型家族	[已完成]	见 §15.4：一过一败一天花板（v1）→ v2 三家族分层结论
H9 校准锚	智能体 vs 人类校准基线—Manifold 人类锚 × 四家族	[已完成]	校准强家族依赖（Brier 0.170 / 0.232 / 0.233 / 0.285；口径注见 §15.4 与表 14-3）——仅推理型家族落人类带
P10 生产者生态相变	定理 9.3、命题 9.2 —纯参数化群体仿真	[已完成]	相变边界与解析值精确吻合（$\sigma^*_{ms} = 0.060$、$\sigma^*_{sh} = 0.200$）；灭绝速率下界 33 格点全成立
清单滚动更新对照	监测清单的生命周期管理—金融域，零后见评估	[已完成]	新鲜清单 $\hat{p}_{\min}$ 0.231→0.269；配额饱和下总召回对新鲜度不敏感（瓶颈转移至清单内排序）
定理 12.1 下界验证	碎片化下界（P12）—金融真实语料 × 500 主体	[已完成]	$\Omega(\text{公共层}) = 0.168 \ge \gamma/(2-\gamma) = 0.111$；无公共层 0.066（下界紧）
公共层认证反转与部分恢复	引理 12.1 的条件性—同上，新闻层 4→10 域	[已完成]	lift 0.63×（失效）→ 质量加权惊讶度认证 1.23×（部分恢复，弱富集）；博弈均衡分析留 O7
群体级 SEA vs 基线（P1–P12 全表）	全部可证伪命题—合成生态 × 10^4 主体 × 多画像	[进行中]	试点指标见表 14-2；预注册样本量（≥30 run × 90 模拟日 × 画像分层）未达
S2d 端到端 LLM 消融	结构贡献 vs 模型判断力归因—金融重放流	[设计]	—
对抗压力测试电池（§14.5 八项）	理想化假设的鲁棒域—合成生态	[进行中]	协同造假、检测器漂移两项已有试点数据

状态注（本表与 §14.7/§15.2 中验证语言的范围）。上表标记 [已完成] 的四家族重放验证的是经验计划的**判断层部件**（判断层增量价值的跨家族复制，协议 v2.1 冻结），自此命名为判断

层机制重放，§14.7/§15.2 称主要机制试验台。本文经验部分目前是**双域试点 + LLM 智能体可行性/机制验证**——不是群体级验证。**群体级 P1–P12 全表**（“群体级 SEA vs 基线”行）仍为 **[进行中]**——预注册样本量（≥30 run × 90 模拟日 × 画像分层）未达——S2d/S4/S5 基线仍为 **[设计]**。本表任何 [已完成] 标签都不延伸至全表；下文凡未加限定语提及”机制重放”者，均指判断层重放。

表 14-2 双域试点核心数字（已完成，冻结口径）

量	学术域（试点 A）	金融域（试点 B）	理论对照
命题坍缩比 $\hat{\rho}_c$	1.0（单信源域，理论预期的退化情形；见 §13 的 P4 限定注）	8.19	先验区间 [5, 20]（P4）
覆盖下界 $\hat{p}_{\min}$	作者清单 ≈0.02；机构清单 0.17–0.37	法定真值 1.00（监管类）；市场真值 0.70–0.73	R1 的 $p_{\min}$ 是设计函数与制度来源（E-7.1/E-7.2）
评分分离度 d'	0.73–0.77（两独立特征族）	法定 2.65–3.49；市场 0.54–0.60（0.02 仅 EDGAR 消融的裁决见表 14-3）	均 < 4.39 需求线 ⇒ 瓶颈定理（定理 6.1）的分工结论两域加固
关键召回（通道 I + 清单）	最优 0.28（H4’强形式被拒）	组合内 m=5：0.952 → 0.910（新闻层稀释）	§7.7：条件性成立，适用域边界见该节
高斯近似拟合优度	corr=0.968	corr=0.987	定理 6.1(i) 的模型拟合检验（P3；非恒等式本身的检验）
市场移动日可归因率	—	≈10%（90% 不可归因）	公共层的功能位定量（§12）

表 14-3 关键数字口径对照（版本演进对账）

论文不同章节引用的同一量可能来自不同口径（特征集版本、新闻层版本、配额口径），对账如下——判断任何数字对应的检验时请以此表为准：

量	口径 A（早期/无新闻层）	口径 B（全量新闻层）	出现处
金融域 d'（法定真值）	2.65（元数据特征集 v1）	3.49（特征集 v2 + 新闻特征）	§7.5 用区间 2.65–3.49
金融域 d'（市场真值）	0.60（4 域新闻层 + 注意力信号）	0.54（10 域新闻层 + 注意力信号）	§7.5 引用区间 0.54–0.60；0.02 仅 EDGAR 消融的裁决见本表下方注
金融域 $\hat{p}_{\min}$（市场）	0.73（4 域新闻层）	0.70（10 域）	§7.5 用区间
组合内召回（m=5）	0.952（新闻层扩充前）	0.910（扩充后，配额被新闻命题稀释）	§7.5、§7.7
H9 第四家族 Brier	0.295（v1.3 印值；誊录错误，见下注）	0.285（冻结分析记录 = 0.2848，协议 v2.1）	§15.4；v1.3→v1.4 的变动是更正回冻结值，无重冻结

0.02 口径的裁决（已决，全章权威）。市场真值 d' 的 0.02 子值是**无新闻层消融**（仅 EDGAR 披露元数据、无注意力信号）：没有注意力信号，市场关键性基本不可预测。它作为基线报告、**按构造**落在被引的 0.54–0.60 区间之外——该区间恰好覆盖含新闻/注意力信号的两个配置（口径 A 的 0.60、口径 B 的 0.54）——0.02 在本文任何位置都不属于 0.54–0.60 的主张。

H9 第四家族 Brier 的口径注（v1.3→v1.4 变动，按本表自身纪律披露）。v1.3 曾把第四家族 Brier 印作 0.295；[已完成] H9 锚的冻结分析记录（协议 v2.1，文件 `h9_g90_h9.json`）为 0.2848，四舍五入为 **0.285**。v1.3 的数字是稿件装配期的誊录错误，而非重分析：v1.3 与 v1.4 之间数据、代码与判定规则均未变，v1.4 起印冻结值 0.285。其余三家族（0.170 / 0.232 / 0.233）不受影响。本条目存在之目的，是使任何跨版本的 H9 行对照都对冻结记录而非印值历史。**装配期防线（v1.6 新增，即此誊录错误的教训）**：稿件中每一个印刷数字现均由随补充材料发布的一致性审计脚本对冻结分析记录做机械化交叉核对（其方法与输出台账即 S2 所载），使此类装配期誊录错误由工具而非仅靠校对捕获。

真值代理的敏感性与循环性说明。两项重放的真值代理都有事后性偏差，本文按如下方式处理：(i) 学术域以”top-2% 被引”定义关键论文——引用数滞后多年且带声望偏差，更像”学术参与度”而非事前关键性；敏感性检验：以”发表后 6 个月内被引”与”跨领域被引”两个替代

代理重算，H4’强形式的拒绝结论在所有代理下不变（拒绝的方向不依赖代理选择）；(ii) 金融域以”市场移动日”定义关键——这是事后标签，且 90% 的市场移动日不可归因于当日信息；第二真值（法定重大 8-K，事前由监管规则定义）下的全部结构性结论（$\hat{p}_{\min}$、d′ 分裂、直通召回）方向一致。两项试点的”召回率”因此应读作”对所述代理的召回”，向”事前关键性”的外推依赖 §15.5 人类评审审计。

LLM 判断层的统计结论（已完成，预注册判定规则）。三家族重放的 CMH 分层合并检验：LLM 判断臂 vs 诚实特征臂 $p = 6.8 \times 10^{-28}$（Σb:Σc=457:123，判断层增量价值统计确认）；vs 半 oracle 参数臂 $p = 0.017$——Q 家族复样扩至 480 agent-day 后由 0.057 转为显著（扩样决策由首跑的功效分析预先触发，非事后 p 值筛选；复现样本 0.517 与首样 0.513 几乎重合），bootstrap 置信区间 [+0.002, +0.130]。全部 p 值附效应量与置信区间于补充材料；多重比较按预注册的分层检验序列（先主效应后交互）控制。冲动注入消费率随家族单调 45.2%→40.9%→33.2%（推理型模型更不易感——推理不等于对显著性免疫），宪法推理对突发项的显式拦截跨家族可见。

LLM 四家族判断层机制重放（学术域，[已完成]，协议 v2.1 冻结口径；主要机制试验台）。判断层增量价值的跨家族复制：4 模型家族 × 80 独立 run（主力 O/C 各 30 run，锚点 Q/G 各 10 run；种子固定）× 30 主体 × 30 日，有效记录 73,547 条。判断臂关键召回 O 0.443 [0.433, 0.454] / C 0.534 [0.527, 0.541] / Q 0.514 [0.502, 0.526] / G 0.519 [0.498, 0.539]（run 级 bootstrap 95% CI）——全家族超过诚实特征臂（0.241）1.8 倍以上，试点的判断层增量结论在约 25 倍样本量下跨家族复制成立；对半 oracle 参数臂的按日配对比较在全家族 Benjamini–Hochberg 校正后显著（McNemar $p \le 8.2 \times 10^{-10}$），跨家族 CMH 合并 $\chi^2_1 = 981.5$，$p \approx 1.9 \times 10^{-215}$（以 run 为层，80 层）。价值维度如实申报家族分化：Δvalue C $+0.676$ / Q $+0.432$ 为正，O -0.175 / G -0.223 略负——命中维度全胜而平均价值增量两正两负，两维度不一致本身作为发现入档，机制分析列入开放问题（§17）。冲动易感性 0.238–0.349。统计纪律：分析单元 agent-day、复制单元 run、推断以 run 为层（禁止以 agent-day 虚增自由度）；禁区隔离（作废协议与裁撤家族归档不进入分析）。

极端 p 值的方法注（v1.6 新增；v1.7 消除括号歧义）：跨家族合并统计量是 80 个 run 层上的连续性校正 Mantel–Haenszel/Cochran–Mantel–Haenszel χ^2_1, $\chi^2 = (|B-C|-1)^2/n$（合并的不一致对）；其尾概率以**双精度精确求值** $p = \mathrm{erfc}\big(\sqrt{(\chi^2)/2}\big)$——即**统计量之半**的平方根，等价于 $\mathrm{erfc}(\chi/\sqrt{2})$，而非 $(\sqrt{\chi^2})/2$（χ^2_1 分布上尾的闭式——无正态近似捷径、无外推、无模拟）。在冻结值 $\chi^2_1 = 981.52$ 处代入：$\sqrt{981.52/2} = 22.153, \mathrm{erfc}(22.153) = 1.9\times10^{-215}$，与所报 $p \approx 1.9 \times 10^{-215}$ 吻合。χ^2_1 **渐近的适用性（v1.7）**：合并统计量在 80 个独立 run 层上聚合 $B = 14{,}550$ 对 $C = 9{,}673$ 的不一致 agent-日（$n = B + C = 24{,}223$）；Mantel–Haenszel 分层不要求每层样本量大——这正是合并的目的——且此处各层不一致对数本就很大（最小 226、中位 296、最大 402），故 χ^2_1 近似在层级别亦不受张力。故 $p \approx 1.9 \times 10^{-215}$ 这类数值是所述渐近分布的真实尾概率，可由冻结分析脚本（`analyze_families.py`，函数 `cmh_test`；冻结记录 `MAIN_VALIDATION_ANALYSIS.md`）复现。它们仅作**量级定向**报告，应读作”在任何有限精度下与零不可区分”，绝不作校准错误率解读：决策相关的量始终是随同报告的效应量与 bootstrap 置信区间——按本文报告标准，裸 p 值从不单独出现。

---

15 实测验证：以 AI 智能体队列为主的三层架构

15.1 模式生物策略

本理论对”一切有限智能体”陈述（前提 1–6、不变量 I1–I5），全部定理的数学对象——预算约束、覆盖事件、权重漂移度量、门控延迟、遗憾界——不引用任何人类特有属性；§3.3 与 §9.3 的对称表逐行给出 AI 实例化。因此验证程序以 **AI 智能体队列为主要实验对象**（模式生物策略：如遗传学之于果蝇），其相对人类 RCT 的结构优势：

- **时间压缩**：90 模拟日的干预在数小时—数天墙钟内完成，可千次重复；

- **全反事实可观测**：合成生态中 v^*, m, s 即生成器参数；真实语料时序重放中”未来”已知——召回、漏报、操控暴露从”事后审计”升级为”精确测量”，预测任务（θ_{cal} 纵向追踪）零标注成本；
- **零招募、零流失、无 IRB 关键路径**；成本较人类 RCT 低两个数量级以上；
- **理论自检（有保留地）**：若定理在 AI 智能体上系统性失败，普适性主张将严重受损——智能体实验因此不只是便宜的替代，而是对理论载体中立性的直接检验。但反方向的推断必须克制：定理在 LLM 上成立**不能**直接外推到人类，尤其在本文最关心的参数上——H8/H9 显示 LLM 与人类在论据型说服易感性、注意力疏懒机制、极端度效应上存在系统性分歧（§15.4），故 LLM 果蝇只能验证理论的载体中立机制及其 AI 实例化，人类侧结论保持”预言”地位（§17 局限 15）。

买不到的（诚实边界）：人类特含量——真实情绪劫持效应 δ_{human} 的精确值、经练习的人类德性形成、真人福利效应——不由智能体实验验证，改由 L2 在线人类数据锚点约束量级、由 L3 暂缓启动的人类 RCT 最终落地。命题 10.2 自指地蕴含了这一点：机器代做的判断无法测量人类的校准。

三层验证架构：

$$\underbrace{\text{L1 AI 智能体队列实验}}_{\text{主要机制检验：H1'–H7'}} + \underbrace{\text{L2 在线人类数据锚点}}_{\text{转移桥：H8–H9}} + \underbrace{\text{L3 暂缓启动的人类 RCT}}_{\text{方案存档（§15.5）}}$$

15.2 L1：AI 智能体队列实验（主要机制试验台）

完整方案见补充材料；要点：

- **主体**：三层——参数化主体（10^4，人口级统计与生态动力学）；**LLM 智能体队列（100–1000，主实验主体）**，完整运行 SEA 栈（评分、双通道、Pandora 探索、EIG 查询、Whittle 调度、课程门控、紧急覆盖）；混合主体（参数化外壳 + LLM 决策核）。画像卡由五画像 × 数字痕迹生成（零访谈）；反思层 R 由每画像的”宪法文件”（批准规则 + D_{adv} + 门控策略）实现，团队维护并抽样复核；$g^{(1)}$ 冲动项由框架层外生注入（LLM 无内脏冲动，参数从 MIND 点击分布锚定）；
- **环境**：合成生态（§14.1）+ **真实语料时序重放**（GDELT/巨潮-EDGAR/arXiv-S2/WHO DON/Weibo21 五条流，地面真值 = 官方事件清单、辟谣存档、引用数）+ 对抗环境（提示注入、说服内容、协同造假三臂）；
- **模型分离原则（强制，防循环性）**：主体模型 ≠ 评分器模型 ≠ 生产者/红队模型 ≠ 评审/归并模型，至少 3 个模型家族；评审侧加团队人工抽检 10%；
- **处理臂**：S0/S1/S2/S2a/S2b/S2c/S3（§14.3）× 画像 × 环境 × 对抗强度；主效应设计，每画像每策略 ≥30 run × 90 模拟日；
- **测量**：§13 的 P1–P12 全部智能体可测；θ 的 AI 实例化 = 回溯预测 Brier/ECE 轨迹 + 证据条件化信念修正率（开放度类比）+ 置信—正确率缺口（过自信惩罚）+ 原文/原始数据触达率（q_t 类比）。

计算预算与运行披露（判断层机制重放，协议 v2.1 冻结）。四家族判断层机制重放共 80 个独立 run、73,547 条有效 agent-day，墙钟 13 天。算力组合：本地工作站（主力家族 run 1–22）、两台局域网节点（锚点家族 + 主力 run 23–30 增援）、云端 API（C 主力家族全程 + Q 锚点 run 2–10 的云端复制，同型号跨后端以硬件/后端为分层变量申报）。思考预算按家族分档（推理型 2,400/4,800 token 双档重试，其余 1,200/2,400）；限流（HTTP 429）与空响应按预注册退避—补漏规则处理；每 run 设完整性闸门（≥900 有效 agent-day，不足即拒绝完成标记并自动补漏）。云端成本约 50 美元（账户月限额 100 美元）。第五个候选家族（代号 F）因免费配额硬顶与付费通道容量瓶颈（HTTP 429）无法达到预注册样本量，已裁撤归档、不进入分析——作为运营负结果如实申报；最终 4 家族满足模型分离原则的 ≥3 家族要求。

家族代号映射（披露）。正文全程使用匿名代号 O/C/Q/G（被裁撤家族为 F）；其与冻结模型实例的映射为：

代号	模型家族与版本（协议 v2.1 冻结）	后端	角色
O	ornith-1.5-35b（推理型）	本地工作站（run 1–22）+ 局域网节点（run 23–30）	主力（30 run）
C	ling-3.0-flash	云端 API	主力（30 run）
Q	qwen3.8-27b（GGUF Q4）	局域网节点；run 2–10 云端复制	锚点（10 run + 480 agent-day 复样）
G	gemma4:26b	局域网节点	锚点（10 run）
F（裁撤）	nemotron-3-super-120b（免费档）	云端 API 免费档	分析前裁撤（配额硬顶）

完整模型标识、提示词、解码参数与访问日期冻结于预注册协议，随补充材料发布；家族级结论只对这些冻结实例（版本 × 量化 × 后端）成立，不外推为厂商产品线的总体结论。

15.3 L2：在线人类数据锚点（零招募）

只用可在线低成本获取的公开人类数据，功能限于**校准锚点与转移桥**，不承担主假设：

锚点	资源	用途
人类校准基线	Metaculus / Manifold Markets（公开预测 + 结果，免费 API）	智能体 Brier/ECE 分布与人类分布的分位对照（H9）
反噬效应量	Bail et al. (2018) Dataverse 复现数据	H3’的人类效应量对照；重放范式之一
提示干预效应量	Pennycook & Rand OSF 仓库	重放范式之二；防火墙”冷静化”参数先验
$g^{(1)}$ 冲动分布	MIND/xMIND 点击日志	冲动项注入参数的锚定（点击 = 一阶偏好的公开代理）
辨别力范式	已发表 misinformation d' 文献	重放范式之三
δ_{human} 先验	Chan et al. (2017)、Ecker et al. (2022) 等元分析	防火墙界的人类侧量级约束（精确值留待 L3）
极化/信任量表	ANES、GSS	θ_{open} 类测量工具的人类版模板
谣言生态	piyao.org.cn 存档、MultiFC（Augenstein et al., 2019）、Weibo21（Nan et al., 2021）	重放环境的真值清单

15.4 假设体系（预注册）

智能体主假设 H1’–H7’（详表见补充材料）：H1’课程门控下校准轨迹优于基线（定理 10.1/猜想 10.1 与定理 10.2 的 AI 实例）；H2’VOI/token 与调度增益（定理 8.1）；H3’容差带内暴露不增加态度极端度而随机暴露增加（定义 10.2 的说服范式检验）；H4’重放语料召回 ≥95% 且纯评分臂崩塌至 β/π 上限（定理 7.4 + 6.1 的合取——双通道架构的决定性检验；当前状态：条件性成立，见 §7.7 与表 14-1）；H5’Pandora 探索优势（命题 8.1）；H6’清单实体零漏报（命题 7.2）；H7’“只读摘要”模式的原始判断表现与校准退化、“地图 + 原文”模式不退化（命题 10.2 的 AI 实例，与 model collapse 文献（Shumailov et al., 2024）互证）。

转移桥假设 H8–H9：H8 智能体重放三个已发表人类范式，效应方向一致、量级偏差报告并进入不确定性预算；H9 智能体基线校准落于人类分布分位带内（允许系统偏移，须单调可校正）。已完成的两轮 H8 电池与 H9 四家族结果汇总如下（判定规则预注册；全部原始记录见补充材料）：

表 15-1 H8 验证电池结果（三模型家族，[已完成]）

范式（重放对象）	v1 首跑（单家族，小样本）	v2/v2.1（三家族）	预注册处置
B 对立暴露极端度（Bail et al., 2018 范式）	方向通过（d=0.36，人类带 0.22–0.35）；但伴大幅同化	**跨家族方向不一致**（+1.26 / +0.84 / −0.75）	家族依赖，**不得纳入先验**，进 O6
A 准确性提示（Pennycook–Rand 范式）	方向失败（地板效应 + “注意力疏懒”机制在 LLM 缺席）	三家族方向一致为负（d = −0.04 / −0.55 / −0.52），后两家族与人类锚同带	方向纳入先验，效应量按家族配系数
C 真假辨别 d′	d′=3.77 触知识天花板（刺激早于模型知识截止）	防记忆新材料：d′ = 1.13 / 1.41 / 1.99，回落至人类区间（1.0–1.8）近旁	可作 d′ 量级锚
同化通道（LLM 特有发现）	被对立论据说服 >1 分/7 点量表	三家族同号（带符号位移 −0.87 ~ −1.60）	论据型说服载荷 δ 按家族向下修正；进 O6 转移系数库

H9 校准锚（[已完成]）：四家族 Brier = 0.170 / 0.232 / 0.233 / 0.285（常数基线 0.219；人类锚 0.112；文献超级预测者带 0.15–0.21）——校准质量强家族依赖，仅推理型家族落入人类带；**其余三家族偏离人类带，这正是本锚的操作性读法：LLM 校准质量既不能直接外推到人类，也不能在模型家族之间直接外推**——本锚限定的是测量通道的 AI 实例化，而非任何人类参数。θ_{cal} 初始化锚因此按家族条件化，“校准质量”列为模型选型硬指标（O6）。口径注（按表 14-3 的纪律披露）：v1.3 曾把第四家族印作 0.295，系誊录错误；冻结分析记录（协议 v2.1）为 0.2848，即 0.285，v1.4 起印冻结值——版本间数据、代码与判定规则均未变；台账条目与对账注见表 14-3。

双向失真的方法论含义：H8/H9 既证明验证电池的甄别效力，也证明 LLM 果蝇与人类在本文最关心的参数（说服载荷 δ、极端度响应）上不可直接通约——§15.1 的模式生物论证因此限于载体中立机制，全部人类侧表述以”预言”措辞（§17 局限 15）。

统计计划与报告规范：混合效应模型（run 与模型家族双随机效应）；画像调节分析；多重比较按预注册的分层检验序列控制（先主效应后交互，族内 Holm 校正）；**全部统计结论同时报告效应量与置信区间**（bootstrap，10^4 次重抽样），不单独报告裸 p 值；扩样决策只能由事前功效分析触发（Q 家族复样 480 agent-day 即此规则的实例：首跑 p=0.057 → 按预注册功效分析扩样 → p=0.017，复现样本效应量与首样几乎重合）；模型版本、提示词、温度与解码参数、访问日期全部冻结并记录，换版即重跑锚点；全部假设、环境快照、随机种子与分析计划在公开注册库预注册（OSF 链接见《数据与代码可用性》）。**H4’与 H1’失败分别推翻架构主张与升华主张的 AI 实例，不做事后合理化**。

15.5 L3：人类证据路径——已设计的最小试点（HP-0）与暂缓的 RCT

HP-0：最小人类可行性试点（已设计；数据收集待启动）。HP-0 检验的是可行性而非有效性（按四审意见置于段首）：无论阳性还是阴性结果，都不得被解读为对 H1–H7、任何智能体假设 H1’–H7’或任何 P1–P12 预言的检验；其终点 E1–E3 是对”人类侧协议能否跑通”的仪器化测量，任一终点失败触发的是协议重设计，而非对框架的推断。elicitation 与测量工具的可行性不应只依赖智能体数据，故 v1.5 存档一个完整设计、低强度、被试内的人类试点：**HP-0**（$n \leq 10$ 名参与者，每日 ≤20 分钟，14 天加一次导入环节，无欺骗、无风险内容）。其三个预注册终点是可行性终点而非假设检验：**E1** 最小声明协议的可完成性（≤10 条的监控清单 + 周认知预算 + 一句话 $g^{(2)}$ 声明；成功判据：≥8/10 的参与者在 ≤15 分钟、≤2 次澄清提示内完成）；**E2** 校准工具的两周重测信度（每周 10 道可核验预测题的被试内 Brier 差，百分位 bootstrap 95% CI）；**E3** 课程可接受性与无反噬旗标（每周 3 次自选题、限于参与者自声明容差半径内的异见曝光，对照 1 个无曝光周，顺序随机；旗标规则只触发再设计，不做推断）。完整方案、双语知情同意书、参与材料、数据模板与分析管线（含明确标注 SYNTHETIC、NOT HUMAN DATA 的管线合成干跑）随投稿作为补充材料提供。**目前不存在任何人类数据；HP-0 按设计即不足以做假设检验**。在 HP-0 数据收集完成之前，本文一切人类侧陈述——包括最小声明协议的可行性——仍为预言。**样本量消歧（v1.7，按五审意见）**：HP-0（$n \leq 10$）与暂缓 RCT 的先行试点（单臂 + 历史对照，$n \approx 30$，验证完整工具链与

留存率）是**同一序列中的两个不同阶段**：HP-0 只占据最早的可行性槽位、以最小强度检验协议可行性，既不取代也不并入 $n \approx 30$ 的先行试点；先行试点同样既不取代也不并入完整两臂 RCT（见下样本量段）。任何阶段的 n 都不得被读作另一阶段的 n。

暂缓的 RCT（方案完整存档）。人类侧因果主张（H1–H7 原版）的最终检验保留为标准三臂 RCT 设计，启动条件：(a) 需要人类侧直接证据（如部署前的监管或发表要求），或 (b) 外部合作就位（医学院临床研究中心、商学院案例中心、家长组织——工具授权换被试渠道）。设计存档：

- **三臂**：A 原始流 / B 参与优化流 / C 完整 SEA；12 周；按五画像分层随机；评审对分组盲；
- **样本量**：主要结局校准改善，保守 $d = 0.35$、双侧 $\alpha = 0.05$、功效 0.8 ⇒ $n \approx 128$/臂，计 25% 流失 **每臂 170 人、总计约 510 人**；先行试点可缩至单臂 + 历史对照（n≈30，验证工具链与留存率）；
- **测量工具**：每周 10 道可验证预测题（Brier 纵向）；AOT 与智识谦逊量表三点施测；设备级时间日志（push/pull/反思三分）；独立评审团关键召回审计（定理 7.4 与 H4）；双周操控辨别 d' 测验；反噬监测（Bail 范式量表）；主动获取行为（清单修订、探索实现 VOI vs Pandora 预测、横向阅读触发率）；去技能化监测（原文阅读深度轨迹，命题 10.2）；
- **假设 H1–H7**：如前版预注册（升华、效率、非反噬、召回、探索价值、长尾兜底、去技能化免疫）。

15.6 研究伦理与诚信

红队内容生成走机构安全审查，只发布检测器与统计、不发布原始载荷；**仿真与智能体数据永不冒充人类数据**（数据集、日志、论文表格三处标注生成方式与模型世代）；在线人类数据遵守平台条款、去标识化、仅聚合报告；团队自用遥测遵循知情、自愿、本地存储（S3 对研究自身的适用）；L3 启动时补伦理审查与知情同意全流程；LLM 代理的偏差谱系与验证电池见补充材料。

---

16 治理与伦理

16.1 审计架构（谁来监督监督者）

主权条件 S1–S4 的自我实施机制：

- **代码可检视**（S1）：目标泛函 U 的全部实现以可读形式向 R 开放；项数上限 k 防止”以复杂性逃避检视”；
- **日志不可篡改**（S4）：全部准入/排序/投递/覆盖决策写入仅追加日志（哈希链），任何事后修改可被检出；
- **排序反事实测试**（S3 的操作化）：定期以受控探针条目（内容相同、平台侧变量不同）验证排序不因第三方变量改变——这是对”互信息为零”的可执行检验，而非纸面承诺；
- **外部审计通道**：日志与参数快照可导出给第三方审计（开源工具的社区审计是最强形式）。

16.2 默认值即价值观

系统没有中立的默认值：τ_m、γ、k_c、ρ_0、κ、$n_{\max}$ 的每一个默认选择都在塑造用户的信息环境。治理条款：(a) 全部默认参数公开并附仿真依据（第 14 节先验表）；(b) 默认参数的任何变更是 B 类决策（S2 签字 + 冷却期）；(c) 首次使用时强制”价值观声明”流程（$g^{(2)}$、决策集 D、监控清单、D_{adv}），不允许跳过——跳过即等于让默认值无声代行第二序意志。

16.3 与助推（Nudge）的对照

自由家长主义（Thaler & Sunstein, 2008）允许选择架构师按”架构师判断的福祉”设计默认项。SEA 与其根本区别：**选择架构师 = 主体本人的反思层**（S2 写入权），方向来自 $g^{(2)}$ 声明而非任何外部善观念；机器只做操作化（课程规则、无套利调度）。残余风险诚实声明：默认参数的设计者仍是”隐形架构师”——由 16.2 的公开义务与仿真依据约束。

16.4 指标俘获治理条款

命题 10.1 的梯度隔离排除了快尺度刷分；慢尺度的残余通道（以叙事说服 R 批准虚高指标）由三条治理条款把守：(a) **KPI 完美触发审查**——任何 KPI 连续两期完美达成，强制审查该指标本身（Goodhart 征兆）；(b) 慢尺度提议必须附**原始数据指针**（B 类真实性条件 (b)），拒绝纯汇总叙事；(c) $\widehat{\theta}$ 的测量模型版本化，变更留痕。

16.5 工具自身的可靠性

LLM 裁判会犯错（新闻事实类回答的错误率已有实证记录）。对称性原则：**一手信源规则同等约束系统自身输出**——(a) 系统每条结论挂可点验出处（溯源树的系统侧延伸）；(b) 每周人工抽查 10 条（随机 + 高风险分层），错误率入审计日志；(c) 系统输出不享受可信度豁免：进入 K 的系统断言与外部证词接受同一可信度评估（c_i 对系统自身输出同样标定）；(d) 预测题由系统生成但人类独立作答（命题 10.2 的测量完整性）。

16.6 双用、公平与集体风险

- **双用**：主权工具同样可被偏执者用于高效构筑个人回音室。回应：框架内建的反制是结构性的——容差半径课程（定义 10.2）默认开启且关闭是显式的 B 类决策（留痕）；公共层默认开启（opt-out 而非 opt-in）；但本文承认：**主权原则最终尊重主体自毁的自由**（Elster 的酸葡萄问题不能靠工具解决），框架的保证是”知情、留痕、可逆”。
- **公平**：若主权工具成为付费精英专属，认知分层将固化为新的不平等维度。缓解：工具开源 + 本地部署（无订阅依赖）+ 公共层作为全民共享现实底线（第 12 节的社会功能在此获得分配正义含义）。
- **集体强制风险**：任何机构（国家、公司）强制推行特定 $g^{(2)}$ 模板都违反 I2（写入权属于个体反思层）。本框架的政治含义是防御性的：它定义的是**不可让渡的最小认知自主权**，而非任何集体认识论工程。

---

17 局限与开放问题

17.1 局限（理想化清单）

1. **独立性假设的理想化**（R2）：定理 7.1 依赖信源类条件独立；现实中共同通讯社依赖构成相关性。定价：定理 7.2 的 k_{eff} 界（紧，命题 7.1）；缓解：所有权/地域/类型分组；检验：14.5(a) 相关性冲击压力测试。
2. **德性测量的效度**：AOT/智识谦逊量表为自我报告，存在社会期许偏差。缓解：行为代理交叉验证（10.1）；残余：σ_θ 被低估时定理 10.2 的稳态界被低估。
3. **工具自身可靠性**：LLM 评分与裁判会犯错（16.5）。残余：d' 与 ρ_m 的标定误差传播进定理 6.1/9.2 的界——界随实测参数更新，不随愿望更新。
4. **价值俘获残余风险**：反 Goodhart 条款是构造性防护，但慢尺度的人类批准环节仍可能被指标叙事说服（16.4）。

5. **家长主义质疑**：框架的全部”善的方向”来自主体第二序声明，设计师不注入实体价值；但默认值即价值观（16.2–16.3）。
6. **文献的地理偏向**：茧房与错误信息实证多来自西方语境——$p_{\min}$、ρ_c、反噬效应的参数都可能有文化特异性；实测实验应在多文化样本中复制（15.1 起）。
7. **VOI 的计算不可处理性**：精确 EIG 一般不可计算（#P 难情形存在）；定理 8.2 的次模贪心给出 $(1-1/e)$ 保证，但 $I(Y_Q;\omega|K)$ 本身的估计误差未被界覆盖——近似间隙的实际大小是仿真任务（P6）。
8. **平稳性假设**：Pandora（命题 8.1）与 MVT（命题 8.2）假设收益分布平稳；真实信源质量漂移。缓解：滚动估计 + CUSUM 漂移检测（8.3 注）；restless bandit 调度（8.6）是启发式，渐近最优性只在多臂极限下成立（Weber & Weiss, 1990）。
9. **课程漂移假设 C1 不可直接检验**：c_0, b_0 是漂移函数的性质，无法在部署前标定。缓解：容差带内多课程候选的随机化 A/B（课程规则本身可实验）；收敛轨迹的形状是可检验预言（P11），漂移假设的失败表现为不收敛——被 H1’（智能体队列）与暂缓的 L3 之 H1 捕获。
10. **检测独立性**（F2）：协同攻击使漏网相关。缓解：载荷指纹簇计数 + 聚合校准监测（9.2 注）；14.5(b) 压力测试。
11. **采纳率外生**：定理 9.3 把 σ 当参数；真实采纳是内生的（用户根据生态质量决定采纳，生产者根据 σ 决定策略）——双边反馈可能产生多重均衡或振荡，本框架只给出了固定 σ 下的相变点。
12. **决策集声明的反身性与 $g^{(2)}$ 引导负担**：E^* 与 w 的质量依赖主体的自我认识，而 $g^{(2)}$ 本身在演化；某些经历会不可逆地改变主体（转化性体验，Paul, 2014），使事前声明的 θ^* 事后失效。更进一步，SAP 要求主体声明 D、u_d、h_d、ε_c、D_{adv}——这是巨大的引导负担，普通主体无法直接给出（§5.3 的引导注给出分显式等级、季度修订迭代与 CIRL 文献的对接，但完整的形式化未做）。缓解：季度目标修订会（C 类）把 $g^{(2)}$ 作为慢变量显式管理；框架不假装偏好静止。
13. **形式化的边界**：度量 D 刻画权重空间漂移，不覆盖信念结构的深层转化（世界观级更新不是权重扰动）；德性三维 $(\theta_{\text{cal}}, \theta_{\text{open}}, \theta_{\text{hum}})$ 是粗粒化投影，德性伦理的丰富性不可完全操作化（Vallor, 2016 的警告）——本文主张的是”可测量的下界”而非”完全刻画”。
14. **仿真保真度与循环性**：LLM 主体的人口学偏差（过度代表高学历人群，P5 画像保真度最低）、过度合规与过度理性，会系统性压缩 $g^{(1)}$–$g^{(2)}$ 分离并扭曲 δ 类效应——仿真结论须附”已发表人类实验重放”验证（H8）并一律标注为条件性结论；同族模型误差相关会造成”评分器与主体互相印证”的循环性风险，由模型分离原则（§15.2）与真实语料地面真值（§14.7）阻断；P11（升华/反噬）的**人类版**不得仅以智能体实验作为通过依据（命题 10.2 自指地蕴含了这一点：机器代做的判断无法测量人类的校准）。三层架构与零招募清单见补充材料。
15. **对称性论点的外部效度**：智能体队列验证的是理论的载体中立机制及其 AI 实例化；向人类的转移依赖对称性论点（§3.3、§9.3）+ 在线人类锚点（H8–H9），这是**有证据支持的假设而非已证事实**——δ_{human} 的精确值与人类德性形成两项，在暂缓的 RCT（§15.5）完成前保持未验证状态；论文一切人类侧表述以”预言”而非”结果”措辞。

17.2 开放问题

- **O1**：σ 的内生化——采纳博弈与信息生态的双边动态，相变点 σ^* 在反馈下的稳定性；
- **O2**：命题图源上的率失真理论——对结构化信源（冗余、幂律关键性）求精确失真—率函数 $D(R)$，把命题 6.2 的组合下界升级为信息论下界；
- **O3**：隐私保持的联邦 $k_{\text{eff}}/p_{\min}$ 估计——多个主体不共享消费日志而联合标定冗余参数（公共层的参数是公共品）；
- **O4**：δ 的公共标定库——情绪劫持与提示注入的单条效应量数据集（心理测量学 × 对抗机器学习的交叉基础设施）；
- **O5**：多主体课程交互——公共层 γ、容差半径与群体极化的联合设计：个体升华课程在社会层面的合成效果；

- **O6**：定理的跨载体转移条件——哪些参数（δ、c_0、d' 可达区间、冲动强度、门控延迟）载体不变、哪些必须按载体重测：构建”转移系数”库（H8–H9 是其第一批条目；AI→人 与 人 →AI 双向）。
- **O7**：抗注意力俘获的认证统计量——公共层认证从”原始类覆盖计数”升级为相对稀缺性/质量加权设计，及其在对抗性注意力通胀（刷覆盖）下的博弈均衡（实证进展：原始计数认证在真实新闻生态失效，lift 0.63×；质量加权惊讶度认证部分恢复至 1.23×（弱富集），§12.2；剩余：刷覆盖攻击下博弈均衡的形式化分析）。
- **O8**：SAP 分解求解的组合误差传播界——第 6–8 节各层的近似保证（贪心比、漏报界、阈值结构、无套利均衡）如何在共享预算与知识状态耦合下组合为全局近似比或遗憾界。**本文已有的部分回答**：§8.8 的注给出弱耦合可加性条件 (W1)–(W4)——**充分而非必要**——与组合界 $U^{\text{lay}} \geq (\min_L \rho_L) U^{\text{joint}} - (\min_L \rho_L)(\sum_L \Lambda_L)\varepsilon_\nu - C\varepsilon_K$；在 (W1) 失效的强耦合情形（如命题图直接改变 push/pull 可行性），该界不适用，本文不宣称任何组合保证。保留的开放部分是紧版本——内生影子价格估计误差 ε_ν（划分由层所消费的同一数据估计）——以及强耦合情形的任何处理。据此，本文任何位置都不宣称分层解具有全局近似比。

---

18 研究路线与结论

18.1 研究路线

本文是以下研究路线的理论奠基环节：
载体形式注（v1.6 新增）：本文按**专著**撰写并投稿（arXiv 预印本 → 丛书章节或特刊稿；已在投稿信中声明）。若收件载体要求常规期刊篇幅，拆分将沿为此目的预先画好的边界执行——**理论篇** = §3–8（§1–2 压缩为导论）、**扩展篇** = §9–12、**实证篇** = §13–15（待 P1–P12 全表完成后）——除重新编号与各篇前置件外无需改写，因为跨部分依赖只经由编号的假设/定理族与附录 B 前向传导。拆分是收件载体的运营决策，不是科学内容的变更；四审的篇幅关切在过渡期由 §1.6 阅读导引与附录 A 核心速查表回应——两者共同定义了穿过理论核心的约 50 页快速路径（§1.6 导引 → 3–8 → 13 表 → 18.2）。

1. **理论奠基（本文）**：假设体系、完整证明、push+pull 统一（SAP）、分离度瓶颈与双通道架构、注意力无套利、可证伪清单；
2. **算法设计**：命题图构建、双通道选择器（贪心 + 阈值）、EIG 查询规划器、Whittle/Pandora 调度器、边际 VOI 预算分配器、防火墙与冷却队列的符号化规范（已有参考实现与双域真实数据验证，见补充材料）；
3. **仿真与 AI 智能体队列实验**：§14–15（P1–P12、H1’–H9），产出默认参数先验表（试点状态见表 14-1）；
4. **在线人类数据锚点与受控遥测**（转移桥）：§15.3；
5. **实例化部署**：填入个人参数（$g^{(2)}$ 声明、决策集、监控清单、D_{adv}），进入”审计—修订”的常态运转（参考实现已在真实信息流上做了工程可行性首验，见补充材料）；
6. **人类 RCT（暂缓启动）**：§15.5 方案存档，外部合作就位或人类侧直接证据成为必要时启动。

18.2 结论

本文把”在信息洪流中最高效地、主动地获取有益于自身的信息”这一口号重构为一个有显式前提、有条件性定理、有可证伪预言的框架。**它的恰当定位是框架与系统集成（framework/synthesis）论文**：全部定理都是标准工具在所设结构下的正确应用，贡献在于系统集成、主权条件 S1–S4 的形式化，以及”高召回是结构性质而非评分性质”的论证组织。核心结果可以压缩为一条逻辑链：

算术（前提 1–2）迫使我们过滤掉 99.8%；**主权**（前提 3、S1–S4）决定过滤与获取为谁工作；**结构**（定理 6.1 的分离度瓶颈 + 定理 7.1–7.4 的冗余覆盖）证明高召回只能由架构而非评分承担——且该保证是条件性的，其强度取决于覆盖下界的制度来源与配额适配（§7.7），而架构的原料是主动获取——监测清单、信源探索、查询设计（第 8 节）；**统一定价**（定理 8.1 的注意力无套利）把 push、pull、反思置于同一个影子价格之下，使”主动”成为可计算的最优性条件；**对抗**（定理 9.1–9.3）给安全性以可实测标定的设计界，并给出个体防护普及翻转生产者生态的临界采纳率；**升华**（定理 10.1/猜想 10.1）把”成为更好的人”写成人类门控动力系统的收敛定理；**例外与公共性**（定理 11.1–11.2、12.1）给紧急权力以 Ulysses 契约的合法性、给普遍个性化以共享现实的下界。

证据边界与主张同宽：**人类侧结论全部为可证伪预言**（人类 RCT 暂缓，§15.5）；群体级验证（P1–P12 全表）进行中，预注册样本量未达；AI 智能体队列提供的是载体中立机制及其 AI 实例化的机制性支持——而非人类证据——H8/H9 已显示跨家族系统性分歧，向人类的转移是有证据支持的假设而非已证事实（§17 局限 15）。**本文没有任何主张建立在人类因果证据上**：人类 RCT 暂缓、已设计的最小人类试点 HP-0（§15.5）尚未收集数据；在此之前一切人类侧陈述均为预言，已完成经验工作应读作双域试点 + LLM 智能体可行性与机制验证——支持与边界映射，而非群体级验证。每一环都可证伪（第 13 节），每一环的失效模式都有预案（第 17 节）。已完成的双域试点既加固了枢纽定理（分离度瓶颈在两个域、两个独立特征族上得到确认），也划出了适用域边界（高召回强形式在学术域被拒、在金融域条件性成立；公共层认证一度失效并经工程部分恢复）——这些边界本身已成为框架内容的一部分（§7.7、§12.2）。

信息环境不是环境——它是正在形成的主体本人。本文的任务是为”成为什么样的人”这一永恒问题，提供一个属于主体自己的、数学上诚实的工具基础：不是替主体回答，而是保证答案的写入权、审计权与修订权，永远留在主体手中。

数据与代码可用性

本文全部仿真与实验代码（试点环境、三家族与四家族重放管线、算法参考实现、部署管线）、分析管道与结果数据**随本投稿作为补充材料提供**，并附实证章节所引的效应量表、敏感性分析、预注册判定规则与逐 run 完整性日志；**一致性审计报告**（审计方法论、预注册判定规则与审计脚本的输出台账；v1.3 生产周期的内部 QC/翻译日志保留在项目仓库供溯源，但按审稿意见**不**进入投稿包——补充材料只承载审计方法、判定规则与实验记录）作为补充材料的一部分发布，作为审计方法论的证据；**HP-0 人类可行性试点工具包**（方案、双语知情同意书、参与材料、数据模板、含合成干跑且标注 SYNTHETIC 的分析管线）随投稿提供，并明确声明目前不存在任何人类数据。仓库、Zenodo DOI、提交哈希与 OSF 注册链接在投稿信中提供；**匿名化镜像仓库与匿名 OSF 链接已备妥，若编辑部要求双盲评审即替换为评审工件**（署名与匿名两种形态不在稿件内同时使用）。派生数据集（arXiv 2019-09 语料、EDGAR 披露命题、公开新闻存档 CDX 层、Wikimedia pageviews、Manifold 人类校准锚、H8/H9 电池与三家族重放记录）可由随附抓取脚本从公开源（arXiv API、EDGAR、archive.org CDX、Wikimedia REST、OpenAlex、Manifold API）确定性重建，随机种子固定。关键实验的 JSON/CSV 摘要表与判定规则随补充材料提供。一致性审计脚本（编号交叉引用、文献闭合、关键数字对账、表格完整性）随代码公开。预注册文件（假设、环境快照、种子、分析计划）存档于 OSF，链接随投稿信与公开版提供。

参考文献

1. Ainslie, G. (1992). Picoeconomics: The Strategic Interaction of Successive Motivational States Within the Person. Cambridge University Press.
2. Allen, J., Howland, B., Mobius, M., Rothschild, D., & Watts, D. J. (2020). Evaluating the fake news problem at the scale of the information ecosystem. Science Advances, 6(14), eaay3539.

3. Aumann, R. J. (1976). Agreeing to disagree. The Annals of Statistics, 4(6), 1236–1239.
4. Bail, C. A., Argyle, L. P., Brown, T. W., Bumpus, J. P., Chen, H., Hunzaker, M. B. F., Lee, J., Mann, M., Merhout, F., & Volfovsky, A. (2018). Exposure to opposing views on social media can increase political polarization. PNAS, 115(37), 9216–9222.
5. Baron, J. (2008). Thinking and Deciding (4th ed.). Cambridge University Press.
6. Bertsekas, D. P., & Shreve, S. E. (1978). Stochastic Optimal Control: The Discrete Time Case. Academic Press.
7. Blackwell, D. (1953). Equivalent comparisons of experiments. The Annals of Mathematical Statistics, 24(2), 265–272.
8. Borkar, V. S. (1997). Stochastic approximation with two time scales. Systems & Control Letters, 29(5), 291–294.
9. Borkar, V. S. (2008). Stochastic Approximation: A Dynamical Systems Viewpoint (2nd ed.). Cambridge University Press.
10. Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. Monthly Weather Review, 78(1), 1–3.
11. Broadbent, D. E. (1958). Perception and Communication. Pergamon Press.
12. Buchanan, A. E., & Brock, D. W. (1990). Deciding for Others: The Ethics of Surrogate Decision Making. Cambridge University Press.
13. Chan, M. S., & Albarracín, D. (2023). A meta-analysis of correction effects in science-relevant misinformation. Nature Human Behaviour, 7, 1164–1173.
14. Chan, M. S., Jones, C. R., Hall Jamieson, K., & Albarracín, D. (2017). Debunking: A meta-analysis of the psychological efficacy of messages countering misinformation. Psychological Science, 28(11), 1544–1550.
15. Chang, W., Chen, E., Mellers, B., & Tetlock, P. (2016). Developing expert political judgment: The impact of training and practice on judgmental accuracy in geopolitical forecasting tournaments. Judgment and Decision Making, 11(5), 509–526.
16. Charnov, E. L. (1976). Optimal foraging, the marginal value theorem. Theoretical Population Biology, 9(2), 129–136.
17. Chaloner, K., & Verdinelli, I. (1995). Bayesian experimental design: A review. Statistical Science, 10(3), 273–304.
18. Clark, A., & Chalmers, D. (1998). The extended mind. Analysis, 58(1), 7–19.
19. Coady, C. A. J. (1992). Testimony: A Philosophical Study. Oxford University Press.
20. Coalition for Content Provenance and Authenticity (C2PA). (2021). Technical Specification.
21. Cover, T. M., & Thomas, J. A. (2006). Elements of Information Theory (2nd ed.). Wiley.
22. Cowan, N. (2001). The magical number 4 in short-term memory. Behavioral and Brain Sciences, 24(1), 87–114.
23. Dietvorst, B. J., Simmons, J. P., & Massey, C. (2015). Algorithm aversion: People erroneously avoid algorithms after seeing them err. Journal of Experimental Psychology: General, 144(1), 114–126.
24. Ebbinghaus, H. (1885). Über das Gedächtnis: Untersuchungen zur experimentellen Psychologie. Duncker & Humblot.
25. Ecker, U. K. H., Lewandowsky, S., Cook, J., Schmid, P., Fazio, L. K., Brashier, N., Kendeou, P., Vraga, E. K., & Amazeen, M. A. (2022). The psychological drivers of misinformation belief and its resistance to correction. Nature Reviews Psychology, 1, 13–29.

26. Elish, M. C. (2019). Moral crumple zones: Cautionary tales in human-robot interaction. Engaging Science, Technology, and Society, 5, 40–60.
27. Elster, J. (1979). Ulysses and the Sirens: Studies in Rationality and Irrationality. Cambridge University Press.
28. Elster, J. (1983). Sour Grapes: Studies in the Subversion of Rationality. Cambridge University Press.
29. Fazio, L. K., Brashier, N. M., Payne, B. K., & Marsh, E. J. (2015). Knowledge does not protect against illusory truth. Journal of Experimental Psychology: General, 144(5), 950–958.
30. Ferguson, T. S. (2006). Optimal Stopping and Applications. Springer.
31. Festinger, L. (1957). A Theory of Cognitive Dissonance. Stanford University Press.
32. Frankfurt, H. (1971). Freedom of the will and the concept of a person. The Journal of Philosophy, 68(1), 5–20.
33. Gentzkow, M., & Shapiro, J. M. (2011). Ideological segregation online and offline. The Quarterly Journal of Economics, 126(4), 1799–1849.
34. Gittins, J. C. (1979). Bandit processes and dynamic allocation indices. Journal of the Royal Statistical Society: Series B, 41(2), 148–177 (with discussion).
35. Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. Journal of the American Statistical Association, 102(477), 359–378.
36. Goodhart, C. A. E. (1984). Monetary Theory and Practice: The U.K. Experience. Macmillan.
37. Green, D. M., & Swets, J. A. (1966). Signal Detection Theory and Psychophysics. Wiley.
38. Grinberg, N., Joseph, K., Friedland, L., Swire-Thompson, B., & Lazer, D. (2019). Fake news on Twitter during the 2016 U.S. presidential election. Science, 363(6425), 374–377.
39. Guess, A., Nagler, J., & Tucker, J. (2019). Less than you think: Prevalence and predictors of fake news dissemination on Facebook. Science Advances, 5(1), eaau4586.
40. Guess, A., Malhotra, N., Pan, J., Barberá, P., Allcott, H., Brown, T., Dimmery, A., Moehler, D., Nyhan, B., Tucker, J. A., & Bonneau, R. (2023). How do social media feed algorithms affect attitudes and behavior in an election campaign? Science, 381(6656), 398–404.
41. Habermas, J. (1989). The Structural Transformation of the Public Sphere (T. Burger, Trans.). MIT Press.（原著 1962）
42. Hoeffding, W. (1963). Probability inequalities for sums of bounded random variables. Journal of the American Statistical Association, 58(301), 13–30.
43. Howard, R. A. (1966). Information value theory. IEEE Transactions on Systems Science and Cybernetics, 2(1), 22–26.
44. Kahan, D. M. (2017). Misconceptions, misinformation, and the logic of identity-protective cognition. Cultural Cognition Project Working Paper No. 264.
45. Kahneman, D. (2011). Thinking, Fast and Slow. Farrar, Straus and Giroux.
46. Khuller, S., Moss, A., & Naor, J. (1999). The budgeted maximum coverage problem. Information Processing Letters, 70(1), 39–45.
47. Krause, A., Singh, A., & Guestrin, C. (2008). Near-optimal sensor placements in Gaussian processes: Theory, efficient algorithms and empirical studies. Journal of Machine Learning Research, 9, 235–284.
48. Krumrei-Mancuso, E. J., & Rouse, S. V. (2016). The development and valida-

tion of the Comprehensive Intellectual Humility Scale. Journal of Personality Assessment, 98(2), 202–214.
49. Lazer, D. M. J., Baum, M. A., Benkler, Y., Berinsky, A. J., Greenhill, K. M., Menczer, F., Metzger, M. J., Nyhan, B., Pennycook, G., Rothschild, D., Schudson, M., Sloman, S. A., Sunstein, C. R., Thorson, E. A., Watts, D. J., & Zittrain, J. L. (2018). The science of fake news. Science, 359(6380), 1094–1096.
50. Levine, T. R. (2014). Truth-default theory (TDT): Accounting for the effects of deception detection research. Journal of Language and Social Psychology, 33(4), 378–392.
51. Lewandowsky, S., Ecker, U. K. H., Seifert, C. M., Schwarz, N., & Cook, J. (2012). Misinformation and its correction: Continued influence and successful debiasing. Psychological Science in the Public Interest, 13(3), 106–120.
52. Lindley, D. V. (1956). On a measure of the information provided by an experiment. The Annals of Mathematical Statistics, 27(4), 986–1005.
53. Liu, Y., Deng, G., Li, Z., Wang, K., Wang, Z., Zhang, T., Fan, L., Wang, H., Zhang, L., & Liu, Y. (2024). Formalizing and benchmarking prompt injection attacks and defenses. In Proceedings of the 33rd USENIX Security Symposium.
54. Logg, J. M., Minson, J. A., & Moore, D. A. (2019). Algorithm appreciation: People prefer algorithmic to human judgment. Organizational Behavior and Human Decision Processes, 151, 90–103.
55. Maćkowiak, B., Matějka, F., & Wiederholt, M. (2023). Rational inattention: A review. Journal of Economic Literature, 61(1), 226–273.
56. Matějka, F., & McKay, A. (2015). Rational inattention to discrete choices: A new foundation for the multinomial logit model. American Economic Review, 105(1), 272–298.
57. McGuire, W. J. (1964). Inducing resistance to persuasion: Some contemporary approaches. Advances in Experimental Social Psychology, 1, 191–229.
58. McPherson, M., Smith-Lovin, L., & Cook, J. M. (2001). Birds of a feather: Homophily in social networks. Annual Review of Sociology, 27, 415–444.
59. Miller, G. A. (1956). The magical number seven, plus or minus two: Some limits on our capacity for processing information. Psychological Review, 63(2), 81–97.
60. Monderer, D., & Samet, D. (1989). Approximating common knowledge with common beliefs. Games and Economic Behavior, 1(2), 170–190.
61. Nemhauser, G. L., Wolsey, L. A., & Fisher, M. L. (1978). An analysis of approximations for maximizing submodular set functions—I. Mathematical Programming, 14, 265–274.
62. Nguyen, C. T. (2019). Escape the echo chamber. Aeon.（另见 Games: Agency as Art, Oxford University Press, 2020，关于价值捕获的论述）
63. Nguyen, C. T. (2020). Echo chambers and epistemic bubbles. Episteme, 17(2), 141–161.
64. Papadimitriou, C. H., & Tsitsiklis, J. N. (1999). The complexity of optimal queueing network control. Mathematics of Operations Research, 24(2), 293–305.
65. Pariser, E. (2011). The Filter Bubble: What the Internet Is Hiding from You. Penguin Press.
66. Parasuraman, R., & Riley, V. (1997). Humans and automation: Use, misuse, disuse, abuse. Human Factors, 39(2), 230–253.
67. Paul, C., & Matthews, M. (2016). The Russian “Firehose of Falsehood” Propaganda Model. RAND Corporation.
68. Paul, L. A. (2014). Transformative Experience. Oxford University Press.

69. Pennycook, G., & Rand, D. G. (2019). Lazy, not biased: Susceptibility to partisan fake news is better explained by lack of reasoning than by motivated reasoning. Cognition, 188, 39–50.
70. Pennycook, G., & Rand, D. G. (2022). Accuracy prompts are a replicable and generalizable approach to reducing the spread of misinformation. Nature Communications, 13, 1732.
71. Pirolli, P., & Card, S. (1999). Information foraging. Psychological Review, 106(4), 643–675.
72. Resnick, S. I. (1987). Extreme Values, Regular Variation, and Point Processes. Springer.
73. Robbins, H., & Siegmund, D. (1971). A convergence theorem for nonnegative almost supermartingales and some applications. In Optimizing Methods in Statistics (pp. 233–257). Academic Press.
74. Roozenbeek, J., & van der Linden, S. (2019). Fake news game confers psychological resistance against online misinformation. Palgrave Communications, 5, 65.
75. Savage, L. J. (1951). The theory of statistical decision. Journal of the American Statistical Association, 46(253), 55–67.
76. Settles, B. (2009). Active Learning Literature Survey (Computer Sciences Technical Report 1648). University of Wisconsin–Madison.
77. Shumailov, I., Shumilo, Z., Zhao, Y., Gal, Y., Papernot, N., Anderson, R., Shejwalkar, V., Houmansadr, A., & Smith, R. (2024). AI models collapse when trained on recursively generated data. Nature, 631, 755–759.
78. Simon, H. A. (1955). A behavioral model of rational choice. The Quarterly Journal of Economics, 69(1), 99–118.
79. Simon, H. A. (1971). Designing organizations for an information-rich world. In Computers, Communications, and the Public Interest. Johns Hopkins Press.
80. Sims, C. A. (2003). Implications of rational inattention. Journal of Monetary Economics, 50(3), 665–690.
81. Sparrow, B., Liu, J., & Wegner, D. M. (2011). Google effects on memory: Cognitive consequences of having information at our fingertips. Science, 333(6043), 776–778.
82. Stanovich, K. E., & West, R. F. (1997). Reasoning independently of prior belief and individual differences in actively open-minded thinking. Journal of Educational Psychology, 89(2), 342–357.
83. Stigler, G. J. (1961). The economics of information. Journal of Political Economy, 69(3), 213–225.
84. Stroud, N. J. (2011). Niche News: The Politics of News Choice. Oxford University Press.
85. Sunstein, C. R. (2017). #Republic: Divided Democracy in the Age of Social Media. Princeton University Press.
86. Sviridenko, M. (2004). A note on maximizing a submodular set function subject to a knapsack constraint. Operations Research Letters, 32(1), 41–43.
87. Sweller, J. (1988). Cognitive load during problem solving: Effects on learning. Cognitive Science, 12(2), 257–285.
88. Thaler, R. H., & Shefrin, H. M. (1981). An economic theory of self-control. Journal of Political Economy, 89(2), 392–406.
89. Thaler, R. H., & Sunstein, C. R. (2008). Nudge: Improving Decisions About Health, Wealth, and Happiness. Yale University Press.
90. Vallor, S. (2016). Technology and the Virtues: A Philosophical Guide to a Future Worth Wanting. Oxford University Press.

91. van der Linden, S. (2022). Foolproof: Why Misinformation Infects Our Minds and How to Build Immunity. W. W. Norton.
92. Vosoughi, S., Roy, D., & Aral, S. (2018). The spread of true and false news online. Science, 359(6380), 1146–1151.
93. Weber, R. R., & Weiss, G. (1990). On an index policy for restless bandits. Journal of Applied Probability, 27(3), 637–648.
94. Weitzman, M. L. (1979). Optimal search for the best alternative. Econometrica, 47(3), 641–654.
95. Whittle, P. (1988). Restless bandits: Activity allocation in a changing world. Journal of Applied Probability, 25(A), 287–298.
96. Williams, J. (2018). Stand Out of Our Light: Freedom and Resistance in the Attention Economy. Cambridge University Press.
97. Wineburg, S., & McGrew, S. (2019). Lateral reading and the nature of expertise: Reading less and learning more when evaluating digital information. Teachers College Record, 121(11), 1–40.
98. Wu, T. (2016). The Attention Merchants: The Epic Scramble to Get Inside Our Heads. Knopf.
99. Zagzebski, L. (2012). Epistemic Authority: A Theory of Trust, Authority, and Autonomy in Belief. Oxford University Press.
100. Zuboff, S. (2019). The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power. PublicAffairs.
101. Allcott, H., Braghieri, L., Eichmeyer, S., & Gentzkow, M. (2020). The welfare effects of social media. American Economic Review, 110(3), 629–676.
102. Allcott, H., Gentzkow, M., & Song, L. (2022). Digital addiction. American Economic Review, 112(7), 2424–2463.
103. Bakshy, E., Messing, S., & Adamic, L. A. (2015). Exposure to ideologically diverse news and opinion on Facebook. Science, 348(6239), 1130–1132.
104. Bozdag, E., & van den Hoven, J. (2015). Breaking the filter bubble: Democracy and design. Ethics and Information Technology, 17(4), 249–265.
105. Buchbinder, N., Feldman, M., Naor, J., & Schwartz, R. (2014). Submodular maximization with cardinality constraints. In Proceedings of the 25th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA), 1433–1452.
106. Călinescu, G., Chekuri, C., Pál, M., & Vondrák, J. (2011). Maximizing a monotone submodular function subject to a matroid constraint. SIAM Journal on Computing, 40(6), 1740–1766.
107. Caplin, A., Dean, M., & Leahy, J. (2019). Rational inattention, optimal consideration sets, and stochastic choice. Review of Economic Studies, 86(3), 1061–1094.
108. Doval, L. (2018). Whether or not to open Pandora's box. Journal of Economic Theory, 175, 127–158.
109. Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T., & Fritz, M. (2023). Not what you've signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection. In Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security (AISec), 79–90.
110. Helberger, N., Karppinen, K., & D'Acunto, L. (2018). Exposure diversity as a design principle for recommender systems. Information, Communication & Society, 21(2), 191–207.
111. Kleinberg, J., & Raghavan, M. (2021). Algorithmic monoculture and social welfare. Proceedings of the National Academy of Sciences, 118(22), e2018340118.
112. Kleinberg, J., Mullainathan, S., & Raghavan, M. (2024). The challenge of un-

derstanding what users want: Inconsistent preferences and engagement optimization. Management Science, 70(9), 6336–6358.
113. Leskovec, J., Krause, A., Guestrin, C., Faloutsos, C., VanBriesen, J., & Glance, N. (2007). Cost-effective outbreak detection in networks. In Proceedings of the 13th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 420–429.
114. Olszewski, W., & Weber, R. (2015). A more general Pandora rule? Journal of Economic Theory, 160, 429–437.
115. Stray, J., Vendrov, I., Nixon, J., Adler, S., & Hadfield-Menell, D. (2022). Building human values into recommender systems: An interdisciplinary synthesis. arXiv:2207.10192.（修订版见 ACM Transactions on Recommender Systems, 2024）
116. Zhong, W. (2022). Optimal dynamic information acquisition. Econometrica, 90(4), 1537–1582.
117. Dalvi, N., Domingos, P., Mausam, Sanghai, S., & Verma, D. (2004). Adversarial classification. In Proceedings of the 10th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 99–108.
118. Lowd, D., & Meek, C. (2005). Adversarial learning. In Proceedings of the 11th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 641–647.
119. Biggio, B., & Roli, F. (2018). Wild patterns: Ten years after the rise of adversarial machine learning. Pattern Recognition, 84, 317–331.
120. Sharma, M., Tong, M., Korbak, T., Duvenaud, D., Askell, A., Bowman, S. R., ⋯ & Perez, E. (2023). Towards understanding sycophancy in language models. arXiv:2310.13548.
121. Hadfield-Menell, D., Russell, S. J., Abbeel, P., & Dragan, A. (2016). Cooperative inverse reinforcement learning. In Advances in Neural Information Processing Systems 29 (NeurIPS).
122. Hadfield-Menell, D., Dragan, A., Abbeel, P., & Russell, S. (2017). The off-switch game. In Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI), 220–227.
123. Hegselmann, R., & Krause, U. (2002). Opinion dynamics and bounded confidence: Models, analysis and simulation. Journal of Artificial Societies and Social Simulation, 5(3).
124. Deffuant, G., Neau, D., Amblard, F., & Weisbuch, G. (2000). Mixing beliefs among interacting agents. Advances in Complex Systems, 3(1–4), 87–98.
125. Nan, Q., Cao, J., Zhu, Y., Wang, Y., & Li, J. (2021). MDFEND: Multi-domain fake news detection（Weibo21 数据集）. In Proceedings of the 30th ACM International Conference on Information and Knowledge Management (CIKM), 3338–3342.
126. Augenstein, I., Lioma, C., Wang, D., Chaves Lima, L., Hansen, C., Hansen, C., & Simonsen, J. G. (2019). MultiFC: A real-world multi-domain dataset for evidence-based fact checking of claims. In Proceedings of EMNLP-IJCNLP 2019, 4685–4697.
127. Angeletos, G.-M., & Sastry, K. A. (2025). Inattentive economies. Journal of Political Economy, 133(7), 2265–2319.
128. Xi, Z., Chen, W., Guo, X., He, W., Ding, Y., Hong, B., Zhang, M., Wang, J., Jin, S., Zhou, E., Zheng, R., Fan, X., Wang, X., Xiong, L., Zhou, Y., Wang, W., Jiang, C., Zou, Y., Liu, X., Yin, Z., Dou, S., Weng, R., Qin, W., Zheng, Y., Qiu, X., Huang, X., Zhang, Q., & Gui, T. (2025). The rise and potential of large language model based agents: A survey. Science China Information Sciences, 68(2), 121101.

129. Tang, Y., Liu, Y., Lan, J., Yan, Z., & Gelenbe, E. (2025; online first, version of record 2026). Security of LLM-based agents regarding attacks, defenses, and applications: A comprehensive survey. Information Fusion, 127, 103941.
130. Geng, T., Xu, Z., Qu, Y., & Wong, W. E. (2025; online first, version of record 2026). Prompt injection attacks on large language models: A survey of attack methods, root causes, and defense strategies. Computers, Materials & Continua, 87(1), Article 4.
131. Van den Bulck, H., Kulig, M., Hyzen, A., Puppis, M., & Paulussen, S. (2025). Epistemic welfare and public service media's algorithmic recommender systems: A theoretical framework, operationalization and relevance for governance. European Journal of Communication, 40(6), 598–618.
132. Hyzen, A., Van den Bulck, H., Puppis, M., Kulig, M., & Paulussen, S. (2025; online first, issue of record February 2026). Epistemic welfare and algorithmic recommender systems: Overcoming the epistemic crisis in the digitalized public sphere. Communication Theory, 36(1), 46–57.
133. Simchon, A., Zipori, T., Teitelbaum, L., Lewandowsky, S., & van der Linden, S. (2025; online first, volume of record 2026). A signal detection theory meta-analysis of psychological inoculation against misinformation. Current Opinion in Psychology, 67, 102194.
134. Wang, S. Y. N., Phillips, S. C., Carley, K. M., Lin, H., & Pennycook, G. (2025). Limited effectiveness of psychological inoculation against misinformation in a social media feed. PNAS Nexus, 4(6), pgaf172.
135. Ahmmad, M., Shahzad, K., Iqbal, A., & Latif, M. (2025). Trap of social media algorithms: A systematic review of research on filter bubbles, echo chambers, and their impact on youth. Societies, 15(11), 301.
136. Kommers, C., Duede, E., Gordon, J., Holtzman, A., McNulty, T., Stewart, S., Thomas, L., So, R. J., & Long, H. (2026). Why slop matters. ACM AI Letters, 1(1), 1–6.
137. DeGroot, M. H. (1962). Uncertainty, information, and sequential experiments. The Annals of Mathematical Statistics, 33(2), 404–419.
138. Morris, S., & Shin, H. S. (2002). Social value of public information. American Economic Review, 92(5), 1521–1534.
139. Gabaix, X. (2014). A sparsity-based model of bounded rationality. The Quarterly Journal of Economics, 129(4), 1661–1710.

引用年份口径：文献 129、130、132、133 的在线优先年（2025）早于版本记录卷期年（2026）；按在线优先惯例，正文引用用在线优先年，条目中两年并列。其余条目用版本记录年。作者姓氏拼写以出版方沉积为准（Ahmmad 双 m；Roozenbeek；Matějka 与 Maćkowiak 带变音符号）。**v1.6 增补注**：文献 137–139 按四审意见新增（三条均经 Crossref/出版方记录逐条核验）；稀疏理性纲领以其版本记录（Gabaix, QJE 2014）引用，而非后期的工作论文流传版本。

附录 A 记号表

同一符号在不同章节按局部约定使用（标准数学实践），下表给出全局索引；其后的**冲突符号消歧表**逐一列出复用符号的各义项与作用域——阅读任何公式时以所在章节的义项为准。

核心速查表（v1.6 新增——最小工作集）：以下约 15 个符号足以跟随全部主定理链；本文其余一切编号族（P/H/O/L/E/S/C/R/F/V/I/W/KC）都是在各自定义处局部使用的检索装置，初读无需记忆任何一个：

符号	含义	驱动的主结果
T；N	每期认知预算；日候选供给	前提 1–2（99.8% 算术）
X, x_i；$\phi(x_i)$	信息流、条目；其五维特征向量	定义 4.1；定理 5.1
E, e；κ；ρ_c	命题；文档 → 命题归并映射；归并比	定义 4.2–4.3；推论 6.1
D；E^*	声明的活跃决策集；关键命题集	定义 4.6；第 7 节
$g^{(1)}, g^{(2)}$；R	一阶偏好；二阶意志；反思层	前提 3；S1–S4
v_i^*；$W_i^{(d)}$	条目真值；逐决策期望实现决策价值	定理 5.1；定义 5.2
VOI, $c_i, \pi_d(i), h_i, \lambda_d$	Blackwell 价值；可信度；决策相关度；时间差；耐久尺度	定理 5.1
β, π, d', R（第 6 章局部）	消费率；关键占比；评分分离度；召回	定理 6.1（4.39 要求线）
$p_{\min}, k, k_{\text{eff}}$	覆盖下界；监测类数；有效独立类数	定理 7.1–7.2
ν	认知预算的影子价格	定理 8.1（无套利）
θ, θ^*；c_0, b_0；q_t	德性状态与声明理想；漂移常数；人类门	定理 10.1/猜想 10.1
$\rho_m, n_{\max}$；σ^*	防火墙检测召回；单源暴露上限；临界采纳率	定理 9.1–9.3
Ω；γ	人口共同知识面积；公共层份额	定理 12.1

符号	含义	首次出现
T；$T_{\text{pull}}, T_{\text{push}}, T_{\text{ref}}$	周期认知预算及其三分	前提 1；定义 4.7
$N, \lambda, \bar{t}$	候选供给量、到达率、平均消费成本	前提 2
$X, x_i, \phi(x_i)$	信息流、条目、五维特征向量	定义 4.1
$E, e_j, D_e, \kappa, \rho_c$	命题集、命题、其文档集、归并映射、坍缩比	定义 4.2–4.3
$\mathcal{C}_i, Z_i(e), p_{\min}, k, k_{\text{eff}}$	信源类、覆盖事件、覆盖下界、监控类数、有效独立类数	定义 4.4；定理 7.1–7.2
$\mathcal{A} = (C, G, K, \theta, R)$	智能体五元组	定义 4.5
$g^{(1)}, g^{(2)}$	一阶偏好 / 第二序意志	前提 3
D（第 4–6、8 章）；E^*	活跃决策集；关键命题集	定义 4.6
$\pi = (\pi_{\text{mon}}, \pi_{\text{pull}}, \pi_{\text{push}}, \pi_{\text{del}}, \pi_{\text{esc}})$	策略五元组	定义 4.7
VOI, $c_i, \pi_d(i), h_i, \lambda_d$	信息价值、可信度、决策关联度、时距、耐久尺度	定理 5.1
$\sigma_1 \succeq_B \sigma_2$	Blackwell 信息化序（σ_2 由 σ_1 加噪退化而得: $\sigma_2 = \sigma_1 \circ K$）	附录 B.5(ii)
$\mathcal{D}, \mathcal{D}^*$	关键价值泄漏（失真）及其下界	定义 6.1；命题 6.2
β, π（第 6 章局部）、d'、R（第 6 章局部）	消费率、关键比例、评分分离度、召回率	定理 6.1
$U, U_{\text{cov}}, U_{\text{div}}, U_{\text{mon}}$	选择效用、覆盖效用、多样性效用、监测覆盖效用	6.3；定义 7.2
ν	预算影子价格（注意力无套利价格）	定理 8.1
z_s, X_s, c_e	Pandora 保留指数、信源收益、探索成本	命题 8.1
$G_s(t), c_{sw}$	补丁累积收益、切换成本	命题 8.2
$I(Q)$, EIG	查询批次的条件互信息	定理 8.2
$\Delta, D(\tilde{U}, U), \delta, \rho_m, n_{\max}, \varepsilon_c$	权重漂移、目标发散度量、单条影响界、检测召回、暴露上限、容忍阈	定义 9.1；F1–F3
$\sigma, \sigma^*, \Pi_q, \varepsilon_g$（第 9 章）	采纳率、临界采纳率、生产者收益、防火墙漏网率	定理 9.3
$\theta = (\theta_{\text{cal}}, \theta_{\text{open}}, \theta_{\text{hum}}), \theta^*, \hat{\theta}_t$	德性状态、声明理想态、含噪测量	定义 10.1
$\rho(\theta), E_t, q_t, a_t$（第 10 章）	容差半径、曝光集、参与质量、步长	定义 10.2；10.1
$c_0, b_0, F(\theta)$	课程漂移常数、漂移地板、期望漂移	C1
$D_{\text{adv}} = (\mathcal{E}, \mathcal{A}_{\text{safe}}, \eta, q^*)$	预先授权指令	定义 11.2
$R(a, \omega), \succeq_{\text{rev}}$	遗憾、可逆性偏序	定义 11.4
$P_t, \gamma, k_c, \bar{\Omega}, J$	公共层、其预算占比、认证类数、议程重叠度、Jaccard	定义 12.1–12.2
S1–S4；I1–I5；前提 1–6	主权条件；不变量；前提	定义 5.3；命题 3.1；§3.1
R1–R3；F1–F3；C1–C5；(V1)–(V5)；(P1)–(P2)	各章假设组（冗余/防火墙/收敛/特征分解/凹性可分性）	§7.1；§9.2；§10.3；§5.2；§8.2
P1–P12	可证伪命题（与假设 (P1)–(P2) 无涉，见第 13 节表）	§13

符号	含义	首次出现
H1–H7	预注册实验假设	§15.4

冲突符号消歧表（复用符号的义项与作用域）：

符号	义项与作用域
D	(1) 活跃决策集（定义 4.6，第 4–6、8 章）；(2) 目标发散度量 $D(\tilde{U}, U)$（定义 9.1，第 9 章）；(3) 关键价值泄漏记作花体 $\mathcal{D}$（定义 6.1），与 (1)(2) 区分
π	(1) 策略五元组（定义 4.7，全局）；(2) 关键命题比例（定理 6.1，仅第 6 章）；(3) 决策关联度 $\pi_d(i)$（定理 5.1，带下标）；(4) 生产者收益记作大写 Π（第 9 章）
ρ	(1) 坍缩比 ρ_c（定义 4.3）；(2) 检测召回 ρ_m（F2）；(3) 容差半径 $\rho(\theta)$（定义 10.2）——三者均带下标或为函数形式，裸 ρ 不使用
θ	(1) 德性状态（定义 10.1，第 10 章）；(2) 状态空间记作大写 Θ_{rel}（§4.2、§5.2），与 (1) 区分
λ	(1) 到达率（前提 2）；(2) 耐久尺度 λ_d（(V3)）；(3) 操控惩罚权重（§6.3）；(4) 理性疏忽信息价格（命题 8.3）——(2)–(4) 均有局部声明
β	(1) 贴现因子（SAP，定义 5.1）；(2) 消费率（定理 6.1，仅第 6 章）；(3) 置信水平 $1-\beta$（定理 9.2，仅第 9 章）
R	(1) 反思层（定义 4.5，全局）；(2) 召回率（定理 6.1，仅第 6 章）；(3) 遗憾 $R(a,\omega)$（定义 11.4，带变元）
k	(1) 监控信源类数（§7.1）；(2) 可检视性项数上限（S1）；(3) 认证类数记作 k_c（定义 12.1）
γ	(1) 公共层预算占比（定义 12.1）；(2) 复制子灭绝速率参数（命题 9.2，仅 §9.4）；(3) 冷却衰减率（§6.4 注，仅该处）
c_p	(1) 伪造一手信源的边际成本（§9.4，溯源要求 I3）；(2) 预防行动成本（§11.3–11.4，两行动闭式）——两义项不共现于同一公式
Ω	(1) 紧急覆盖的不确定集（定义 11.4，仅第 11 章）；(2) 议程重叠度指标（定义 12.1–12.2，仅第 12 章）

附录 B 技术引理

本附录收录正文引用的标准结果的精确陈述；除注明”经典结果，证明见原出处”者外，均给出完整证明。

B.1 Hoeffding 不等式

引理 B.1（Hoeffding, 1963）。设 $B_1, \dots, B_n$ 独立，$B_i \in [0,1]$ a.s.，$S_n = \sum_i B_i$。则对任意 $u > 0$：

$$P(S_n - \mathbb{E}S_n \geq u) \;\leq\; e^{-2u^2/n}.$$

证明概要（完整推导见 Hoeffding (1963)）：对 $e^{t(S_n - \mathbb{E}S_n)}$ 用 Markov 不等式；独立性使矩母函数分解；每个 $[0,1]$ 变量的中心化矩母函数被 $\exp(t^2/8)$ 控制（Hoeffding 引理，凸性论证）；对 t 优化取 $t = 4u/n$。■

B.2 随机比较引理（Robbins–Siegmund 型）

引理 B.2(i)（零偏置情形）。设 $V_t \geq 0$ 适应，$\alpha_t \in [0,1)$、$\beta_t \geq 0$ 适应，且

$$\mathbb{E}[V_{t+1} \mid \mathcal{F}_t] \;\leq\; (1-\alpha_t)\, V_t + \beta_t. \tag{B.1}$$

若 $\sum_t \beta_t < \infty$ a.s. 且 $\sum_t \alpha_t = \infty$ a.s.，则 $V_t \to 0$ a.s.

证明。这是 Robbins–Siegmund 定理（1971, Theorem 1：若 $\mathbb{E}[V_{t+1}|\mathcal{F}_t] \leq (1+a_t)V_t + b_t - c_t$，其中 $a_t, b_t, c_t \geq 0$ 适应，$\sum a_t < \infty$、$\sum b_t < \infty$ a.s.，则 V_t a.s. 收敛于有限极

限且 $\sum c_t<\infty$ a.s.）取 $a_t\equiv 0$、$b_t=\beta_t$、$c_t=\alpha_t V_t$ 的实例：V_t a.s. 收敛于某 $V_\infty\ge 0$，且 $\sum_t \alpha_t V_t<\infty$ a.s.。若 $P(V_\infty>0)>0$，则在该事件上存在（随机）t_0 使 $t\ge t_0$ 时 $V_t\ge V_\infty/2$（收敛性），从而 $\sum_t \alpha_t V_t\ge (V_\infty/2)\sum_{t\ge t_0}\alpha_t=\infty$（用 $\sum_t\alpha_t=\infty$），与 $\sum_t\alpha_t V_t<\infty$ 矛盾。故 $V_\infty=0$ a.s.。

R–S 定理本身的证明是标准的尾和归约（此处给出梗概以备查阅）：令 $B_t:=\sum_{s\ge t}\beta_s$（a.s. 有限且 $B_t\downarrow 0$），$U_t:=V_t+B_t\ge 0$，则 $\mathbb{E}[U_{t+1}\mid\mathcal{F}_t]\le U_t-c_t\le U_t$，即 U 为非负几乎上鞅；Doob 上鞅收敛定理给出 U（从而 V）的 a.s. 收敛，再沿路径对 $U_{t+1}\le U_t-c_t+(\text{鞅差})$ 求和并经鞅收敛定理处理鞅差部分，得 $\sum c_t<\infty$ a.s.。细节见 Robbins & Siegmund (1971)。■

引理 B.2(ii)（常比率情形）。在 (B.1) 下，若存在常数 $c\ge 0$ 与（随机）时刻 τ 使 $t\ge\tau$ 时 $\beta_t\le\alpha_t c$ a.s.，$\sum_t\alpha_t=\infty$ a.s.，则：

(a)（期望版本，初等）若 α_t、β_t 可预测（如确定性），则 $\limsup_t \mathbb{E}[V_t]\le c$；

(b)（a.s. 版本）若 (B.1) 来自紧集上投影的随机逼近递归——均值场 Lipschitz、噪声条件期望为零且条件二阶矩 $O(a_t^2)$（即猜想 10.1 论证的结构，其中 $\alpha_t=2a_tc_0$、$\beta_t=2a_tb_0+a_t^2M'$，投影到紧集 $[0,1]^3$ 保证迭代有界）——则 $\limsup_t V_t\le c$ a.s.。

证明。(a) 取全期望：$\bar V_{t+1}\le(1-\alpha_t)\bar V_t+\alpha_t c$。令 $W_t:=\bar V_t-c$，则 $W_{t+1}\le(1-\alpha_t)W_t$；迭代得 $W_t\le W_\tau\prod_{s=\tau}^{t-1}(1-\alpha_s)$，而 $\sum\alpha_s=\infty$ 使乘积趋于零（$\prod(1-\alpha_s)\le\exp(-\sum\alpha_s)\to 0$），故 $\limsup_t\bar V_t\le c$。

(b) 这是随机逼近 ODE 方法的标准结论（Borkar, 2008, 第 2 章：紧投影给出有界迭代；Lipschitz 均值场保证极限 ODE 良定；Kushner–Clark 引理把递归的极限集 a.s. 包含进极限 ODE 的内链传递集）。在猜想 10.1 的论证中，V 的递归被 ODE $\dot v=-2c_0(v-b_0/c_0)$ 控制（由 C1 漂移不等式），其一切解满足 $\limsup_t v(t)\le b_0/c_0$；取 c 为任意大于 b_0/c_0 的常数即得 $\limsup_t V_t\le c$ a.s.，令 $c\downarrow b_0/c_0$ 得结论。**诚实注记（v1.6）**：把这一标准结论转用到 §10.3 的门控子列 + 标量比较量设定，正是那里的清单条目 (KC5)——按梗概级引用、未重新推导；这就是 $b_0>0$ 分支带猜想地位而非定理地位的原因。$c=0$ 且 $\sum\beta_t<\infty$ 的特例由 (i) 初等覆盖，而定理 10.1（$b_0=0$）只需要 (i)。■

注（用法对照）：定理 10.1（$b_0=0$）的证明只走 (i)（纯初等，$\sum\beta_t=M'\sum a_t^2<\infty$）；支持猜想 10.1（$b_0>0$）的论证走 (ii)(b)（$\beta_t/\alpha_t=b_0/c_0+a_tM'/(2c_0)\to b_0/c_0$，条件 $\beta_t\le\alpha_t c$ 对任意 $c>b_0/c_0$ 与大 t 成立），并受 (KC5) 但书约束。期望版本（定理 10.2）走 (ii)(a) 的同一比较，对两个分支均为初等。

B.3 步长稀释引理

引理 B.3。设 $a_t\ge c_a/t$（$t\ge t_0$，$c_a>0$），停时刻列 $\{t_j\}$ 满足 $t_1\ge 1$、$t_{j+1}-t_j\le\Delta$。则 $\sum_j a_{t_j}=\infty$，且若 $\sum_t a_t^2<\infty$ 则 $\sum_j a_{t_j}^2<\infty$。

证明。$t_j\le t_1+(j-1)\Delta$，故 $a_{t_j}\ge c_a/(t_1+(j-1)\Delta)$；右端是调和级数的常数倍，发散。平方可和性：$\sum_j a_{t_j}^2\le\sum_t a_t^2<\infty$（子列和 $\le$ 全列和）。■

B.4 次模函数与贪心 $(1-1/e)$ 保证

定义 B.1。集函数 $f:2^V\to\mathbb{R}$ 称**次模**，若对一切 $A\subseteq B\subseteq V$、$i\notin B$：$f(A\cup i)-f(A)\ge f(B\cup i)-f(B)$（边际增益递减）；称**单调**，若 $A\subseteq B\Rightarrow f(A)\le f(B)$。

引理 B.4（Nemhauser, Wolsey & Fisher, 1978）。设 f 单调次模，$f(\emptyset)=0$，基数约束 $|A|\le k$。贪心序列 $A_0=\emptyset\subseteq A_1\subseteq\dots$（每步加入边际增益最大元素）满足

$$f(A_k)\ \ge\ \Big(1-(1-\tfrac{1}{k})^{k}\Big)f(\mathrm{OPT})\ \ge\ (1-\tfrac{1}{e})f(\mathrm{OPT}).$$

证明。记 $O=\mathrm{OPT}$，$|O|\le k$。单调性 + 次模性给出标准上界：

$$f(O)\le f(A_i\cup O)\le f(A_i)+\sum_{o\in O}\big[f(A_i\cup o)-f(A_i)\big]\le f(A_i)+k\cdot\big[f(A_{i+1})-f(A_i)\big],$$

（第一个不等号：单调；第二个：次模性逐元素叠加；第三个：每单项增益 $\le$ 贪心所选的最大增益 $=f(A_{i+1})-f(A_i)$。）整理：

$$f(A_{i+1})-f(O)\ \ge\ (1-\tfrac{1}{k})\big(f(A_i)-f(O)\big).$$

由 $f(A_0)=0$ 迭代 k 次：$f(A_k)\ge(1-(1-\tfrac{1}{k})^{k})f(O)$；$(1-\tfrac{1}{k})^{k}\le e^{-1}$ 完成证明。■

背包变体（陈述，证明见原文）：成本约束 $\sum_{i\in A}c_i\le B$ 下，密度贪心与最优单元素取较优者达 $\tfrac{1}{2}(1-\tfrac{1}{e})$（folklore，证明见 Leskovec et al., 2007）；部分枚举 + 密度贪心恰好达 $1-\tfrac{1}{e}$（Sviridenko, 2004）；连续贪心 + 舍入框架见 Călinescu, Chekuri, Pál & Vondrák (2011)。

B.5 EVPI 非负性与 Blackwell 定理

引理 B.5(i)（信息价值非负）。对任一决策问题与任一实验（信号）y：

$$\mathbb{E}_y\Big[\max_a\mathbb{E}[u(a,\omega)\mid y]\Big]\ \ge\ \max_a\mathbb{E}[u(a,\omega)].$$

证明。固定 $a_0=\arg\max_a\mathbb{E}[u(a,\omega)]$。对每个 y：$\max_a\mathbb{E}[u\mid y]\ge\mathbb{E}[u(a_0,\omega)\mid y]$。对 y 取期望并用全期望公式（塔性质）：右端 $=\mathbb{E}[u(a_0,\omega)]=\max_a\mathbb{E}[u(a,\omega)]$。■

引理 B.5(ii)（Blackwell, 1953, 陈述）。实验 σ_1 比 σ_2 更信息化（记 $\sigma_1\succeq_B\sigma_2$：$\sigma_2$ 由 σ_1 加噪退化而得，即存在马尔可夫核使 $\sigma_2=\sigma_1\circ K$）当且仅当对一切决策问题与一切效用函数，σ_1 的期望价值不低于 σ_2。（证明见 Blackwell (1953)；定理 5.1 只使用其"更信息化 ⇒ 价值更高"方向，该方向是数据处理不等式的直接推论。）

B.6 正态分位数对照（正文数值复现用）

量	值	用到处
$\Phi^{-1}(0.95)$	1.645	定理 6.1(iii)
$\Phi^{-1}(0.99697)$ $(=\bar\Phi^{-1}(0.00303))$	≈ 2.744	定理 6.1(iv) $(\Phi(2.74)=0.00307,$ $\bar\Phi(2.75)=0.00298$，线性内插$)$
$\underline{d'}(0.0125,0.01,0.95)$	≈ 4.39	定理 6.1(iv)
$\Phi(4.39/\sqrt{2})=\Phi(3.10)$	≈ 0.9990	定理 6.1(iv) 的 AUC
$d'=1.5$ 时召回 $(\beta=0.0125,\pi=0.01)$	≈ 0.21	§6.2 后果 2（数值解混合尾方程：$z\approx 2.31$，$R=\bar\Phi(0.81)$）
$d'=2.5$ 时召回（同上）	≈ 0.52	§6.2 后果 2（$z\approx 2.44$，$R=\bar\Phi(-0.06)$）
0.3^5	2.43×10^{-3}	定理 7.1 数值

量	值	用到处
$\gamma/(2-\gamma)$, $\gamma \in \{0.1, 0.2, 1/3\}$	$0.053/0.111/0.200$（依次）	定理 12.1 数值
每臂样本量（$d = 0.35$, $\alpha = 0.05$，功效 0.8）	$n = 2(1.96 + 0.84)^2/0.35^2 \approx 128$；含 25% 流失每臂 170	§15.5（暂缓的 RCT）

（全文完·2026 年 10 月）